Pontifícia Universidade Católica de Minas Gerais
Instituto de Ciências Exatas e de Informática

Lista de Exercícios 03 - Inteligência Artificial

Vitor Costa Oliveira Rolla

Pontifícia Universidade Católica de Minas Gerais

15 de novembro de 2025

Questão 01

Sobre os conceitos de métodos de amostragem, responda

1. Qual a importância de separar um conjunto de dados em conjuntos de treinamento e de teste?

   Se o conjunto de testes for igual ao conjunto de treinamento, o que acontece com o modelo e um overfitting, ou seja, uma especialização. Nesse caso, o modelo possuirá um desempenho excelente no treino porém será ruim com novas instâncias.

2. Qual a principal limitação do método holdout em relação à partição dos dados e de que forma Amostragem Aleatória busca mitigar esse problema?

   O Holdout possui como principal limitação a possibilidade de uma má partição do conjunto de dados, ou seja, exemplos mais fáceis podem cair no conjunto de teste, o que gera dificuldade para o modelo decidir valores ou rotúlos. Nesse contexto, a Amostragem Aleatória surge como forma de resolver esse problema por meio da média dos erros de todas as hipóteses induzidas.

3. Em um cenário de 5-fold cross-validation (validação cruzada), qual a porcentagem média de exemplos compartilhados entre os diferentes subconjuntos de treinamento?

   Dada a fórmula $(1 - 2/r)$, a porcentagem média de exemplos compartilhados entre os diferentes subconjuntos de treinamento a partir de um 5-fold-cross-validation(r = 5) é de 0,6.

4. Qual a principal diferença entre os métodos de Amostragem Aleatória e Bootstrap?

   A Amostragem Aleatória utiliza diversas instâncias do Holdout sem reposição, já no Bootstrap não há repetição dos dados nos subconjuntos.

5. Em métodos de aprendizado de máquina, qual a diferença entre as definições de "parâmetros" e "hiperparâmetros"? Cite exemplos no contexto de árvores de decisão.

   Os parâmetros são as variáveis que o modelo aprende sozinho a partir dos dados, já os hiperparâmetros são as variáveis que o cientista de dados define manualmente antes do treinamento. Por exemplo, em árvores de decisão, pode-se usar hiperparâmetros como profundidade máxima, níveis de partição e etc.

6. Qual a importância de um conjunto de validação distinto do conjunto de teste final?

   O conjunto de validação mede a performance do de cada modelo para ajustar os hiperparâmetros, ao utilizar esse mesmo conjunto para o teste, tem-se um overfitting.

Questão 02

Uma pessoa cientista de dados treinou um modelo de classificação utilizando ressubstituição para avaliação e obteve acurácia de 100%. Entretanto, ao aplicar o modelo em novos dados, a acurácia caiu para 62%. Explique por que isso ocorreu e proponha uma estratégia de avaliação mais adequada.

Isso ocorreu porque na ressubstituição o modelo é avaliado utilizando o mesmo conjunto de dados usado no treinamento. Dessa forma, o modelo acaba memorizando os dados, ao invés de aprender padrões gerais. Esse fenômeno é conhecido como Overfitting, no qual o modelo se ajusta excessivamente aos dados de treinamento e perde capacidade de generalização.

Desse modo, para uma melhor avaliação, seria necessário dividir o conjunto de dados em um conjunto de teste, outro de validação e outro de treinamento de modo que, ao chegar aos testes, o modelo possa realizar melhores previsões de dados e não "cuspir"resultados decorados.

Questão 03

Considere um modelo avaliado por 10-fold cross-validation. Se o conjunto de dados possui 200 exemplos, quantos exemplos são usados para teste em cada iteração?

Sendo um r-fold-cross-validation com r sendo dez e o conjunto de dados contendo duzentas instâncias, logo o número de exemplos de teste a cada iteração será de vinte, pois um fold é usado para testes e r - um fold será utilizado para treindo e como temos dez folds o valor de cada um será vinte.

Questão 04

Sobre métodos de ensemble, responda:

1. Explique a razão pela qual métodos ensemble tendem a apresentar melhor desempenho do que classificadores individuais.

   Os Ensembles possuem melhor desempenho aos classificadores individuais devido ao fato deles serem combinarem previsões de diversos modelos individuais. Além disso, como os modelos possuem diferentes vieses ou aprendem aspectos diferentes do conjunto de dados, a combinação de suas previsões tende a reduzir variância e aumentar a capacidade de generalização. Dessa forma, os erros de alguns modelos podem ser compensados pelos acertos de outros, resultando em previsões mais robustas e precisas.

2. Quais os principais tipos de métodos ensemble e qual a principal diferença entre eles?

   Dentre os vários tipos, destacam-se os seguintes: Bagging, Boosting e o Stacking. Nesse contexto, a principal diferença entre eles está na forma como são realizadas as combinações de modelos, pois enquanto o Bagging utiliza diversos conjuntos do bootstrap com diferentes indutores para gerar um estimador, o Boosting realiza o treino de forma sequêncial dando prioridade para os erros anteriores e o Stacking gera um meta indutor baseado nos indutores-base.

3. Como o algoritmo Random Forest garante que as árvores criadas sejam diferentes entre si, além do uso de Bootstrap?

   A outra forma de garantir a aleatoriedade das árvores criadas, principalmente pelo fator raiz da árvore, é pela seleção aleatória a partir divisão da árvore em subconjunto aleatórios de atributos.

Questão 05

Em um ensemble baseado em Bagging, dez classificadores retornaram as seguintes previsões:

Classificador	Previsão
C1	Positivo
C2	Positivo
C3	Negativo
C4	Positivo
C5	Negativo
C6	Negativo
C7	Positivo
C8	Negativo
C9	Negativo
C10	Negativo

Figura 1: Tabela de previsão dos classificadores

Qual será a predição final? Justifique sua resposta

O Bagging utiliza vários indutores para gerar um estimador reduzindo a variância. Nesse contexto, como a maioria dos indutores tiveram como previsão o resultado negativo, a predição final também será negativa.

Questão 06

Sobre Naive Bayes, responda

1. Por que o classificador Naive Bayes é chamado de "ingênuo"? Explique a suposição de independência e discuta se ela é realista em problemas do mundo real.

   O classificador Naive Bayes recebe o adjetivo "ingênuo" por causa da simplicidade da suposição que ele faz sobre os dados. Nesse contexto, os eventos no mundo real nem sempre são independentes, todavia tal modelo considera isso para os dados e mesmo assim possui um excelente desempenho,

2. Como o Naive Bayes lida com atributos numéricos (contínuos) em comparação com atributos categóricos?

   Para valores numéricos, é assumido uma distribuição de valores e uma discretização de valores e para os atributos categóricos basta manter um contador para cada valor de atributo por classe.

Questão 07

Uma loja de eletrônicos deseja prever se um cliente comprará um produto com base em sua idade, renda e se é estudante ou não. O histórico de clientes desta loja é dado pela tabela:

Cliente	Idade	Renda	Estudante	Compra
c1	Jovem	Alta	Não	Não
c2	Jovem	Alta	Não	Não
c3	Meia-idade	Alta	Não	Sim
c4	Idoso	Média	Não	Sim
c5	Idoso	Baixa	Sim	Sim
c6	Idoso	Baixa	Sim	Não
c7	Meia-idade	Baixa	Sim	Sim
c8	Jovem	Média	Não	Não
c9	Jovem	Baixa	Sim	Sim
c10	Idoso	Média	Sim	Sim

Figura 2: Tabela de dados

Dado um novo cliente que é jovem, tem renda média e é estudante, qual será a predição realizada por um classificador Naive Bayes? Mostre os cálculos das probabilidades e indique a classe final.

Analisando a imagem abaixo, é possível determinar a probabilidade do cliente comprar sendo não igual a 0,014 e sendo sim igual 0,022. Desse modo, sendo sim uma probabilidade maior, é determinado que o cliente irá comprar o produto.

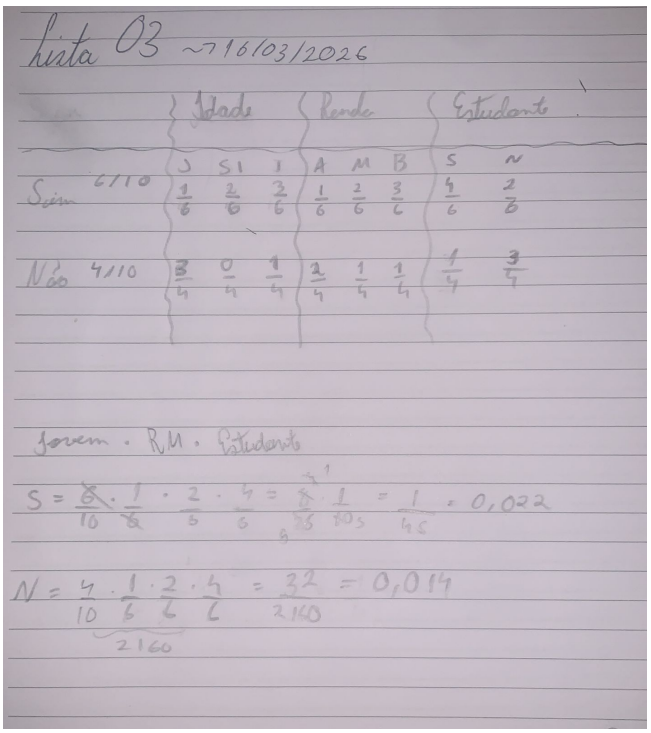

lista 03 ~ 16/03/2026

	Idade			Renda			Estudante	
	J	SI	I	A	M	B	S	N
Sim 6/10	$\frac{1}{6}$	$\frac{2}{6}$	$\frac{3}{6}$	$\frac{1}{6}$	$\frac{2}{6}$	$\frac{3}{6}$	$\frac{4}{6}$	$\frac{2}{6}$
Não 4/10	$\frac{3}{4}$	$\frac{0}{4}$	$\frac{1}{4}$	$\frac{2}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{3}{4}$

Jovem . RM . Estudante

$$S = \frac{6}{10} \cdot \frac{1}{6} \cdot \frac{2}{6} \cdot \frac{4}{6} = \frac{6}{10} \cdot \frac{1}{108} = \frac{1}{45} = 0,022$$

$$N = \frac{4}{10} \cdot \underbrace{\frac{1}{6} \cdot \frac{2}{6}}_{2160} \cdot \frac{4}{6} = \frac{32}{2160} = 0,014$$

Figura 3: Calculos para o exercício 7