



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
INSTITUTO DE CIÊNCIAS EXATAS E DE INFORMÁTICA

Lista de Exercícios 04 - Inteligência Artificial

Vitor Costa Oliveira Rolla

Pontifícia Universidade Católica de Minas Gerais

09 de abril de 2026

Questão 01

Transação	Itens
1	Detergente, Limão, Feijão
2	Álcool, Detergente, Limão
3	Álcool, Detergente, Arroz
4	Limão
5	Limão
6	Álcool, Limão, Arroz, Feijão
7	Álcool, Detergente, Limão

Utilizando o algoritmo Apriori com um **suporte mínimo de 0.3** e **confiança mínima de 0.6**, gere:

1. Os conjuntos de itens (*itemsets*) frequentes, com seus respectivos suportes
2. As regras de associação derivadas, com os respectivos valores de confiança e lift

Resolução

Dados das Transações

A tabela abaixo mostra a ocorrência de cada item nas respectivas transações.

T	Detergente	Limão	Feijão	Álcool	Arroz
1	S	S	S	N	N
2	S	S	N	S	N
3	S	N	N	S	S
4	N	S	N	N	N
5	N	S	N	N	N
6	N	S	S	S	S
7	S	S	N	S	N

Tabela 1: Ocorrência de itens por transação.

Suporte Individual (Itemsets de Tamanho 1)

O suporte de um item corresponde à proporção de transações em que ele aparece, sendo calculado conforme a equação abaixo:

$$\text{Suporte}(X) = \frac{\text{número de transações que contêm } X}{\text{total de transações}}$$

Com base nas 7 transações registradas, o suporte de cada item é apresentado na tabela a seguir.

Item	Transações com S	Contagem	Suporte
Detergente	1, 2, 3, 7	4	$\frac{4}{7} \approx 57,1\%$
Limão	1, 2, 4, 5, 6, 7	6	$\frac{6}{7} \approx 85,7\%$
Feijão	1, 6	2	$\frac{2}{7} \approx 28,6\%$
Álcool	2, 3, 6, 7	4	$\frac{4}{7} \approx 57,1\%$
Arroz	3, 6	2	$\frac{2}{7} \approx 28,6\%$

Tabela 2: Suporte individual de cada item.

Suporte dos Itemsets de Tamanho 2

A tabela abaixo apresenta todos os pares possíveis de itens e seus respectivos suportes, considerando as 7 transações disponíveis.

Par	Transações com S	Contagem	Suporte
{Detergente, Limão}	1, 2, 7	3	$\frac{3}{7} \approx 42,9\%$
{Detergente, Feijão}	1	1	$\frac{1}{7} \approx 14,3\%$
{Detergente, Álcool}	2, 3, 7	3	$\frac{3}{7} \approx 42,9\%$
{Detergente, Arroz}	3	1	$\frac{1}{7} \approx 14,3\%$
{Limão, Feijão}	1, 6	2	$\frac{2}{7} \approx 28,6\%$
{Limão, Álcool}	2, 6, 7	3	$\frac{3}{7} \approx 42,9\%$
{Limão, Arroz}	6	1	$\frac{1}{7} \approx 14,3\%$
{Feijão, Álcool}	6	1	$\frac{1}{7} \approx 14,3\%$
{Feijão, Arroz}	6	1	$\frac{1}{7} \approx 14,3\%$
{Álcool, Arroz}	3, 6	2	$\frac{2}{7} \approx 28,6\%$

Tabela 3: Suporte de todos os itemsets de tamanho 2.

Itemsets Frequentes com Suporte $\geq 0,3$

Aplicando o suporte mínimo de 0,3, os itemsets de tamanho 2 que satisfazem esse critério são apresentados abaixo.

Itemset	Contagem	Suporte
{Detergente, Limão}	3	$\frac{3}{7} \approx 42,9\%$
{Detergente, Álcool}	3	$\frac{3}{7} \approx 42,9\%$
{Limão, Álcool}	3	$\frac{3}{7} \approx 42,9\%$

Tabela 4: Itemsets de tamanho 2 com suporte $\geq 0,3$.

Itemsets de Tamanho 3

A partir dos itemsets frequentes de tamanho 2 — {Detergente, Limão}, {Detergente, Álcool} e {Limão, Álcool} — o único candidato de tamanho 3 gerado pelo algoritmo Apriori é:

$$C_3 = \{\text{Detergente, Limão, Álcool}\}$$

Itemset	Transações com S	Contagem	Suporte
{Detergente, Limão, Álcool}	2, 7	2	$\frac{2}{7} \approx 28,6\%$

Tabela 5: Candidato de tamanho 3 e seu suporte.

Como o suporte de {Detergente, Limão, Álcool} é de aproximadamente 28,6%, valor inferior ao suporte mínimo de 0,3, esse itemset é descartado. Portanto, **não existem itemsets frequentes de tamanho 3**, e o algoritmo Apriori encerra a fase de geração de candidatos.

Fase do Apriori — Geração de Regras de Associação

A confiança de uma regra $A \rightarrow B$ é calculada como:

$$\text{Confiança}(A \rightarrow B) = \frac{\text{Suporte}(A \cup B)}{\text{Suporte}(A)}$$

Assumindo confiança mínima de 0,6, as regras são avaliadas a seguir.

Regras geradas a partir dos Itemsets de Tamanho 2

Regra	Suporte($A \cup B$)	Suporte(A)	Confiança
Detergente $\rightarrow$ Limão	$\frac{3}{7} \approx 0,42$	$\frac{4}{7} \approx 0,57$	$0,42/0,57 \approx 0,73$
Limão $\rightarrow$ Detergente	$\frac{3}{7} \approx 0,42$	$\frac{6}{7} \approx 0,85$	$0,42/0,85 \approx 0,49$
Detergente $\rightarrow$ Álcool	$\frac{3}{7} \approx 0,42$	$\frac{4}{7} \approx 0,57$	$0,42/0,57 \approx 0,73$
Álcool $\rightarrow$ Detergente	$\frac{3}{7} \approx 0,42$	$\frac{4}{7} \approx 0,57$	$0,42/0,57 \approx 0,73$
Limão $\rightarrow$ Álcool	$\frac{3}{7} \approx 0,42$	$\frac{6}{7} \approx 0,87$	$0,42/0,87 \approx 0,46$
Álcool $\rightarrow$ Limão	$\frac{3}{7} \approx 0,42$	$\frac{4}{7} \approx 0,57$	$0,42/0,57 \approx 0,73$

Tabela 6: Confiança das regras geradas a partir dos itemsets de tamanho 2.

Regras geradas a partir do Itemset de Tamanho 3

Embora $\{\text{Detergente}, \text{Limão}, \text{Álcool}\}$ não seja um itemset frequente ($\text{suporte} \approx 0,28 < 0,3$), suas regras associadas são avaliadas abaixo. Com confiança mínima de 0,6, todas as três regras são aprovadas.

Regra	Suporte($A \cup B$)	Suporte(A)	Confiança
Detergente e Álcool $\rightarrow$ Limão	0,28	0,43	$0,28/0,43 \approx 0,65$
Detergente e Limão $\rightarrow$ Álcool	0,28	0,43	$0,28/0,43 \approx 0,65$
Álcool e Limão $\rightarrow$ Detergente	0,28	0,43	$0,28/0,43 \approx 0,65$

Tabela 7: Confiança das regras geradas a partir do itemset de tamanho 3.

Análise do Lift das Regras Aprovadas

O lift mede o quanto a regra supera a expectativa aleatória. Valores acima de 1 indicam associação positiva real; abaixo de 1, a regra não agrega valor preditivo. É calculado como:

$$\text{Lift}(A \rightarrow B) = \frac{\text{Confiança}(A \rightarrow B)}{\text{Suporte}(B)}$$

Regra	Confiança	Suporte(B)	Lift
Detergente $\rightarrow$ Limão	0,73	0,85	0,86
Detergente $\rightarrow$ Álcool	0,73	0,57	1,28
Álcool $\rightarrow$ Detergente	0,73	0,57	1,28
Álcool $\rightarrow$ Limão	0,73	0,85	0,86
Detergente e Álcool $\rightarrow$ Limão	0,65	0,85	0,76
Detergente e Limão $\rightarrow$ Álcool	0,65	0,57	1,14
Álcool e Limão $\rightarrow$ Detergente	0,65	0,57	1,14

Tabela 8: Lift das regras de associação aprovadas.

Interpretação dos Resultados

Detergente $\leftrightarrow$ Álcool (lift 1,28). As regras $\text{Detergente} \rightarrow \text{Álcool}$ e $\text{Álcool} \rightarrow \text{Detergente}$ apresentam o maior lift do conjunto. Isso indica que a co-ocorrência desses dois itens é 28% mais frequente do que seria esperado pelo acaso. A associação faz sentido do ponto de vista prático: ambos são produtos de limpeza e tendem a ser adquiridos na mesma ocasião de compra.

Detergente e Limão $\rightarrow$ Álcool e Álcool e Limão $\rightarrow$ Detergente (lift 1,14). As regras derivadas do itemset de tamanho 3 apresentam lift positivo, reforçando a associação entre produtos de limpeza no dataset. Com a confiança mínima de 0,6, essas regras são aprovadas e agregam valor preditivo real.

Detergente $\rightarrow$ Limão e Álcool $\rightarrow$ Limão (lift 0,86). Apesar da confiança elevada (0,73), o lift abaixo de 1 revela que essas regras não possuem valor preditivo real. O Limão apresenta suporte muito alto ($\approx 0,85$), aparecendo em quase todas as transações. Portanto, saber que um cliente comprou detergente ou álcool não aumenta a probabilidade de ele comprar limão — essa probabilidade já era naturalmente alta.

Detergente e Álcool $\rightarrow$ Limão (lift 0,76). Pela mesma razão, o consequente Limão puxa o lift para baixo de 1, tornando essa regra sem valor preditivo adicional, mesmo sendo aprovada pela confiança.

Questão 02

1. Oversampling vs. Undersampling

Ambas as técnicas lidam com o problema de classes desbalanceadas (ex.: 95% “não fraude”, 5% “fraude”). O **oversampling** aumenta a classe minoritária — seja duplicando instâncias existentes ou gerando instâncias sintéticas (ex.: SMOTE). Não há perda de dados, mas a técnica pode causar overfitting. O **undersampling** reduz a classe majoritária, removendo instâncias aleatoriamente. É mais rápido, porém descarta dados potencialmente úteis.

2. Tratamento de Dados Ausentes sem Remoção de Instâncias

A estratégia mais recomendada é a **imputação**, que substitui o valor ausente por um valor estimado. As formas mais comuns são: imputar pela média ou mediana do atributo (para dados numéricos), pela moda (para categóricos), ou por métodos mais sofisticados como KNN ou regressão, que utilizam os demais atributos da instância para estimar o valor faltante.

3. Verificação de Redundância sem Conhecer a Origem do Atributo

A redundância pode ser detectada calculando a **correlação** entre atributos. Se dois atributos apresentam correlação muito alta (próxima de 1 ou -1), um provavelmente é redundante em relação ao outro. Para atributos numéricos utiliza-se o coeficiente de Pearson; para categóricos, o teste qui-quadrado ou informação mútua.

4. Binarização

A binarização transforma um atributo em 0 ou 1 a partir de um limiar (ex.: idade > 18 vira 1, caso contrário 0). Não é uma boa opção quando o atributo possui variação contínua relevante para o modelo — ao binarizar, descarta-se toda a informação de magnitude.

5. Discretização

A discretização transforma um atributo contínuo em categorias (faixas). As principais estratégias são:

- **Largura igual (equal-width):** divide o intervalo total em faixas de mesmo tamanho. É simples, mas sensível a outliers.
- **Frequência igual (equal-frequency):** cada faixa contém o mesmo número de instâncias. Distribui melhor os dados.
- **Baseada em entropia:** utiliza a variável alvo para encontrar os melhores pontos de corte. É mais sofisticada e supervisionada.
- **Manual/por domínio:** faixas definidas por conhecimento do negócio (ex.: faixas etárias 0–12, 13–17, 18–65, 65+).

6. MinMax vs. Z-score

MinMax (reescala) transforma os valores para um intervalo fixo, geralmente $[0, 1]$, conforme a fórmula:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

É sensível a outliers, pois os valores de mínimo e máximo são influenciados por extremos.

Z-score (padronização) transforma os valores para que possuam média 0 e desvio padrão 1, conforme a fórmula:

$$x' = \frac{x - \mu}{\sigma}$$

É mais robusta a outliers e é a escolha preferida quando o algoritmo assume distribuição normal dos dados (ex.: regressão logística, SVM).

A diferença prática: MinMax preserva a forma da distribuição original e garante um intervalo fixo; Z-score não garante intervalo fixo, mas lida melhor com dados que contêm outliers ou distribuição aproximadamente normal.