



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
INSTITUTO DE CIÊNCIAS EXATAS E DE INFORMÁTICA

Lista de Exercícios 05 - Inteligência Artificial

Vitor Costa Oliveira Rolla

Pontifícia Universidade Católica de Minas Gerais

02 de maio de 2026

Questão 01

Resolução

1. Redes Neurais como “Caixa-Preta”

No aprendizado de máquina, chamamos de "caixa-preta" aqueles modelos onde a relação entre a entrada e a saída de dados é um mistério. Em termos simples, não conseguimos entender com clareza como a rede chegou a uma conclusão específica.

Diferente de outros métodos como as árvores de decisão, que criam regras fáceis de ler, ou o Naive Bayes, que trabalha com probabilidades compreensíveis, a rede neural espalha o que aprendeu por meio de pesos sinápticos em toda a sua estrutura. Isso acaba deixando sua lógica interna escondida e difícil de decifrar.

O grande problema disso é a dificuldade em conferir ou justificar as decisões tomadas pelo modelo. Em áreas sensíveis como diagnósticos médicos, análise de crédito ou decisões jurídicas, a falta de explicações claras impede que erros ou preconceitos sejam detectados. Como alternativa, profissionais utilizam métodos de extração de conhecimento, que buscam traduzir o comportamento complexo da rede em formatos que os seres humanos consigam interpretar melhor.

2. Neurônio Artificial e sua Inspiração Biológica

O neurônio artificial funciona como uma representação matemática do neurônio biológico, que é a unidade básica do nosso sistema nervoso. Para se ter uma ideia da complexidade, o cérebro humano possui cerca de 100 bilhões de neurônios trabalhando ao mesmo tempo. As Redes Neurais Artificiais tentam imitar essa estrutura, focando em como os nós se conectam e como se comportam em conjunto, baseando-se no que entendemos sobre o funcionamento do cérebro.

No nosso corpo, o processo começa nos dendritos, que recebem estímulos de outros neurônios e os levam até o corpo celular. Lá, essas informações são combinadas e processadas para gerar um novo impulso elétrico, que viaja pelo axônio até chegar ao próximo neurônio.

Esse sinal segue sempre o mesmo caminho: começa nos dendritos, passa pelo corpo e termina no axônio. O ponto de encontro entre o final de um axônio e o início do próximo dendrito é a sinapse. Ela atua como uma espécie de válvula, controlando a intensidade da transmissão desses impulsos por toda a rede.

O neurônio artificial replica essa lógica com os seguintes componentes:

- **Entradas (x_i):** correspondem aos estímulos recebidos pelos dendritos. Representam os atributos do problema ou as saídas de neurônios anteriores.
- **Pesos sinápticos (w_i):** representam a força de cada sinapse. Um peso elevado amplifica a contribuição daquela entrada; próximo de zero, a suprime. São os parâmetros ajustados durante o treinamento.
- **Viés (*bias*, b):** valor somado independentemente das entradas, que permite deslocar o limiar de ativação do neurônio.
- **Função de agregação:** calcula a soma ponderada $z = \sum_i w_i x_i + b$, imitando a integração dos sinais no corpo celular.

- **Função de ativação (f):** aplica uma transformação (em geral não linear) ao resultado da agregação, determinando se e com que intensidade o neurônio “dispara”. Substitui o potencial de ação biológico.
- **Saída ($\hat{y} = f(z)$):** o sinal propagado ao próximo neurônio, equivalente ao axônio transmitindo o impulso à sinapse seguinte.

3. Paralelo entre Neurônio Biológico e Artificial

Componente Biológico	Componente Artificial
Dendritos (recebem estímulos)	Entradas (x_i)
Sinapses (controlam o fluxo de informação)	Pesos sinápticos (w_i)
Corpo celular (combina e processa sinais)	Função de agregação ($\sum w_i x_i + b$)
Limiar de disparo	Viés (b) e função de ativação
Potencial de ação	Saída da função de ativação ($f(z)$)
Axônio (conduz o impulso ao próximo nó)	Conexão de saída para o próximo neurônio

Tabela 1: Paralelo entre neurônio biológico e neurônio artificial.

Assim como no neurônio biológico o sinal sempre flui na direção **dendritos** $\rightarrow$ **corpo** $\rightarrow$ **axônio**, no neurônio artificial a informação percorre **entradas** $\rightarrow$ **agregação** $\rightarrow$ **ativação** $\rightarrow$ **saída**.

4. Função de Ativação

A **função de ativação** é aplicada ao resultado da soma ponderada das entradas e determina qual sinal será propagado ao próximo neurônio. Ela é necessária porque introduz **não linearidade** na rede: sem ela, qualquer composição de camadas se reduziria a uma única transformação linear, incapaz de aprender padrões complexos. Além disso, comprime a saída em um intervalo controlado, estabilizando o processo de treinamento.

Os principais tipos de função de ativação são:

- **Degrau (*Step*):** retorna 0 ou 1 conforme z ultrapassa um limiar. Utilizada no Perceptron original de Rosenblatt (1958). Por não ser diferenciável em todo o domínio, inviabiliza o algoritmo de *backpropagation*.
- **Sigmoide:** $\sigma(z) = \frac{1}{1 + e^{-z}}$. Mapeia qualquer valor real para o intervalo $(0, 1)$, sendo útil em saídas de probabilidade. Diferenciável em todo o domínio, porém sofre do problema de *vanishing gradient* em redes profundas.
- **Tangente Hiperbólica (*tanh*):** $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$. Semelhante à sigmoide, mas com saída centrada em zero (intervalo -1 a 1), o que pode acelerar a convergência.
- **ReLU (*Rectified Linear Unit*):** $f(z) = \max(0, z)$. Computacionalmente eficiente e mitiga o *vanishing gradient*. É a escolha padrão em redes profundas modernas.
- **Softmax:** converte um vetor de valores reais em uma distribuição de probabilidade que soma 1. Utilizada na camada de saída de classificações multiclasse.

5. Limitação Matemática do Perceptron e o Inverno da IA

Em 1969, Minsky e Papert demonstraram formalmente, no livro *Perceptrons*, que o modelo de camada única era incapaz de aprender funções **linearmente inseparáveis**. A limitação central é que “*um Perceptron só consegue traçar uma linha reta (ou um hiperplano em dimensões superiores) para separar duas classes*”.

O exemplo canônico é o problema do **XOR**: não existe nenhuma reta capaz de separar os pontos da classe positiva ($A \oplus B = 1$) dos pontos da classe negativa ($A \oplus B = 0$) no plano bidimensional, como evidenciado na tabela a seguir.

A	B	A XOR B
0	0	0 (negativa)
0	1	1 (positiva)
1	0	1 (positiva)
1	1	0 (negativa)

Tabela 2: Tabela-verdade da função XOR — problema linearmente inseparável.

Em contraste, funções como OR e AND são linearmente separáveis — existem infinitas retas que as separam corretamente. A demonstração da insolubilidade do XOR impôs um limite severo à expressividade do Perceptron e contribuiu para a retração de investimentos na área, período que ficou conhecido como o **inverno da IA** (*Dark Age*).

6. Como Camadas Ocultas Resolvem Problemas Mais Complexos

Para superar a limitação do Perceptron de camada única, Hinton, Rumelhart e Williams (1986) propuseram o algoritmo de *backpropagation* aplicado a **redes multicamadas** (*Multi-layer Perceptron* — MLP). A adição de **camadas ocultas** (*hidden layers*) entre a camada de entrada e a de saída aumenta significativamente a capacidade de representação da rede.

Cada camada oculta aprende representações intermediárias progressivamente mais abstratas dos dados de entrada. A composição de transformações não lineares permite que a rede construa **fronteiras de decisão não lineares** de formato arbitrário no espaço de entradas, resolvendo problemas como o XOR, que são insolúveis para um Perceptron simples. Em suma, as RNAs multicamadas passaram a ser capazes de aprender **padrões complexos representados como combinação de pesos e ativações**, o que reativou o interesse na área e deu início a uma nova onda de pesquisa que culminaria no *Deep Learning*.

7. Justificativa Teórica para Funções de Ativação Não Lineares no MLP

A justificativa fundamental é que, sem funções de ativação não lineares, a composição de múltiplas camadas colapsaria em uma única transformação linear. Matematicamente, o produto de matrizes de pesos de camadas consecutivas é equivalente a uma única matriz:

$$f(W_2 \cdot (W_1 \cdot x)) = (W_2 W_1) \cdot x = W' \cdot x$$

Isso tornaria as camadas extras inúteis, pois a rede se comportaria exatamente como um único neurônio linear — incapaz de separar classes linearmente inseparáveis, reproduzindo a mesma limitação do Perceptron apontada por Minsky e Papert.

A não linearidade quebra essa equivalência, permitindo que cada camada adicione capacidade expressiva real à rede. Formalmente, isso é sustentado pelo **Teorema da Aproximação Universal**, que estabelece que uma rede com ao menos uma camada oculta e função de ativação não linear pode aproximar qualquer função contínua com precisão arbitrária, dado um número suficiente de neurônios.

8. As Duas Fases do Backpropagation

O algoritmo de **retropropagação** (*backpropagation*), proposto por Hinton, Rumelhart e Williams (1986), opera em duas fases principais:

- **Propagação direta (*Forward Activity*)**: os dados de entrada percorrem a rede da camada de entrada até a camada de saída. Em cada neurônio, a soma ponderada é calculada e a função de ativação é aplicada. Ao final, a saída prevista é comparada ao rótulo real por meio de uma **função de perda**, gerando um escalar que quantifica o erro do modelo.
- **Retropropagação do erro (*Backward Error*)**: o gradiente da função de perda em relação a cada peso da rede é calculado utilizando a **regra da cadeia** do cálculo diferencial. O erro é propagado da camada de saída em direção à camada de entrada, atribuindo responsabilidade a cada parâmetro. Os pesos são então atualizados na direção oposta ao gradiente por meio do **método do gradiente descendente**, reduzindo progressivamente o erro do modelo.

9. Intuição por Trás do Uso de Derivadas no Gradiente Descendente

O **gradiente descendente** é a estratégia de otimização usada pelo *backpropagation* para atualizar os pesos da rede. A intuição geométrica é a seguinte: imagine a função de perda $\mathcal{L}(w)$ como uma superfície montanhosa. O gradiente $\nabla_w \mathcal{L}$ aponta na direção de maior *subida* nessa superfície. Portanto, movendo os pesos na **direção oposta** ao gradiente, caminhamos na direção de maior descida, aproximando-nos de um mínimo da função de perda.

A **derivada** de $\mathcal{L}$ em relação a um peso w indica a taxa de variação da perda naquele ponto — o quanto o erro aumenta ou diminui se w for levemente alterado. Usar essa informação permite que o algoritmo saiba *em qual direção* e *com que intensidade* ajustar cada peso. A atualização segue a regra:

$$w \leftarrow w - \eta \cdot \frac{\partial \mathcal{L}}{\partial w}$$

onde η é a taxa de aprendizado e $\frac{\partial \mathcal{L}}{\partial w}$ é a derivada parcial da perda em relação ao peso w .

10. Taxa de Aprendizado (*Learning Rate*)

A **taxa de aprendizado** (η) é o hiperparâmetro que define o tamanho do passo dado pelo gradiente descendente a cada atualização de peso. Ela controla diretamente o quanto os parâmetros da rede são ajustados em resposta ao gradiente calculado pelo *backpropagation*.

Os riscos de valores extremos são:

- **η muito alto:** os passos são grandes demais e o algoritmo **oscila** em torno do mínimo ou **diverge**, aumentando o erro em vez de reduzi-lo. A convergência não é garantida e a rede pode nunca encontrar uma solução estável.
- **η muito baixo:** os passos são minúsculos, tornando o treinamento **extremamente lento**. Além disso, o algoritmo pode ficar preso em **mínimos locais** ou pontos de sela, nunca alcançando uma solução satisfatória em tempo razoável — problema diretamente relacionado ao alto **custo computacional** que caracteriza o treinamento de RNAs profundas.

Na prática, utilizam-se técnicas como *learning rate scheduling* (decaimento da taxa ao longo do treinamento) e otimizadores adaptativos (Adam, RMSProp), que ajustam η automaticamente para cada parâmetro, mitigando esses riscos.

Questão 02

Desafios Éticos e Sociais das Redes Neurais em Aplicações Reais

1. Efeito “Caixa-Preta” e Ausência de Explicabilidade. Uma das principais desvantagens das RNAs apontada na literatura e nos materiais da disciplina é o efeito de **caixa-preta**: a relação entre entrada e saída não é clara, dificultando a compreensão de como a rede chegou a um resultado. Esse problema adquire dimensão ética severa quando modelos de redes neurais são utilizados em decisões de alto impacto — como diagnóstico médico, triagem jurídica ou concessão de crédito. A incapacidade de auditar o raciocínio do modelo cria um **vácuo de responsabilidade**: quando o sistema erra, não é possível identificar com clareza a causa nem atribuir responsabilidade ao desenvolvedor, à empresa ou ao usuário. Pesquisadores da área de *Explainable AI* (XAI) têm proposto métodos de extração de conhecimento para mitigar esse problema, mas nenhuma solução elimina completamente a opacidade das redes profundas¹.

2. Viés Algorítmico e Discriminação. Redes neurais aprendem a partir de dados históricos que frequentemente refletem desigualdades e preconceitos sociais preexistentes. Quando utilizados sem tratamento crítico, esses dados fazem com que o modelo reproduza e amplifique discriminações em decisões sensíveis. Um exemplo documentado é o de sistemas de reconhecimento facial — aplicação diretamente ligada ao *Deep Learning* — que apresentaram taxas de erro significativamente maiores para mulheres de pele escura em comparação com homens de pele clara, conforme evidenciado por Buolamwini e Gebru². Isso demonstra que, sem auditorias regulares de equidade e representatividade nos dados de treinamento, as RNAs — que **necessitam de muitos dados para serem treinadas** — podem se tornar instrumentos de discriminação sistêmica, especialmente quando os conjuntos de dados disponíveis são historicamente desequilibrados.

3. Impacto no Mercado de Trabalho e Custo Social da Automação. A aplicação de redes neurais em tarefas como reconhecimento de imagem e vídeo, processamento de linguagem natural, síntese de fala e tradução automática — todas listadas como aplicações de *Deep Neural Networks* — representa uma automação crescente de funções antes exercidas por humanos. Relatórios do *World Economic Forum* projetam que, embora novas funções sejam criadas, a transição será desigual e potencialmente excludente para trabalhadores sem acesso a requalificação profissional³. Além disso, o alto **custo computacional** do treinamento de RNAs profundas concentra o poder de desenvolvimento em grandes corporações e países com infraestrutura avançada, aprofundando desigualdades globais. A necessidade de enormes volumes de dados levanta também preocupações sobre coleta massiva de informações pessoais, frequentemente sem consentimento informado adequado.

¹ARRIETA, A. B. et al. “Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI.” *Information Fusion*, v. 58, p. 82–115, 2020. Disponível em: <https://doi.org/10.1016/j.inffus.2019.12.012>

²BUOLAMWINI, J.; GEBRU, T. “Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification.” *Proceedings of Machine Learning Research*, v. 81, p. 1–15, 2018. Disponível em: <https://proceedings.mlr.press/v81/buolamwini18a.html>

³WORLD ECONOMIC FORUM. *The Future of Jobs Report 2023*. Disponível em: <https://www.weforum.org/publications/the-future-of-jobs-report-2023/>