



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
INSTITUTO DE CIÊNCIAS EXATAS E DE INFORMÁTICA

Lista de Exercícios 07 - CNNs e Agrupamento

Vitor Costa Oliveira Rolla

Pontifícia Universidade Católica de Minas Gerais

15 de junho de 2026

Questão 01

Enunciado

Sobre os principais conceitos de redes neurais convolucionais (CNNs), responda:

1. Cite e explique os principais problemas de se usar uma rede MLP (totalmente conectada) para classificar imagens.
2. Descreva, na ordem correta, as quatro etapas principais da arquitetura de uma CNN e diga qual é a função de cada uma.
3. O que é um kernel (filtro) na etapa de convolução e o que é o feature map (mapa de características)? Por que diferentes kernels produzem resultados diferentes?
4. Explique a diferença entre max pooling e average pooling. Considere a seguinte região 2×2 de um feature map e calcule o resultado para cada tipo de pooling:

$$\begin{bmatrix} 29 & 15 \\ 0 & 100 \end{bmatrix}$$

5. Qual é a função da etapa de flattening dentro da CNN? Por que ela é necessária antes da rede densa? ““

Resolução

1. O uso de uma MLP totalmente conectada para classificar imagens apresenta duas principais limitações. A primeira é a grande quantidade de parâmetros, já que cada pixel é conectado a todos os neurônios da próxima camada, aumentando o custo computacional e o risco de overfitting. A segunda é que a MLP não considera a estrutura espacial da imagem, tratando os pixels de forma independente e dificultando a identificação de padrões visuais como bordas, formas e texturas. Por isso, CNNs costumam apresentar desempenho superior em tarefas de visão computacional.
2. Uma CNN é composta, geralmente, por quatro etapas principais:
 - (a) **Camada Convolutiva**: aplica filtros sobre a imagem para extrair características importantes, como bordas, texturas e formas.
 - (b) **Camada de Pooling**: reduz a dimensionalidade dos dados, diminuindo o custo computacional e destacando as características mais relevantes.
 - (c) **Flattening**: transforma matriz produzida pelo pooling em um vetor unidimensional.
 - (d) **Rede Neural Densa**: recebe a lista de números (que são as características extraídas e resumidas pelas etapas anteriores) e aprende a combiná-las para tomar a decisão final
3. Um kernel é uma pequena matriz de pesos que percorre a imagem durante a convolução, realizando operações matemáticas para detectar padrões específicos, como bordas, linhas, texturas ou formas. O resultado da aplicação de um kernel sobre a imagem é chamado de feature map (mapa de características), que destaca a presença da característica que o filtro procura.

Diferentes kernels produzem resultados diferentes porque cada um possui pesos distintos e, consequentemente, responde a padrões diferentes da imagem. Por exemplo, um filtro pode detectar bordas horizontais, enquanto outro pode detectar bordas verticais ou texturas específicas. Assim, cada kernel extrai um conjunto diferente de características relevantes para a classificação da imagem.
4. Max Pooling seleciona o maior valor da região analisada, preservando a característica mais forte detectada pelo filtro, já o average Pooling calcula a média dos valores da região, produzindo uma representação mais suavizada das características. Para a matriz no enunciado, o max pooling é 100 e o average pooling é 36.
5. A etapa de flattening tem a função de transformar os mapas de características (matrizes geradas pelas camadas convolucionais e de pooling) em um único vetor unidimensional. Ela é necessária porque as camadas densas (fully connected) recebem os dados em formato de vetor, e não em formato matricial. Dessa forma, o flattening converte as características extraídas pela CNN em uma representação adequada para que a rede densa possa realizar a classificação final da imagem.

Questão 02

Enunciado

Em relação às técnicas de agrupamento vistas em sala, responda:

1. O objetivo do agrupamento é organizar os dados em grupos. Descreva, com suas palavras, as duas propriedades que um bom agrupamento deve satisfazer em relação à similaridade dos objetos (dentro e entre grupos).
2. Um mesmo conjunto de objetos pode ser agrupado de maneiras diferentes dependendo do critério escolhido (lembre-se do exemplo dos animais: "com bico / sem bico", "água / terra", etc.). O que isso revela sobre a natureza do problema de agrupamento? Existe uma única resposta correta? Por quê?
3. Cite pelo menos três limitações do algoritmo K-Means e, para cada uma delas, indique uma estratégia ou técnica para contorná-la.
4. O Sum of Squared Error (SSE) é uma métrica de qualidade de agrupamento. Explique o que ele mede e por que não faz sentido escolher o número de grupos k simplesmente buscando o menor SSE possível. Como o Método do Cotovelo (Elbow Method) ajuda nessa decisão?
5. O Silhouette Index de um ponto pode variar entre -1 e 1. Interprete o significado de um valor próximo de 1, próximo de 0 e próximo de -1. Como obtemos um índice único para avaliar o agrupamento como um todo? “

Resolução

1. Um bom agrupamento deve satisfazer duas propriedades principais: maximizar a similaridade entre os objetos do mesmo grupo e minimizar a similaridade entre objetos de grupos diferentes. Em outras palavras, os elementos de um mesmo cluster devem ser muito parecidos entre si, enquanto elementos pertencentes a clusters distintos devem ser o mais diferentes possível.
2. Isso revela que o problema de agrupamento é subjetivo e dependente do critério de similaridade adotado. Um mesmo conjunto de objetos pode ser organizado de diferentes formas válidas, dependendo das características consideradas mais importantes. No exemplo dos animais, é possível agrupá-los por presença de bico, habitat (água ou terra) ou classe biológica (mamíferos, aves e peixes), e todas essas soluções podem ser corretas.
3. Três limitações importantes do K-Means são:
 - (a) Necessidade de definir o valor de k previamente: o algoritmo não sabe quantos grupos existem nos dados. Uma escolha inadequada de k pode gerar agrupamentos de baixa qualidade. Para contornar esse problema, pode-se utilizar o Método do Cotovelo (Elbow Method), analisando a variação do SSE para diferentes valores de k .
 - (b) Sensibilidade aos centroides iniciais: diferentes escolhas aleatórias dos centroides podem levar a resultados distintos. Uma estratégia para reduzir esse problema é utilizar o K-Means++, que seleciona centroides iniciais mais bem distribuídos.
 - (c) Suposição de clusters esféricos: o K-Means não funciona bem quando os grupos possuem formatos irregulares, como anéis ou curvas. Nesse caso, uma alternativa é utilizar algoritmos de agrupamento por densidade, como o DBSCAN, que consegue identificar grupos de formatos arbitrários.
4. O SSE mede a compactação dos clusters, calculando a soma das distâncias quadradas entre os pontos e seus centroides. Quanto menor o SSE, mais compactos são os grupos.

Porém, não se deve escolher k apenas pelo menor SSE, pois ele sempre diminui quando k aumenta, podendo chegar a zero se cada ponto formar seu próprio cluster.

O Método do Cotovelo resolve isso ao analisar o gráfico $SSE \times k$ e escolher o ponto em que a redução do erro passa a ser pouco significativa, equilibrando qualidade e simplicidade do agrupamento.
5. O Silhouette Index mede o quão bem um objeto está associado ao seu próprio cluster em comparação com os clusters vizinhos.
 - (a) Valor próximo de 1: indica que o ponto está muito próximo dos elementos do seu próprio cluster e bem distante dos outros clusters. Isso sugere uma classificação adequada
 - (b) Valor próximo de 0: indica que o ponto está próximo da fronteira entre dois clusters, podendo pertencer razoavelmente a qualquer um deles.
 - (c) Valor próximo de -1: indica que o ponto está mais próximo de elementos de outro cluster do que do seu próprio, sugerindo uma possível atribuição incorreta.

Para avaliar o agrupamento como um todo, calcula-se o Silhouette Index Global, que corresponde à média dos valores de Silhouette de todos os pontos do conjunto de dados. Quanto maior esse valor médio, melhor a qualidade geral do agrupamento. Esse índice pode ser utilizado, por exemplo, para comparar diferentes valores de k no K-Means.

Questão 03

Enunciado

Uma plataforma de streaming coletou as avaliações (notas de 1 a 5) que seis usuários deram a quatro filmes. O objetivo é agrupar os usuários em dois grupos de gosto semelhante, e as avaliações de cada usuário, na ordem (Filme 1, Filme 2, Filme 3, Filme 4), são:

- Usuário 1: (5, 3, 1, 1)
- Usuário 2: (3, 1, 5, 3)
- Usuário 3: (2, 1, 5, 3)
- Usuário 4: (4, 3, 4, 2)
- Usuário 5: (5, 5, 3, 1)
- Usuário 6: (3, 1, 5, 3)

Faça este agrupamento usando o algoritmo K-Means com distância euclidiana.

Mostre o passo a passo das duas primeiras iterações do algoritmo.

Considere como centroides iniciais:

- Centroide 1 (C1): (5, 3, 1, 1)
- Centroide 2 (C2): (3, 1, 5, 3)

Resolução

Centroides iniciais:

$$C_1 = (5, 3, 1, 1) \quad C_2 = (3, 1, 5, 3)$$

Iteração 1

Calculamos a distância euclidiana de cada usuário para os centroides.

Usuário	$d(U_i, C_1)$	$d(U_i, C_2)$	Grupo
U1	0	$\sqrt{28} \approx 5,29$	G_1
U2	$\sqrt{28} \approx 5,29$	0	G_2
U3	$\sqrt{35} \approx 5,92$	1	G_2
U4	$\sqrt{11} \approx 3,32$	3	G_2
U5	$\sqrt{8} \approx 2,83$	$\sqrt{28} \approx 5,29$	G_1
U6	$\sqrt{28} \approx 5,29$	0	G_2

Assim, os grupos obtidos são:

$$G_1 = \{U1, U5\}$$

$$G_2 = \{U2, U3, U4, U6\}$$

Recalcular os centroides

$$C'_1 = \left(\frac{5+5}{2}, \frac{3+5}{2}, \frac{1+3}{2}, \frac{1+1}{2} \right) = (5, 4, 2, 1)$$

$$C'_2 = \left(\frac{3+2+4+3}{4}, \frac{1+1+3+1}{4}, \frac{5+5+4+5}{4}, \frac{3+3+2+3}{4} \right) = (3, 1.5, 4.75, 2.75)$$

Iteração 2

Utilizando os novos centroides:

$$C_1 = (5, 4, 2, 1) \quad C_2 = (3, 1.5, 4.75, 2.75)$$

Usuário	$d(U_i, C_1)$	$d(U_i, C_2)$	Grupo
U1	1,41	4,87	G_1
U2	5,00	0,83	G_2
U3	5,57	1,09	G_2
U4	2,45	1,89	G_2
U5	1,41	4,77	G_1
U6	5,00	0,83	G_2

Nenhum usuário mudou de grupo. Portanto, o algoritmo convergiu.

Resultado Final

$$G_1 = \{U1, U5\}$$

$$G_2 = \{U2, U3, U4, U6\}$$