Métodos de Amostragem e Avaliação de Algoritmos

Gabriel P. Oliveira

Inteligência Artificial
2026/1

O que aprendemos até agora?

- Aprendizado preditivo (classificação/regressão)
- Árvores de Decisão
  - Treinamento a partir de conjunto de dados
  - Principais algoritmos
- Métricas de avaliação (acurácia, precisão, *recall*, etc.)

O que aprendemos até agora?

- Aprendizado preditivo (classificação/regressão)
- Árvores de Decisão
  - Treinamento a partir de conjunto de dados
  - Principais algoritmos
- Métricas de **avaliação** (acurácia, precisão, *recall*, etc.)

Como essa avaliação funciona na prática?

Como treinar e avaliar se tenho só um conjunto com n elementos?

O que aprendemos até agora?

- Aprendizado preditivo (classificação/regressão)
- Árvores de Decisão
  - Treinamento a partir de conjunto de dados
  - Principais algoritmos
- Métricas de **avaliação** (acurácia, precisão, *recall*, etc.)

Como essa avaliação funciona na prática?

Como treinar e avaliar se tenho só um conjunto com n elementos?

Como comparar a performance de dois classificadores?

Como comparar algoritmos?

AM é uma ferramenta poderosa, mas **não existe um único algoritmo que apresente o melhor desempenho** para todos os problemas

Como comparar algoritmos?

AM é uma ferramenta poderosa, mas **não existe um único algoritmo que apresente o melhor desempenho** para todos os problemas

Precisamos:

- Conhecer prós/contras de cada algoritmo
- Saber qual contexto cada um é mais útil
- Ter uma metodologia que nos permita comparar dois (ou mais) algoritmos

Como comparar algoritmos?

AM é uma ferramenta poderosa, mas **não existe um único algoritmo que apresente o melhor desempenho** para todos os problemas

Precisamos:

- Conhecer prós/contras de cada algoritmo
- Saber qual contexto cada um é mais útil
- Ter uma metodologia que nos permita comparar dois (ou mais) algoritmos → **Amostragem**

Métodos de Amostragem

O mundo real apresenta uma distribuição de exemplos **D** em um dado domínio, a qual é desconhecida

Ao extrair exemplos do mundo real, forma-se assim um conjunto de exemplos com distribuição **D'** (assumimos que representa o mundo real)

Para estimar a precisão/erro do indutor, treina-se o modelo com amostras de D' e avalia-se seu desempenho em exemplos da mesma distribuição

Normalmente são <u>diferentes dos usados no treino</u>

Métodos de Amostragem

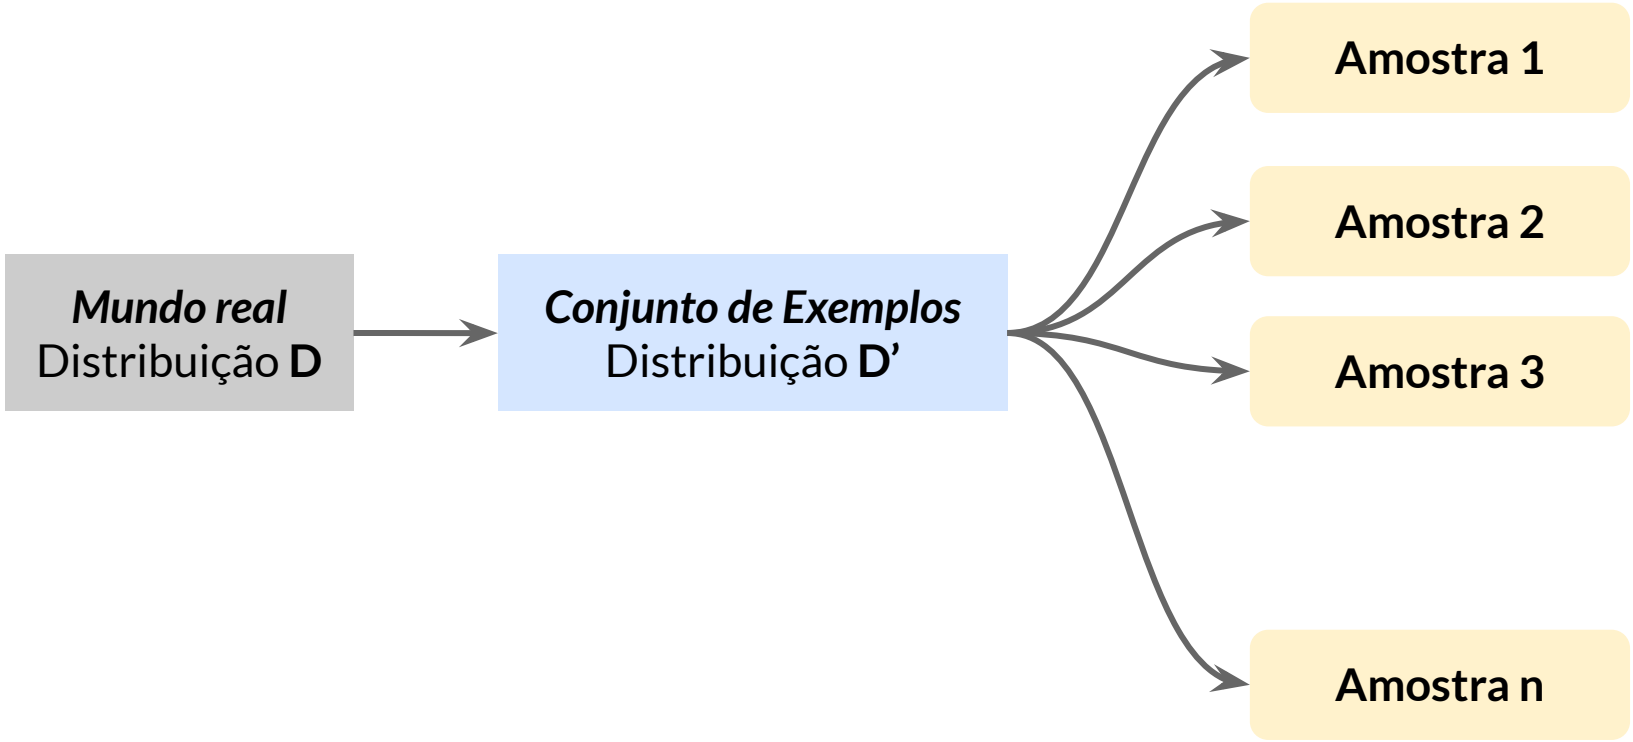

Métodos de Amostragem

Dados um conjunto de exemplos de tamanho finito e um indutor, é importante estimar o **desempenho futuro** do classificador induzido utilizando o conjunto de exemplos

Como?

Ressubstituição

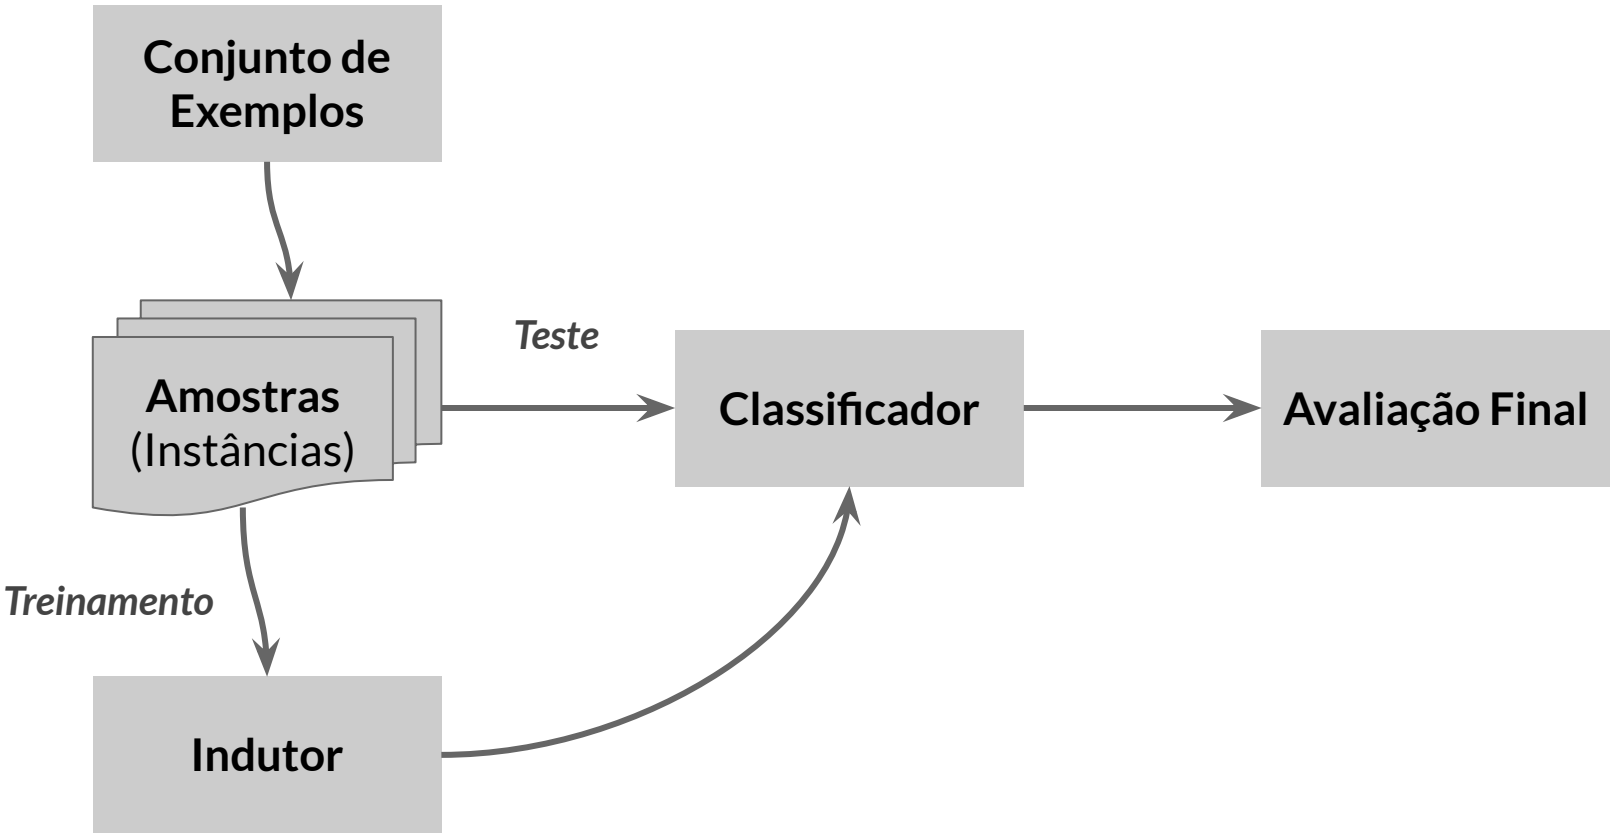

Ressubstituição

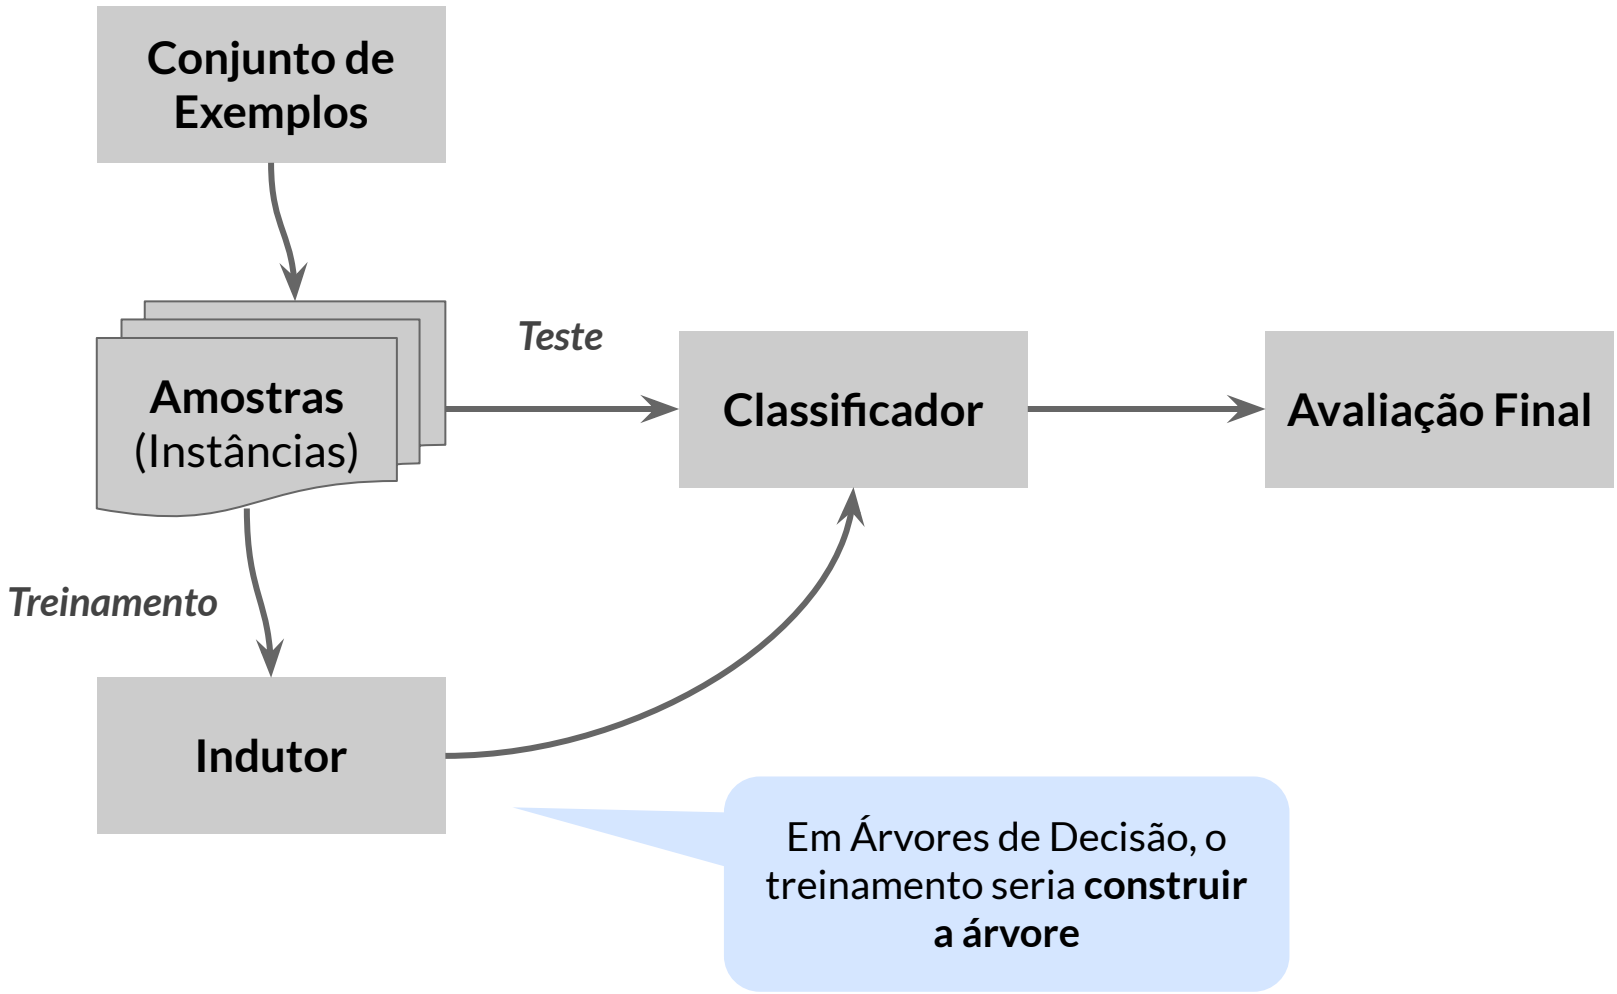

Ressubstituição

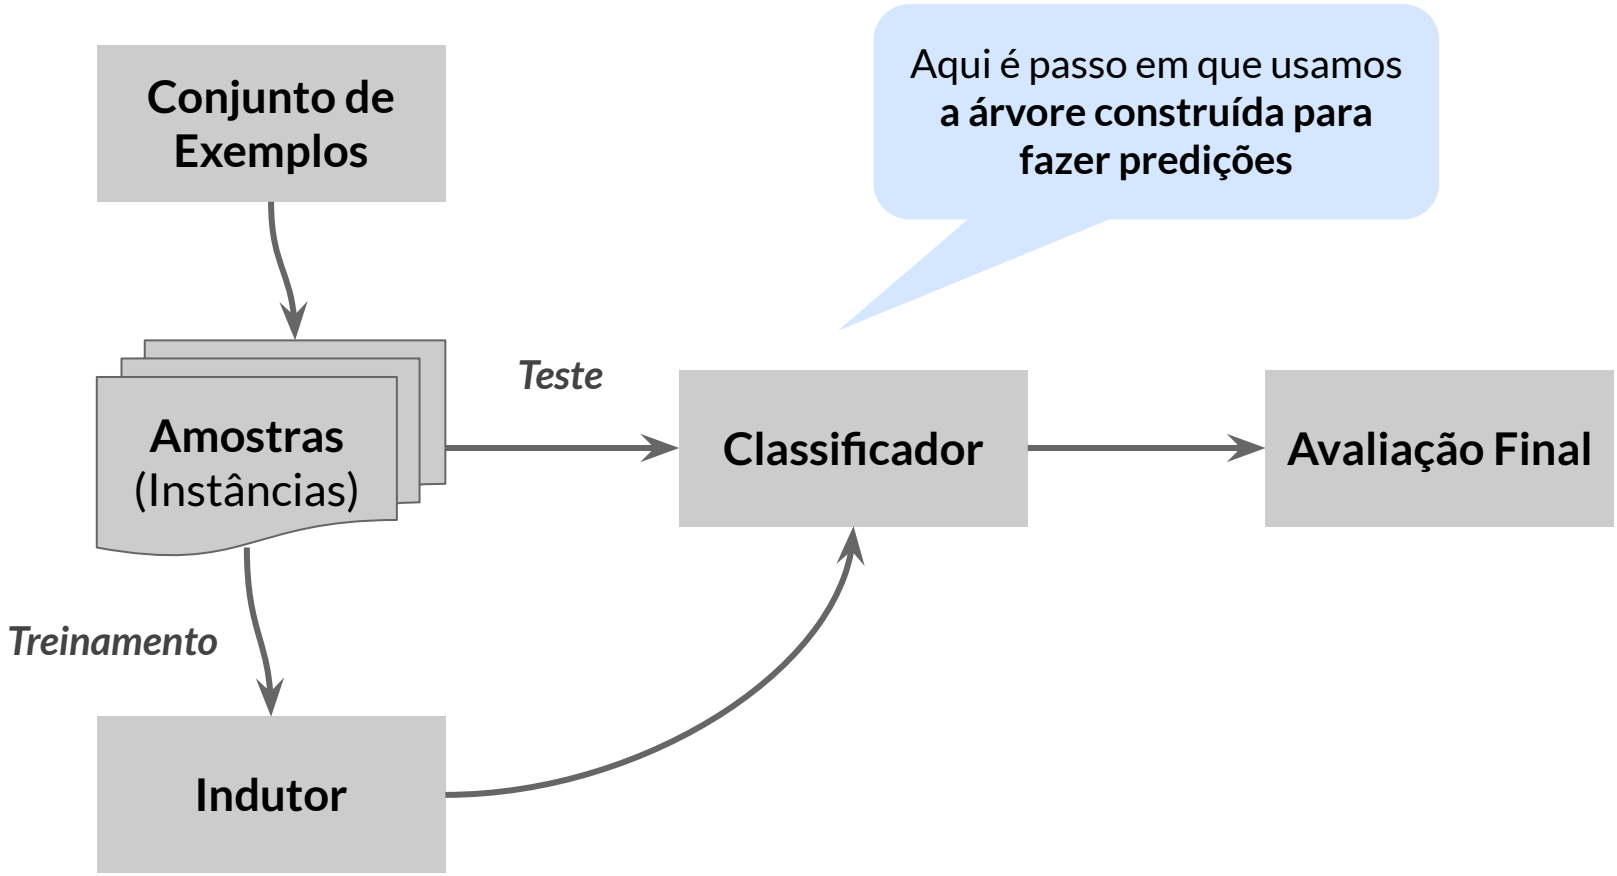

Ressubstituição

Construir o classificador e testar seu desempenho **no mesmo conjunto de exemplos**

Conjunto de **Treinamento** = Conjunto de **Teste**

O erro/acerto obtido aqui é denominado **aparente**

- Estimativa muito otimista da previsão
- Em árvores de decisão sem poda, a precisão pode chegar a 100%

Ressubstituição – Limitações

Possui um *bias* (viés) otimista na previsão, mas o bom desempenho pode **não ser observado em conjuntos independentes (desconhecidos) de teste**

Ressubstituição – Limitações

Possui um *bias* (viés) otimista na previsão, mas o bom desempenho pode **não ser observado em conjuntos independentes (desconhecidos) de teste**

Como resolver o bias?

<u>Não deve haver exemplos em comum</u> entre o conjunto de treinamento (ou aprendizado) e o conjunto de teste

1.

Holdout

O que é e como fazer?

Holdout

Divide-se o conjunto de dados em uma proporção de **p** para treino e **(1-p)** para teste

Holdout

Divide-se o conjunto de dados em uma proporção de **p** para treino e **(1-p)** para teste

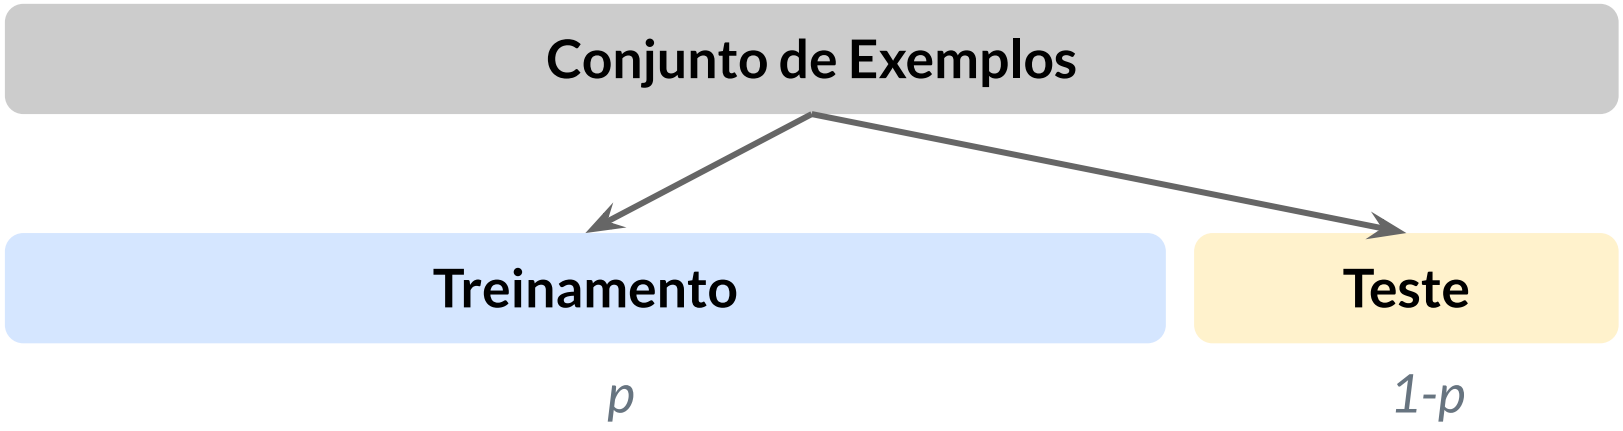

Holdout

Divide-se o conjunto de dados em uma proporção de **p** para treino e **(1-p)** para teste

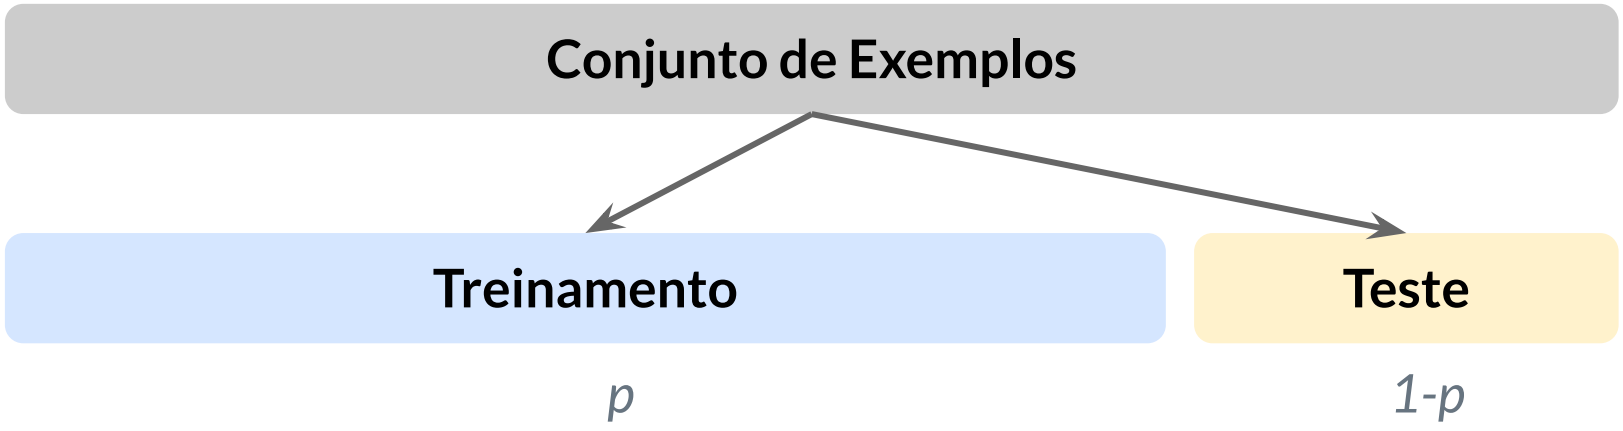

Valores comuns incluem **p=⅔** e **1-p=⅓**

Geralmente, p>½ (conj. treino precisa ser maior)

Holdout – Limitações

Se comparar com a ressubstituição (treinar com todos os exemplos), a taxa de acerto **pode ser menor**

- **Michie et al. (1994):** se o conjunto de dados é grande o suficiente, isso não é um problema

Lembre-se: em AM, queremos sempre que o nosso modelo funcione para exemplos inéditos!

Holdout – Limitações

Depende muito da **forma que o conjunto de dados é particionado**

- Pode acontecer de exemplos “mais fáceis” caírem no subconjunto de teste

Como solucionar?

2.

Amostragem Aleatória

O que é e como fazer?

Amostragem Aleatória

Calcular a **média de vários resultados de holdout** através da construção de várias partições

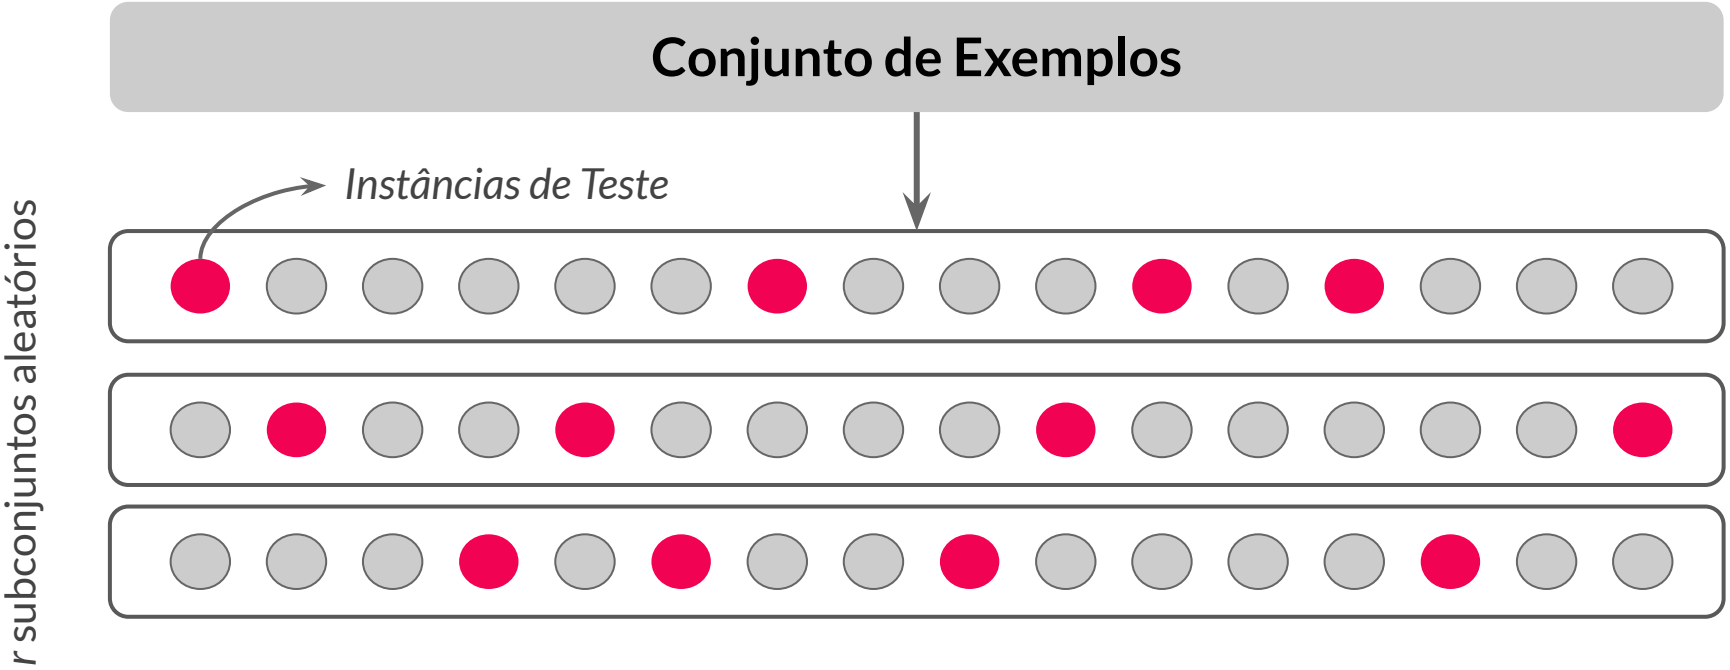

Amostragem Aleatória

O erro final é calculado como sendo a **média dos erros de todas as *r* hipóteses induzidas** e calculados em conjuntos de teste independentes e extraídos aleatoriamente

Amostragem aleatória **pode produzir melhores estimativas de erro** que o estimador holdout

É possivel melhorar?

3.
Validação Cruzada

O que é e como fazer?

Validação Cruzada

O conjunto de exemplos é dividido em ***r* subconjuntos (*folds*) de tamanho aproximadamente igual** (*r-fold cross validation)*

Os objetos de **r-1** partições são usados no treinamento, enquanto a partição restante é usada no teste

Este processo é repetido *r* vezes, utilizando em cada ciclo uma **partição diferente para teste**

Validação Cruzada

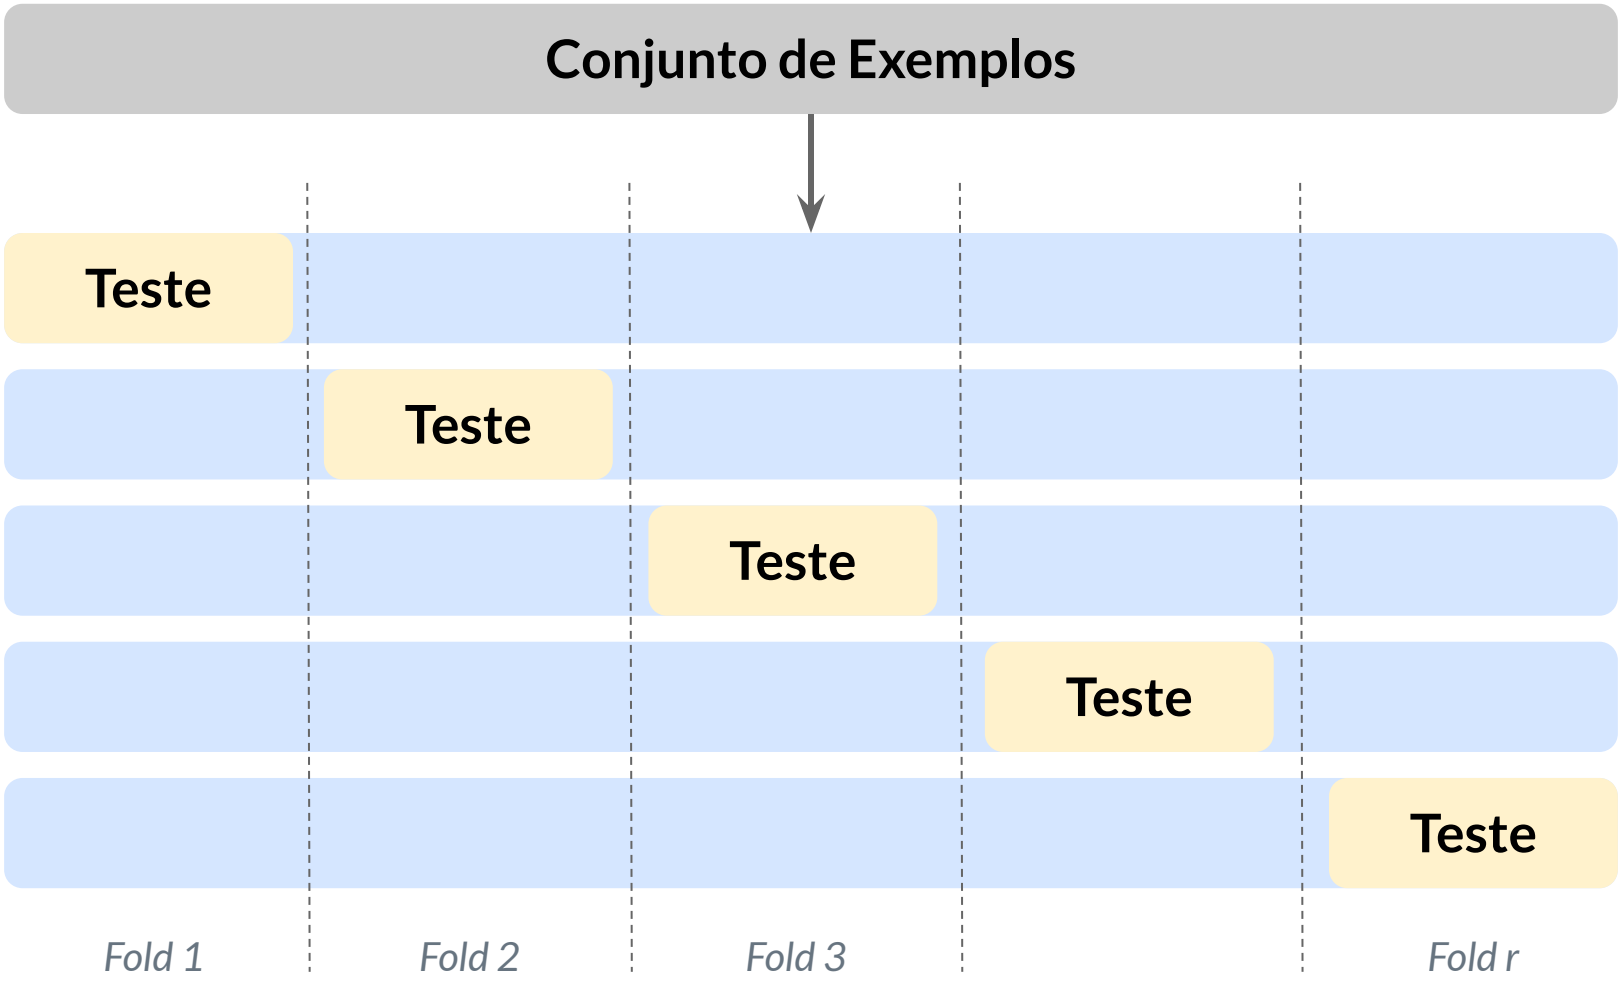

Validação Cruzada

Este procedimento de rotação reduz o viés inerente ao método de *holdout*

Principal crítica → parte dos dados é compartilhada entre os subconjuntos de treinamento

- Por exemplo, usando *10-fold cross validation*, 80% dos objetos nos subconjuntos de treinamento são compartilhados

Validação Cruzada

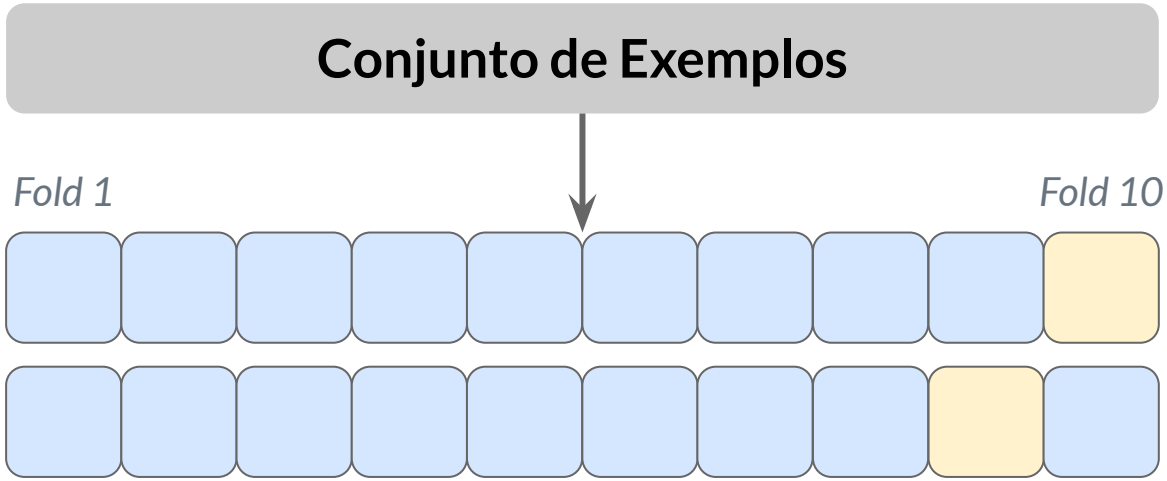

Validação Cruzada

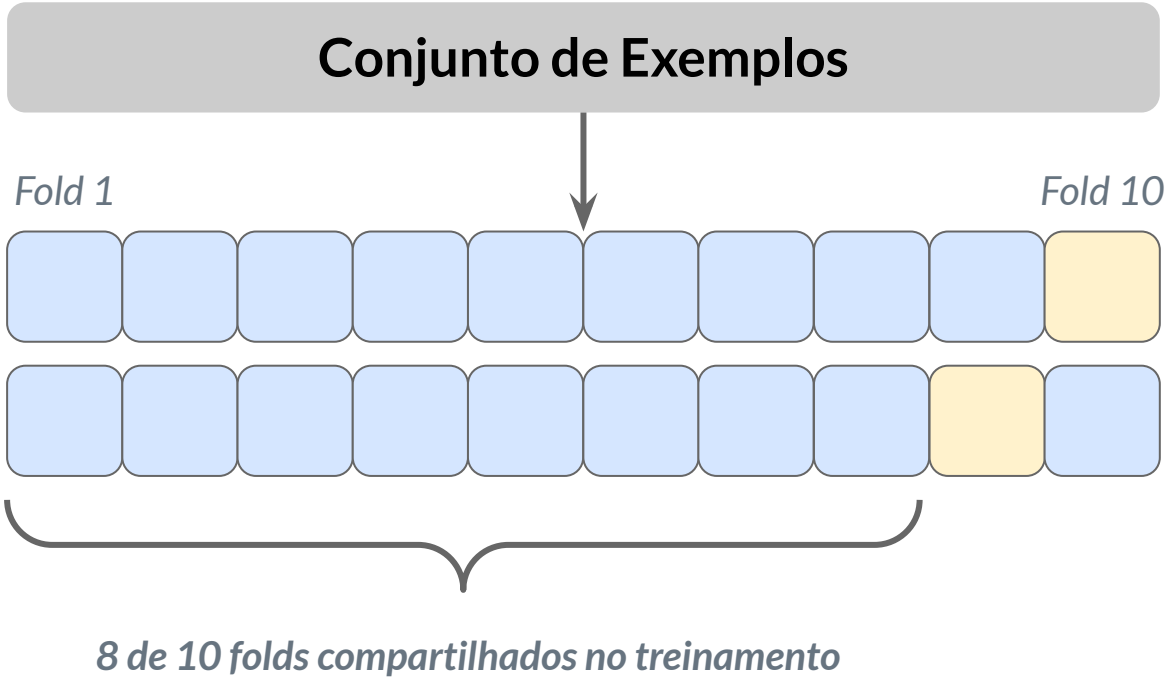

Validação Cruzada

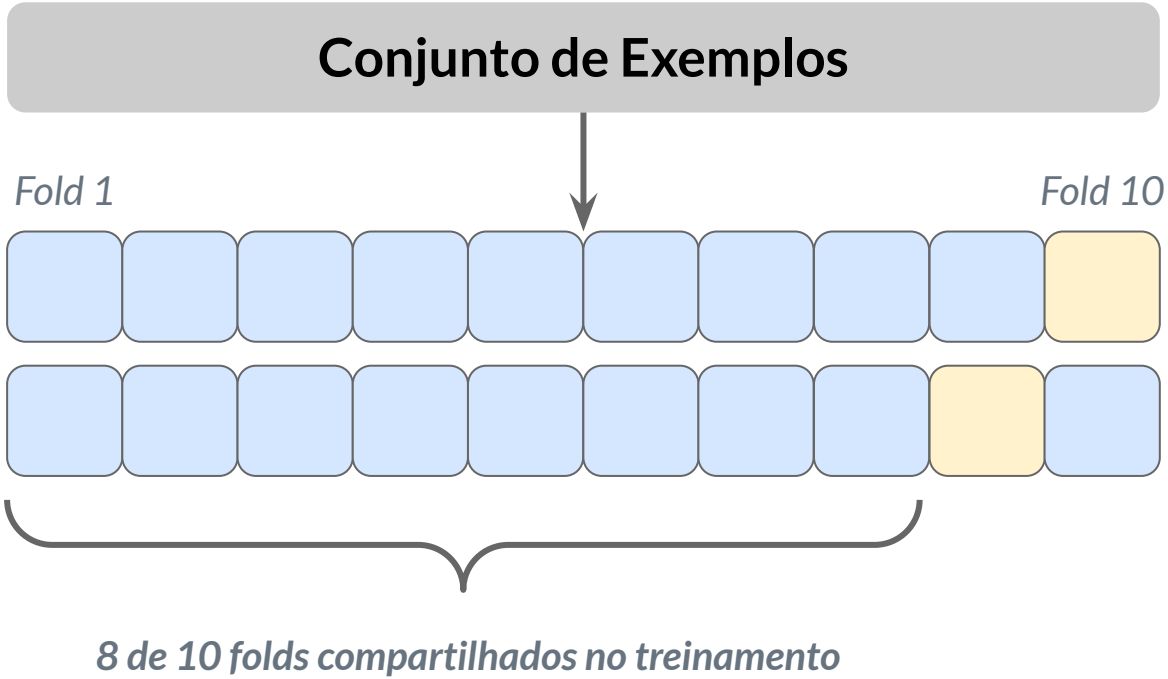

A proporção de elementos compartilhados em *r-fold cross validation* é generalizável para **(1 - 2/r)**

Validação Cruzada Estratificada

Variação que **mantém a proporção de exemplos de cada classe** existente no conjunto total

Por exemplo, se o conjunto original tem 20% de elementos na classe A e 80% na classe B, cada partição também procura manter essa proporção

Leave-one-out

Caso extremo de *r-fold cross validation* em que ***r=n*** (n é o número de exemplos no conjunto)

A cada ciclo, apenas **um exemplo é utilizado no teste**, e os outros n-1 no treinamento

É **computacionalmente caro**, mas produz uma estimativa mais fiel da predição → usada em conjuntos pequenos

4.

Bootstrap

O que é e como fazer?

Bootstrap

No método bootstrap, são gerados *r* subconjuntos de treinamento a partir do conjunto original

Os exemplos são amostrados aleatoriamente desse conjunto **com reposição**

- Ou seja, um exemplo pode estar presente em um mesmo subconjunto de treinamento **mais de uma vez**
- É diferente da amostragem aleatória, que geralmente é feita sem reposição

Bootstrap e0

Existem vários métodos *bootstrap*, mas o mais comum é chamado de **e0**

Neste método, cada conjunto de treinamento tem **n exemplos amostrados com reposição** do conjunto original (**n** também é o tamanho do conjunto original)

O que isso significa?

Bootstrap e0

Como amostramos com reposição, nem todos os exemplos E_i podem ir para o conjunto de treinamento, e outros exemplos podem aparecer mais de uma vez

Os exemplos que não aparecerem no treinamento (não foram amostrados) se tornam o **conjunto de teste**

Bootstrap e0

Conjunto de Exemplos Original (n=5)

E_1	E_2	E_3	E_4	E_5

Conjuntos de Treinamento					*Conjuntos de Teste*			
E_3	E_2	E_3	E_1	E_1	E_4	E_5		
E_5	E_1	E_2	E_4	E_1	E_3			
E_1	E_5	E_3	E_1	E_3	E_2	E_4		
...					...			
E_1	E_1	E_1	E_1	E_1	E_2	E_3	E_4	E_5

Bootstrap e0

Cada exemplo tem uma probabilidade **$1 - (1- 1/n)^n$** de ser selecionado pelo menos uma vez

Se **n** é muito grande, essa probabilidade tende a **$(1 - 1/e) = 0{,}632$**, ou seja:

- 63,2% dos exemplos aparecem em uma amostra bootstrap
- 36,8% dos exemplos não aparecem (conj. de teste)

5.
Ajuste de Parâmetros

Como fazer?

Ajuste de Parâmetros

Em alguns casos, é importante realizar um ajuste de **hiperparâmetros** de um indutor

Ou seja, queremos saber quais seriam os melhores valores para estes hiperparâmetros de forma a maximizar a performance do indutor

Parâmetros x Hiperparâmetros

Parâmetros: são aprendidos automaticamente pelo modelo a partir dos dados durante o treinamento

Ex.: nós de decisão, os atributos de divisão, etc.

Hiperparâmetros: são definidos manualmente pelo cientista de dados antes do início do treinamento

Ex.: profundidade máxima, critério de divisão, etc.

Ajuste de Parâmetros

Em alguns casos, é importante realizar um ajuste de hiperparâmetros de um indutor

Ou seja, queremos saber quais seriam os **melhores valores** para estes hiperparâmetros

Nesses casos, é necessário reservar **uma parte dos exemplos para ajustar os parâmetros (conjunto de validação)** e outra parte para teste

Ajuste de Parâmetros – *Holdout*

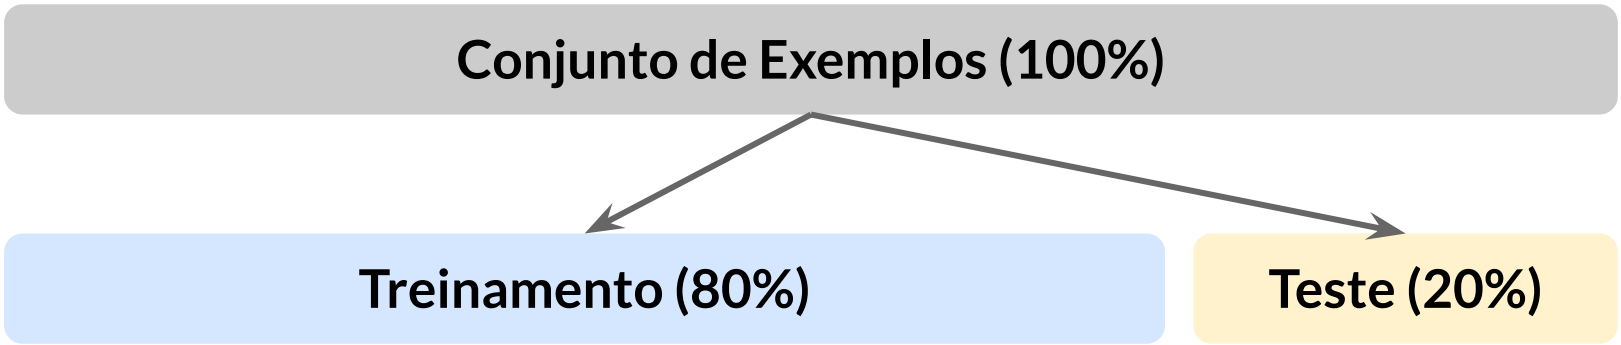

Ajuste de Parâmetros – *Holdout*

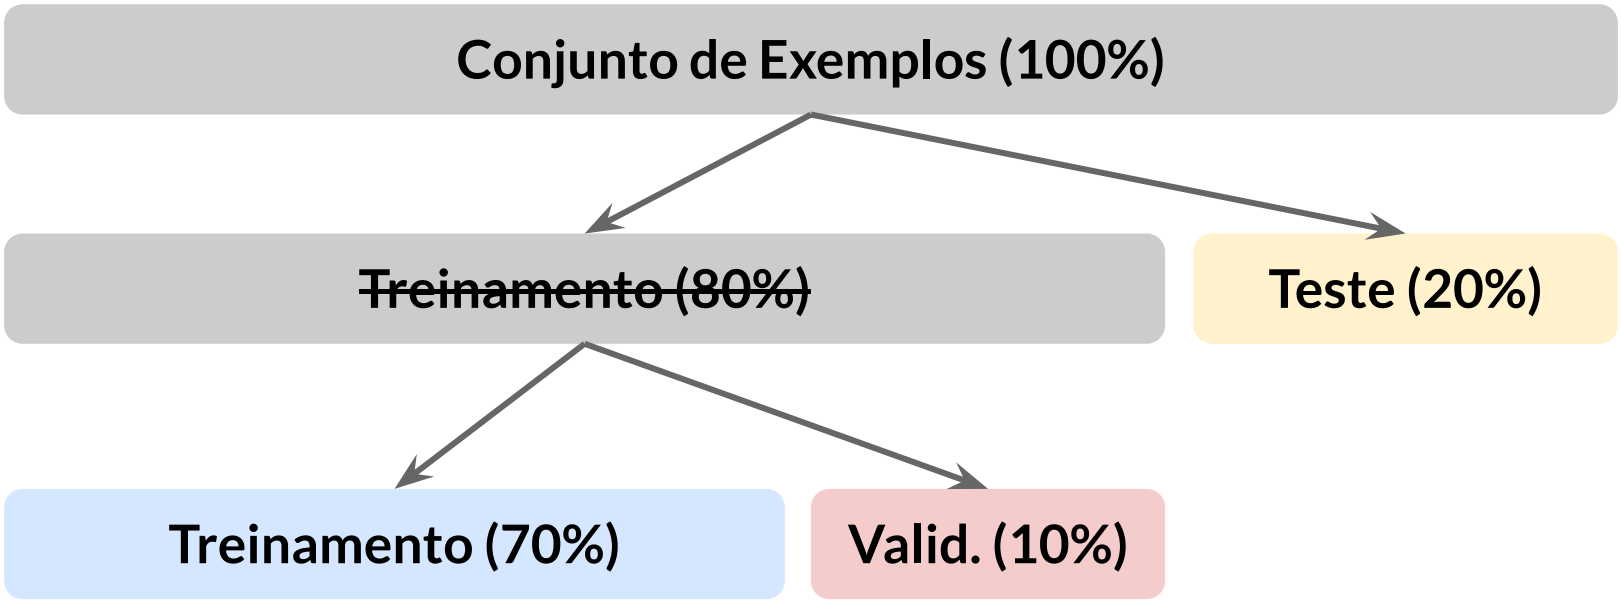

Ajuste utilizando ***holdout***

Ajuste de Parâmetros – *Holdout*

Exemplo: Estou rodando um algoritmo de árvore de decisão e preciso decidir qual o melhor valor da profundidade máxima da árvore

- ***max_depth = [2, 4, 6, 8]***

Ajuste de Parâmetros – *Holdout*

Exemplo: Estou rodando um algoritmo de árvore de decisão e preciso decidir qual o melhor valor da profundidade máxima da árvore

- ***max_depth = [2, 4, 6, 8]***
- Preciso então comparar **quatro modelos de AD** (cada um treinado com um valor diferente de *max_depth*)

Ajuste de Parâmetros – *Holdout*

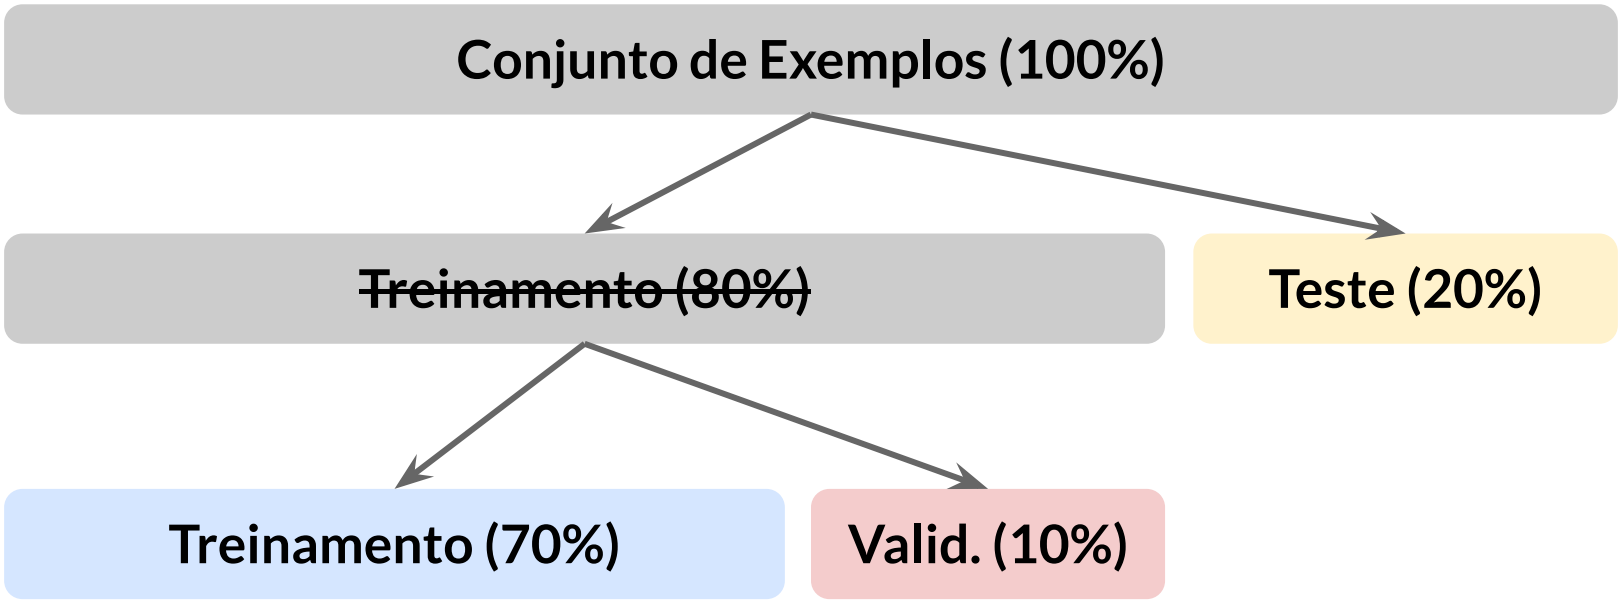

Os modelos são treinados **apenas no conjunto de treinamento**

Ajuste utilizando ***holdout***

Ajuste de Parâmetros – *Holdout*

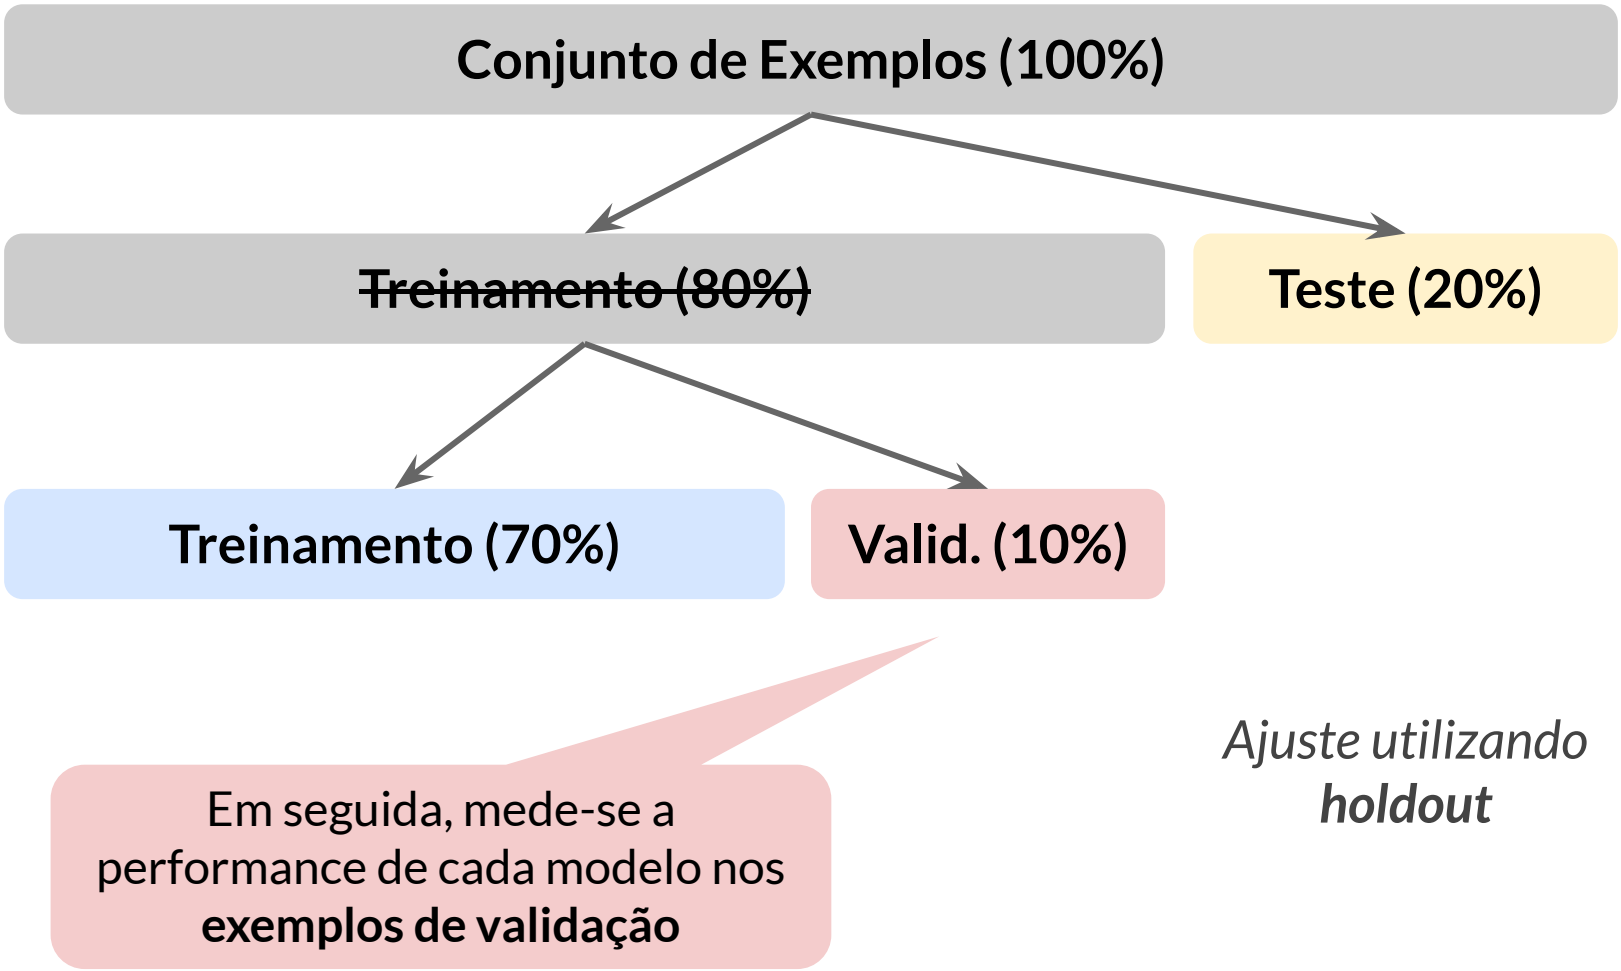

Ajuste utilizando ***holdout***

Ajuste de Parâmetros – *Holdout*

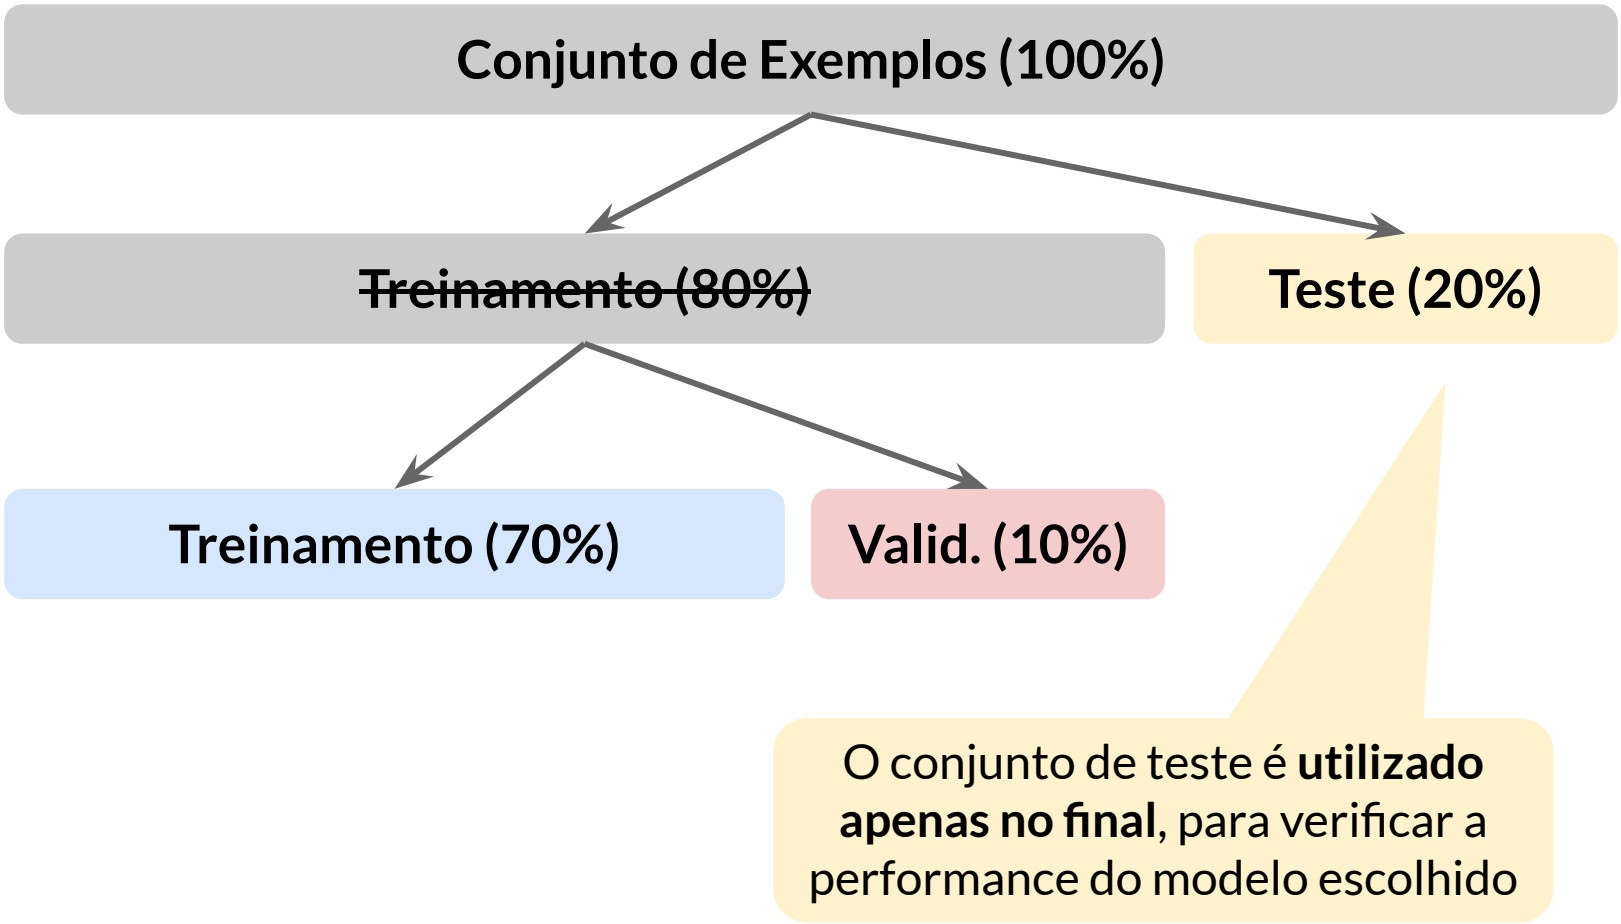

Ajuste de Parâmetros – *Cross-val.*

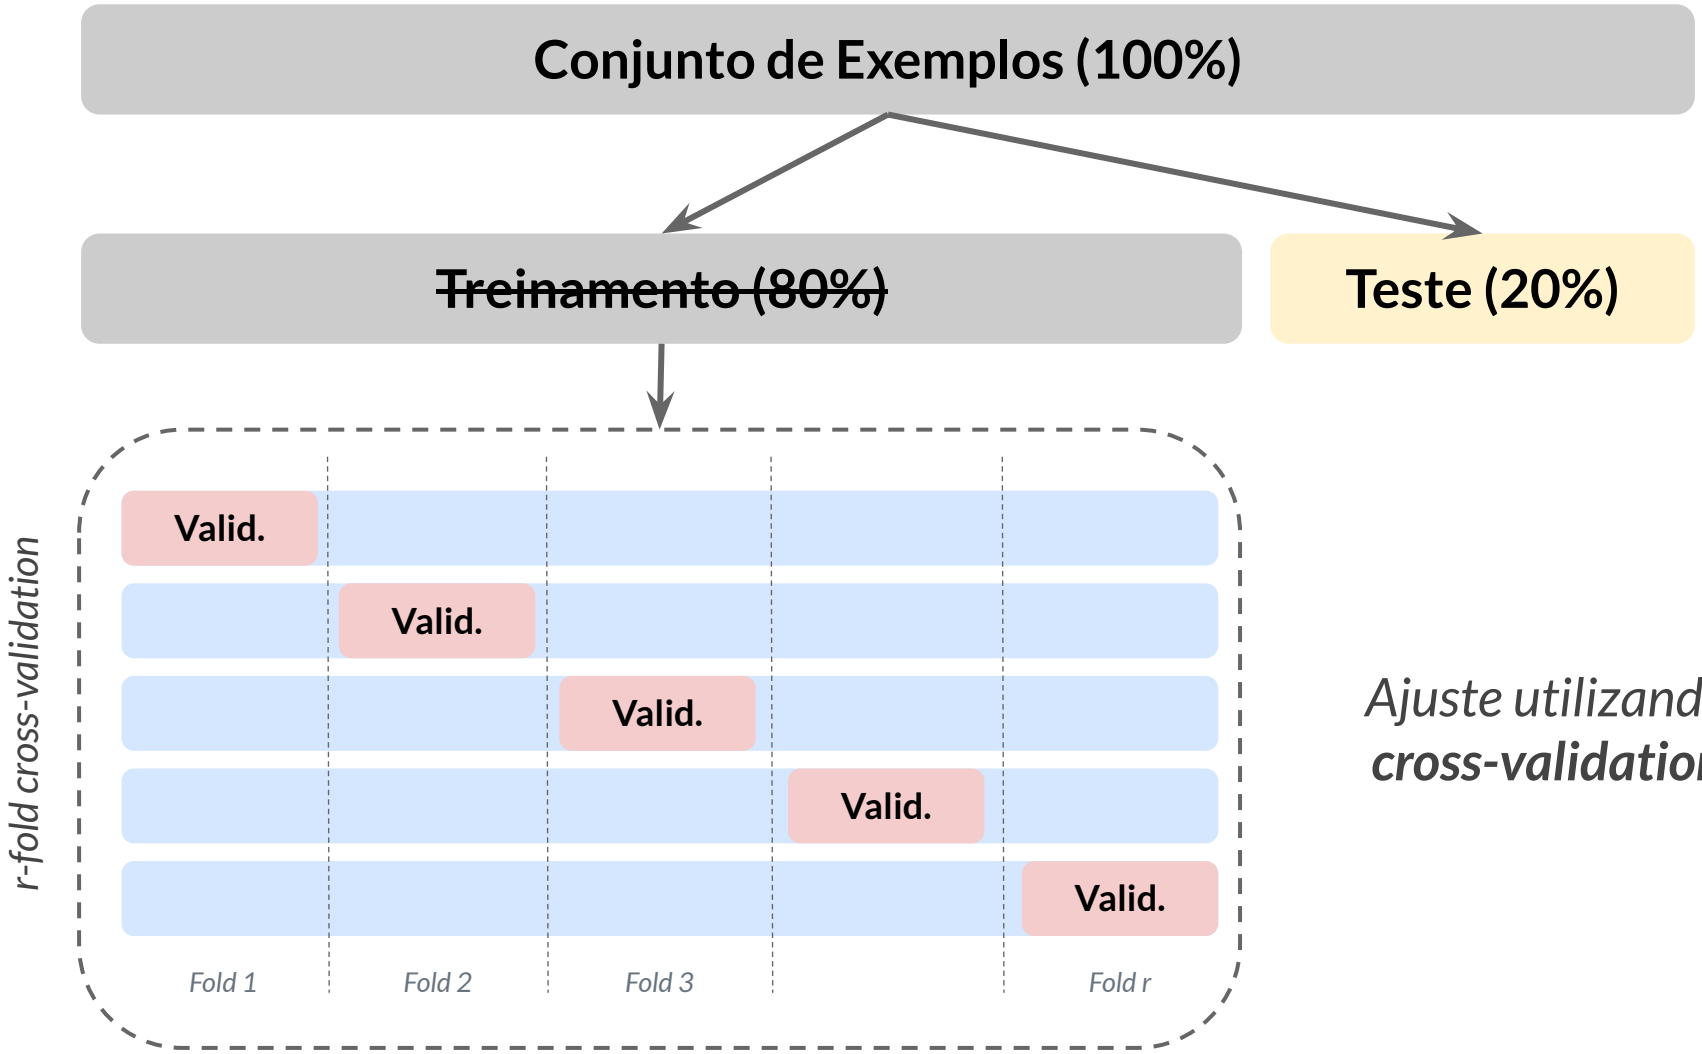

Ajuste utilizando ***cross-validation***

Em resumo...

	Holdout	Aleatória	Leave-one-out	r-fold cv	r-fold strat cv	bootstrap
Treinamento	pn	t	n - 1	n(r-1)/r	n(r-1)/r	n
Teste	(1-p)n	n - t	1	n/r	n/r	n-t
Iterações	1	L << n	n	r	r	~200
Reposição	não	não	não	não	não	sim
Prevalência de Classe	não	não	não	não	sim	sim/não

- **n** representa o número de exemplos;
- **r** o número de folds (partições);
- **p** um número tal que 0 < p < 1;
- **t** um número tal que 0 < t < n e
- **L** o número de hipóteses induzidas

Referências

FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina.** Rio de Janeiro, RJ: LTC, 2011. (***Capítulo 9***)

Material do Prof. José Augusto Baranauskas (USP)