Métodos Probabilísticos
Naive Bayes

Gabriel P. Oliveira

Inteligência Artificial
2026/1

O que aprendemos até agora?

- Aprendizado preditivo (classificação/regressão)
- Árvores de Decisão
  - Treinamento a partir de conjunto de dados
  - Principais algoritmos
- Métricas de avaliação (acurácia, precisão, *recall*, etc.)
- Métodos de amostragem para avaliação
- Métodos *ensemble*
  - Combinar vários classificadores em um só

O que aprendemos até agora?

Já vimos que *Ensembles* (como Random Forest) funcionam como **um grande comitê** onde vários modelos são combinados para chegar a uma decisão

O que aprendemos até agora?

Já vimos que *Ensembles* (como Random Forest) funcionam como **um grande comitê** onde vários modelos são combinados para chegar a uma decisão

E se eu dissesse que podemos tomar decisões excelentes usando apenas um "especialista" que é extremamente simples, rápido e... um pouco "ingênuo"?

Antes de começar...

Como um computador toma decisões quando há incerteza?

Diagnóstico médico

Detecção de spam

Recomendação de músicas

Antes de começar...

Como um computador toma decisões quando há incerteza?

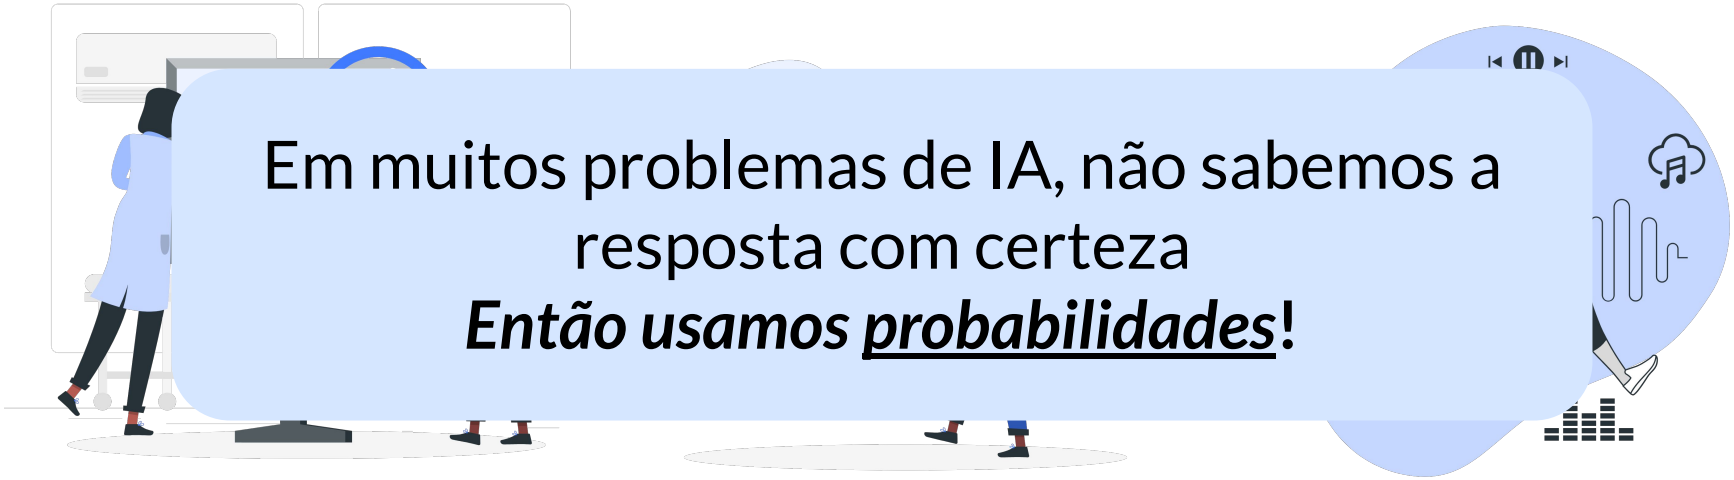

Em muitos problemas de IA, não sabemos a resposta com certeza

Então usamos <u>probabilidades</u>!

Diagnóstico médico

Detecção de spam

Recomendação de músicas

1.
Probabilidade

O que isso tem a ver com Aprendizado de Máquina?

Probabilidade

Qual a probabilidade de hoje chover?

$$P(chuva) = \frac{\text{dias chuvosos no ano}}{\text{total de dias no ano}}$$

Probabilidade

Qual a probabilidade de hoje chover sabendo que:

- Tempo nublado
- Umidade alta
- Temperatura baixa

Probabilidade

Qual a probabilidade de hoje chover sabendo que:

- Tempo nublado
- Umidade alta
- Temperatura baixa

Evidências mudam probabilidades!

Probabilidade condicional

Qual a probabilidade de A sabendo que B ocorreu?

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Probabilidade condicional

<u>Exemplo:</u> Em uma universidade, 60% dos estudantes gostam de IA e 40% gostam de IA e matemática. Qual a probabilidade de alguém gostar de matemática dado que essa pessoa gosta de IA?

Probabilidade condicional

<u>Exemplo:</u> Em uma universidade, 60% dos estudantes gostam de IA e 40% gostam de IA e matemática. Qual a probabilidade de alguém gostar de matemática dado que essa pessoa gosta de IA?

- Evento A: Gostar de matemática
- Evento B: Gostar de IA

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Probabilidade condicional

<u>Exemplo:</u> Em uma universidade, 60% dos estudantes gostam de IA e 40% gostam de IA e matemática. Qual a probabilidade de alguém gostar de matemática dado que essa pessoa gosta de IA?

- Evento A: Gostar de matemática
- Evento B: Gostar de IA

Gostar de matemática e de IA

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0.4}{0.6}$$

Gostar de IA

Probabilidade condicional

<u>Exemplo:</u> Em uma universidade, 60% dos estudantes gostam de IA e 40% gostam de IA e matemática. Qual a probabilidade de alguém gostar de matemática dado que essa pessoa gosta de IA?

- Evento A: Gostar de matemática
- Evento B: Gostar de IA

Gostar de matemática e de IA

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0.4}{0.6} = 0.667$$

Gostar de IA

Probabilidade condicional

Será que conseguimos calcular o problema inverso?

- Por exemplo, é simples calcular que 95% dos doentes têm febre
- Mas se alguém tem febre, qual a chance de estar doente?

Teorema de Bayes

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Teorema de Bayes

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Posterior: o que quero saber depois da evidência

(*e.g., probabilidade de estar doente dado que estou com febre*)

Teorema de Bayes

***A priori*:** o que eu já sabia antes

(e.g., probabilidade de estar doente)

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Teorema de Bayes

Verossimilhança: chance da evidência ocorrer se a hipótese for real

(*e.g., probabilidade de estar com febre dado que estou doente*)

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Teorema de Bayes

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Normalização: evidência

(e.g., probabilidade de febre)

Métodos Bayesianos

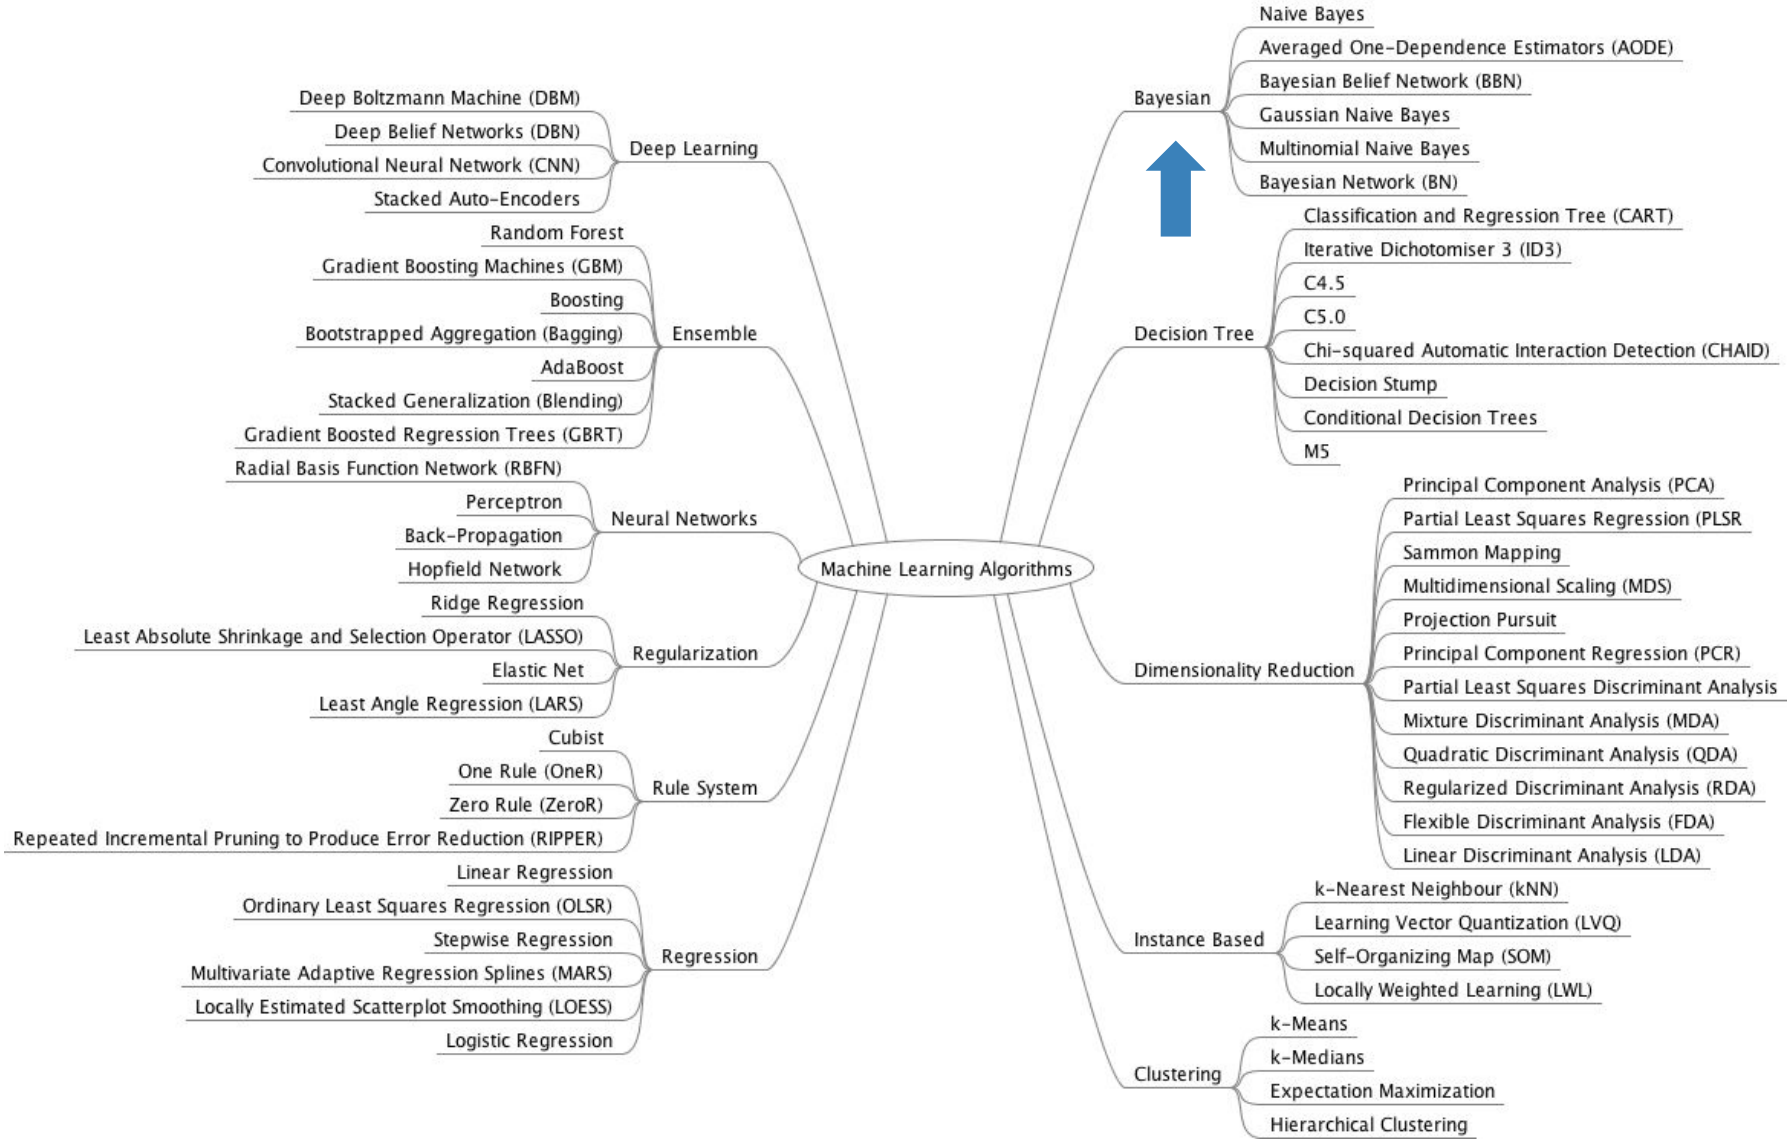

Classificador Bayesiano

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Probabilidade de uma classe **A** dado um conjunto de atributos **B**

Classificador Bayesiano

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

Probabilidade de uma classe **A** dado um conjunto de atributos **B**

Para cada exemplo de teste, a classe predita será a com maior probabilidade posterior

$$classe = argmax\ P(classe|atributos)$$

2.

Naive Bayes

Um classificador ingênuo

Por que Naive Bayes?

Se temos **muitos atributos**, o problema explode combinatoriamente:

$$P(x_1, x_2, \cdots, x_n | classe)$$

Por que Naive Bayes?

Se temos **muitos atributos**, o problema explode combinatoriamente:

$$P(x_1, x_2, \cdots, x_n | classe)$$

Naive Bayes assume **independência** dos atributos

$$P(x_1, x_2, \cdots, x_n | c) = P(x_1|c)P(x_2|c) \cdots P(x_n|c)$$

Por que Naive Bayes?

Se temos **muitos atributos**, o problema explode combinatoriamente:

$$P(x_1, x_2, \cdots, x_n | classe)$$

Naive Bayes assume **independência** dos atributos

$$P(x_1, x_2, \cdots, x_n | c) = P(x_1|c)P(x_2|c)\cdots P(x_n|c)$$

Não é totalmente verdade na vida real, mas costuma funcionar **muito bem**

Fórmula do Naive Bayes

Assumindo que **os valores dos atributos de um exemplo são independentes entre si dada a classe**, a probabilidade de um exemplo com atributos (x_1, ... x_n) pertencer à classe *c* é proporcional à expressão:

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Fórmula do Naive Bayes

Assumindo que **os valores dos atributos de um exemplo são independentes entre si dada a classe**, a probabilidade de um exemplo com atributos (x_1, ... x_n) pertencer à classe *c* é proporcional à expressão:

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Probabilidade *a priori* da classe

Fórmula do Naive Bayes

Assumindo que **os valores dos atributos de um exemplo são independentes entre si dada a classe**, a probabilidade de um exemplo com atributos (x_1, ... x_n) pertencer à classe *c* é proporcional à expressão:

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Probabilidade do atributo x_j dada a classe

Algoritmo Naive Bayes

Se quero classificar uma novo exemplo de teste:

1. No conjunto de treinamento, para cada classe:
   a. Calcular *a priori* **P(classe)**
   b. Calcular **P(atributo | classe)**
   c. Multiplicar P(classe) e P(atributo | classe) para todos os atributos
2. Escolher **classe de maior probabilidade**

Naive Bayes – Exemplo

Um banco quer classificar o risco de inadimplência dos clientes dadas as suas características.

Naive Bayes – Exemplo

Histórico	Dívida	Garantias	Renda Anual	Risco
Ruim	Alta	Nenhuma	<15k	Alto
Desconhecido	Alta	Nenhuma	15k-35k	Alto
Desconhecido	Baixa	Nenhuma	15k-35k	Moderado
Desconhecido	Baixa	Nenhuma	>35k	Alto
Desconhecido	Baixa	Nenhuma	>35k	Baixo
Desconhecido	Baixa	Adequada	>35k	Baixo
Ruim	Baixa	Nenhuma	<15k	Alto
Ruim	Baixa	Adequada	>35k	Moderado
Bom	Baixa	Nenhuma	>35k	Baixo
Bom	Alta	Nenhuma	>35k	Baixo
Bom	Alta	Nenhuma	<15k	Alto
Bom	Alta	Nenhuma	15k-35k	Moderado
Bom	Alta	Nenhuma	>35k	Baixo
Ruim	Alta	Nenhuma	15k-35k	Alto

Naive Bayes – Exemplo

Um banco quer classificar o risco de inadimplência dos clientes dadas as suas características.

Exemplo de teste:

- *Histórico: Bom*
- *Dívida: Alta*
- *Garantias: Nenhuma*
- *Renda: >35k*

Naive Bayes – Exemplo

Atributos

	Histórico			*Dívida*		*Garantia*		*Renda anual*		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto										
Mod.										
Baixo										

Classes (*target*)

Naive Bayes – Exemplo

Calcular *a priori* P(classe) **para cada classe**

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14										
Mod. 3/14										
Baixo 5/14										

Naive Bayes – Exemplo

Calcular P(atributo | classe)

	Histórico			*Dívida*		*Garantia*		*Renda anual*		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

P(Historico = “Bom” | Risco = “Alto”) = 1/6
Dos 6 exemplos com risco alto, 1 tem histórico bom

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	**1/6**	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

p(Risco = "Alto" | *atributos*) = ?

p(Risco = "Moderado" | *atributos*) = ?

p(Risco = "Baixo" | *atributos*) = ?

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

p(Risco = "Alto" | *atributos*) = ?

p(Risco = "Moderado" | *atributos*) = ?

p(Risco = "Baixo" | *atributos*) = ?

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

P(Risco = "Alto" | *atributos*) ∝

P(Risco = "Alto")

* P(Histórico = "Bom" | Risco = "Alto")

* P(Dívida = "Alta" | Risco "Alto")

* P(Garantia = "Nenhuma" | Risco "Alto")

* P(Renda = ">35k" | Risco "Alto")

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

P(Risco = "Alto" | *atributos*) ∝ 6/14 * 1/6 * 4/6 * 6/6 * 1/6
∝ 0,0079

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

P(Risco = "Alto" | *atributos*) ∝ 0,0079

P(Risco = "Mod." | *atributos*) ∝ 3/14 * 1/3 * 1/3 * 2/3 * 1/3

∝ 0,0052

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

P(Risco = "Alto" | *atributos*) ∝ 0,0079

P(Risco = "Mod." | *atributos*) ∝ 0,0052

P(Risco = "Baixo" | *atributos*) ∝ 5/14 * 3/5 * 2/5 * 3/5 * 5/5

∝ 0,0514

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

P(Risco = "Alto" | *atributos*) ∝ 0,0079

P(Risco = "Mod." | *atributos*) ∝ 0,0052

P(Risco = "Baixo" | *atributos*) ∝ 0,0514

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

Exemplo de teste:

- Histórico: Bom
- Dívida: Alta
- Garantias: Nenhuma
- Renda: >35k

Qual a probabilidade de cada classe dadas estes valores de atributos?

P(Risco = "Alto" | *atributos*) ∝ 0,0079

P(Risco = "Mod." | *atributos*) ∝ 0,0052

P(Risco = "Baixo" | *atributos*) ∝ 0,0514

Escolhemos a classe com o **maior valor**

	Histórico			***Dívida***		***Garantia***		***Renda anual***		
Risco	**Bom**	**Desc.**	**Ruim**	**Alta**	**Baixa**	**Nenh.**	**Adeq.**	**<15k**	**15k-35k**	**>35k**
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0/6	3/6	2/6	1/6
Mod. 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0/3	2/3	1/3
Baixo 5/14	3/5	2/5	0/5	2/5	3/5	3/5	2/5	0/5	0/5	5/5

Naive Bayes – Exemplo

Por que ainda estamos usando $\propto$ e não = ?

Naive Bayes – Exemplo

Por que ainda estamos usando $\propto$ e não = ?

Por que a soma das probabilidades não dá 1?

P(Risco = “Alto” | atributos) + P(Risco = “Mod.” | atributos) + P(Risco = “Baixo” | atributos) = 0,0079 + 0,0052 + 0,0514 = 0,0645

Naive Bayes – Exemplo

Por que ainda estamos usando ∝ e não = ?

Por que a soma das probabilidades não dá 1?

P(Risco = “Alto” | atributos) + P(Risco = “Mod.” | atributos) + P(Risco = “Baixo” | atributos) = 0,0079 + 0,0052 + 0,0514 = 0,0645

- Isso ocorre porque **ainda não estamos calculando probabilidades normalizadas**, mas sim valores proporcionais à probabilidade posterior
  - Ou seja, são apenas scores comparáveis

Naive Bayes – Exemplo

Por que ainda estamos usando ∝ e não = ?

Por que a soma das probabilidades não dá 1?

P(Risco = “Alto” | atributos) + P(Risco = “Mod.” | atributos) + P(Risco = “Baixo” | atributos) = 0,0079 + 0,0052 + 0,0514 = 0,0645

- Para transformar em probabilidades reais, basta dividir pela soma total

  P(Risco = “Alto” | atributos) = 0,0079 / 0,0645 = 0,122

  P(Risco = “Mod.” | atributos) = 0,0052 / 0,0645 = 0,081

  P(Risco = “Baixo” | atributos) = 0,0514 / 0,0645 = 0,797

Naive Bayes – Exemplo

Por que ainda estamos usando ∝ e não = ?

Por que a soma das probabilidades não dá 1?

P(Risco = “Alto” | atributos) + P(Risco = “Mod.” | atributos) + P(Risco = “Baixo” | atributos) = 0,0079 + 0,0052 + 0,0514 = 0,0645

- Para transformar em probabilidades reais, basta dividir pela soma total

P(Risco = “Alto” | atributos) = 0,0079 / 0,0645 = **0,122**

P(Risco = “Mod.” | atributos) = 0,0052 / 0,0645 = **0,081**

P(Risco = “Baixo” | atributos) = 0,0514 / 0,0645 = **0,797**

Agora sim a soma é 1

Naive Bayes – Exemplo

Por que ainda estamos usando ∝ e não = ?

Por que a soma das probabilidades não dá 1?

P(Risco = “Alto” | atributos) + P(Risco = “Mod.” | atributos) + P(Risco = “Baixo” | atributos) = 0,0079 + 0,0052 + 0,0514 = 0,0645

- Para transformar em probabilidades reais, basta dividir pela soma total

P(Risco = “Alto” | atributos) = **0,0079** / 0,0645 = 0,122

P(Risco = “Mod.” | atributos) = **0,0052** / 0,0645 = 0,081

P(Risco = “Baixo” | atributos) = **0,0514** / 0,0645 = 0,797

Na prática, muitos algoritmos nem fazem essa normalização

Naive Bayes – Implementação

Como lidar com atributos nominais e contínuos?

- ***Atributos nominais (categóricos)***
  - Basta manter um contador para cada valor de atributo por classe
- ***Atributos contínuos (numéricos)***
  - Assumir distribuição para valores (e.g., normal)
  - Discretizar valores
    - A literatura mostra que produz resultados melhores (Dougherty et al. 1995; Domingos e Pazzani, 1997)

Naive Bayes – Exemplo #2

Quero saber se vou jogar vôlei no clube a partir das características do clima do dia.

Naive Bayes – Exemplo #2

Aparência	Temperatura	Umidade	Ventando	Jogar
Sol	Quente	Alta	Não	Não
Sol	Quente	Alta	Sim	Não
Nublado	Quente	Alta	Não	Sim
Chuva	Agradável	Alta	Não	Sim
Chuva	Fria	Normal	Não	Sim
Chuva	Fria	Normal	Sim	Não
Nublado	Fria	Normal	Sim	Sim
Sol	Agradável	Alta	Não	Não
Sol	Fria	Normal	Não	Sim
Chuva	Agradável	Normal	Não	Sim
Sol	Agradável	Normal	Sim	Sim
Nublado	Agradável	Alta	Sim	Sim
Nublado	Quente	Normal	Não	Sim
Chuva	Agradável	Alta	Sim	Não

Naive Bayes – Exemplo #2

Exemplo de teste:

- Aparência: Sol
- Temperatura: Fria
- Umidade: Normal
- Ventando: Não

Vou jogar?

Agora é com vocês :)

Aparência	Temperatura	Umidade	Ventando	Jogar
Sol	Quente	Alta	Não	Não
Sol	Quente	Alta	Sim	Não
Nublado	Quente	Alta	Não	Sim
Chuva	Agradável	Alta	Não	Sim
Chuva	Fria	Normal	Não	Sim
Chuva	Fria	Normal	Sim	Não
Nublado	Fria	Normal	Sim	Sim
Sol	Agradável	Alta	Não	Não
Sol	Fria	Normal	Não	Sim
Chuva	Agradável	Normal	Não	Sim
Sol	Agradável	Normal	Sim	Sim
Nublado	Agradável	Alta	Sim	Sim
Nublado	Quente	Normal	Não	Sim
Chuva	Agradável	Alta	Sim	Não

Naive Bayes – Exemplo #2

Exemplo de teste:

- Aparência: Sol
- Temperatura: Fria
- Umidade: Normal
- Ventando: Não

	Aparência			***Temperatura***			***Umidade***		***Ventando***	
Jogar	**Sol**	**Nubl.**	**Chuva**	**Quen.**	**Agr.**	**Fria**	**Alta**	**Norm.**	**Sim**	**Não**
Sim										
Não										

Naive Bayes – Exemplo #2

Exemplo de teste:

- Aparência: Sol
- Temperatura: Fria
- Umidade: Normal
- Ventando: Não

	Aparência			***Temperatura***			***Umidade***		***Ventando***	
Jogar	**Sol**	**Nubl.**	**Chuva**	**Quen.**	**Agr.**	**Fria**	**Alta**	**Norm.**	**Sim**	**Não**
Sim 9/14	2/9	4/9	3/9	2/9	4/9	3/9	3/9	6/9	3/9	6/9
Não 5/14	3/5	0/5	2/5	2/5	2/5	1/5	4/5	1/5	3/5	2/5

Naive Bayes – Exemplo #2

Exemplo de teste:

- Aparência: Sol
- Temperatura: Fria
- Umidade: Normal
- Ventando: Não

$$P(c|x_1, \cdots x_n) \propto P(c) \prod_{j=1}^{n} P(x_j|c)$$

P(Jogar = "Sim" | *atributos*) ∝ 9/14 * 2/9 * 3/9 * 6/9 * 6/9
∝ 0,021

P(Jogar = "Não" | *atributos*) ∝ 5*14 * 3/5 * 1/5 * 1/5 * 2/5
∝ 0,003

	Aparência			***Temperatura***			***Umidade***		***Ventando***	
Jogar	**Sol**	**Nubl.**	**Chuva**	**Quen.**	**Agr.**	**Fria**	**Alta**	**Norm.**	**Sim**	**Não**
Sim 9/14	2/9	4/9	3/9	2/9	4/9	3/9	3/9	6/9	3/9	6/9
Não 5/14	3/5	0/5	2/5	2/5	2/5	1/5	4/5	1/5	3/5	2/5

Onde usar Naive Bayes?

Funciona muito bem com textos!

Diagnóstico médico baseado em sintomas

Filtro de spam

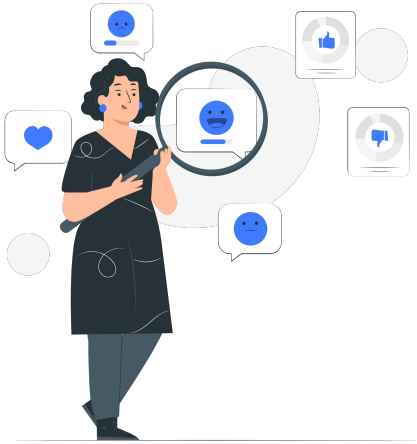

Análise de sentimentos

3.
Redes Bayesianas

Uma breve intuição

Nem tudo é tão independente assim...

O Naive Bayes é ótimo, mas ele vive em uma bolha onde os atributos não se conversam

Nem tudo é tão independente assim...

O Naive Bayes é ótimo, mas ele vive em uma bolha onde os atributos não se conversam

- **Exemplo:** se você tem "Escolaridade Alta", a chance de ter "Salário Alto" é maior. Eles são dependentes!
- Ignorar essas conexões pode fazer o modelo tomar decisões burras

Redes Bayesianas

Uma rede bayesiana é um **grafo direcionado** que representa <u>dependências probabilísticas</u>

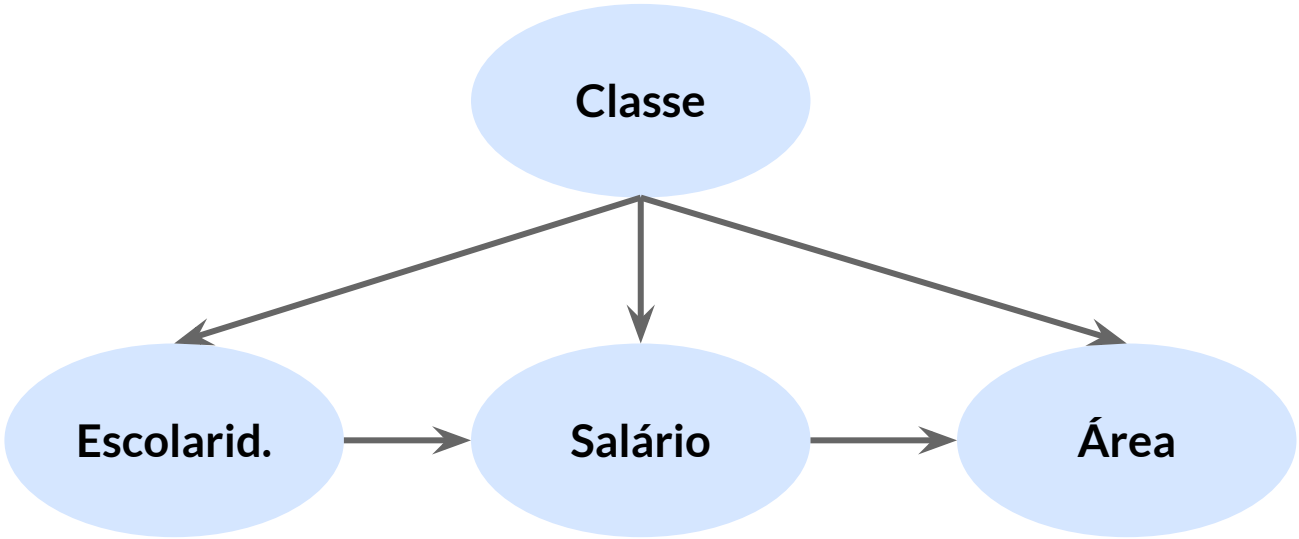

Redes Bayesianas

Uma rede bayesiana é um **grafo direcionado** que representa <u>dependências probabilísticas</u>

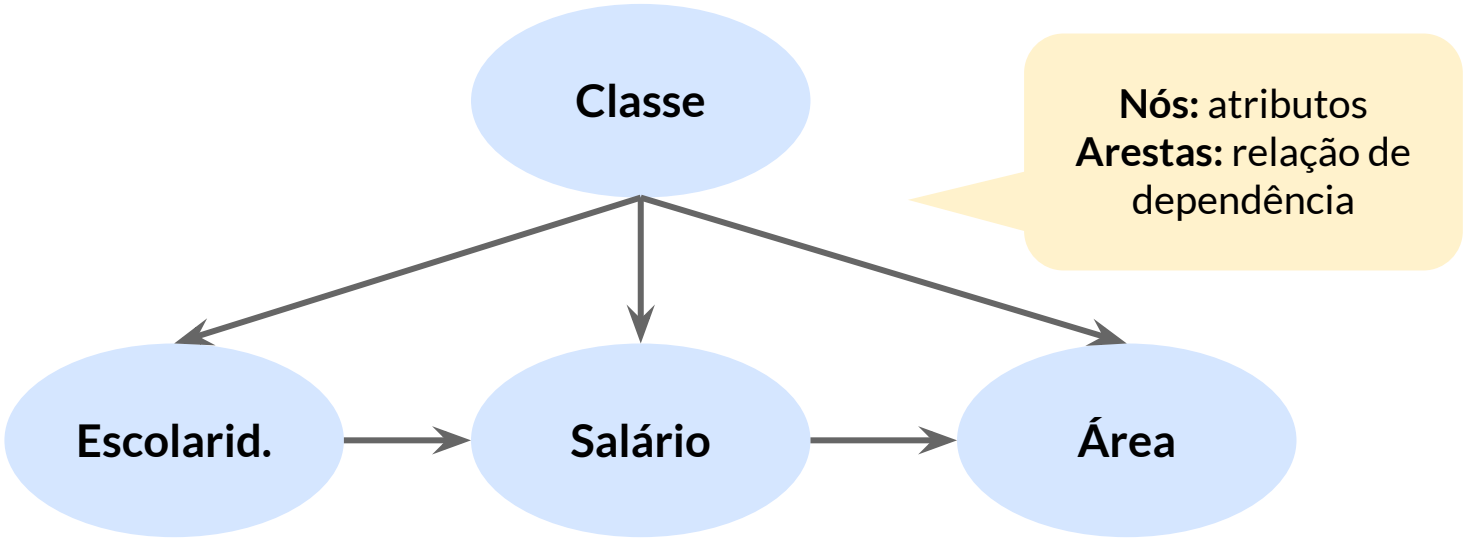

Redes Bayesianas

Uma rede bayesiana é um **grafo direcionado** que representa <u>dependências probabilísticas</u>

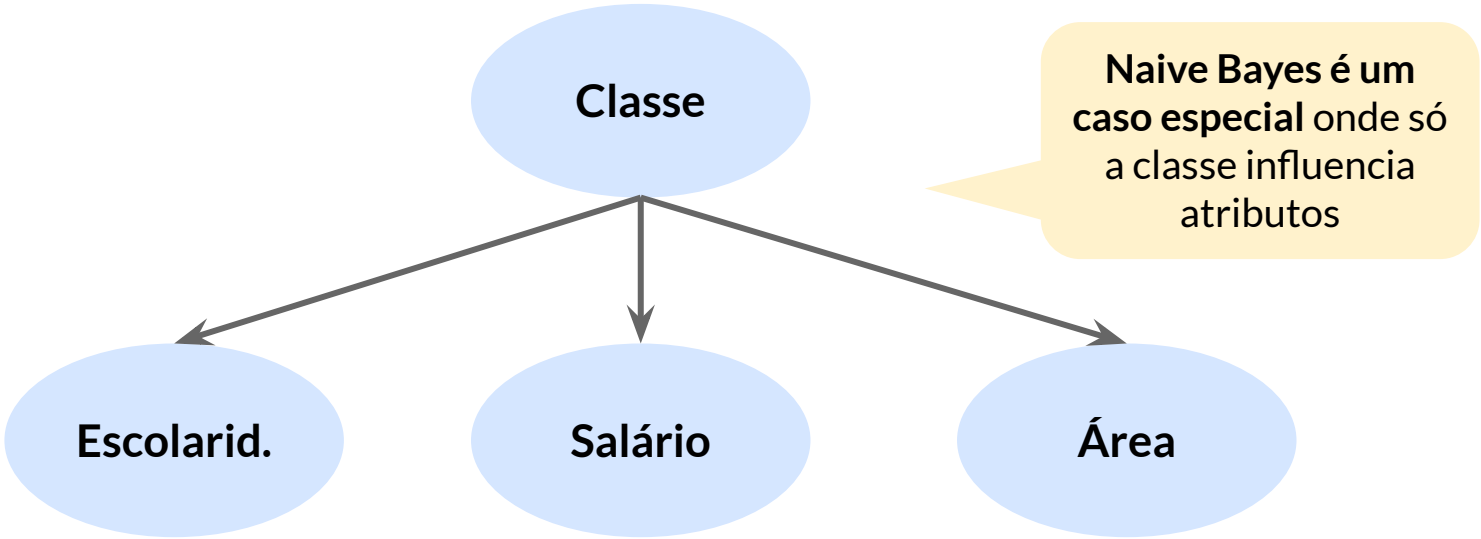

Redes Bayesianas

Classificadores Bayesianos com k-Dependências (k-CBDs)

Cada atributo pode depender de no máximo k atributos

- **0-CBD → Naive Bayes**
  Não permite dependências
- **1-CBD → Classificador TAN**
  Tree Augmented Naive Bayes
- **2-CBD → Classificador BAN**
  Bayesian Augmented Naive Bayes

Referências

FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina.** Rio de Janeiro, RJ: LTC, 2011. (***Capítulo 5)***

Material da Profa. Cristiane Nobre