

Redes Neurais Convolucionais (CNNs)




Gabriel P. Oliveira

Inteligência Artificial
2026/1

O que é mais difícil para um computador?



Reconhecer um gato




Resolver equações
diferenciais

O que é mais difícil para um computador?



Reconhecer um gato



Resolver equações
diferenciais

Por quê? Como resolver?


Visão computacional é a área dentro de IA que permite ao computador extrair conhecimento de imagens (ele pode “enxergar”)

O que é mais difícil para um computador?

Como nosso cérebro faz isso em um piscar de olhos?



Reconhecer um gato




Resolver equações
diferenciais

Por quê? Como resolver? Redes Neurais :)

Se modelos como árvore de decisão aprendem regras explícitas, por que precisamos de redes neurais para resolver certos problemas?

AI? ML? DL? Generative AI?



AI? ML? DL? Generative AI?

Artificial Intelligence

Is the field of study

Machine Learning


Is a branch of AI that focus on the creation of intelligent machines that learn from data. Another very well know branch inside AI is **Optimization**.

Deep Learning


Is a subset of Machine Learning methods, based on **Artificial Neural Networks**.
Examples: CNNs, RNNs

Generative AI

A type of ANNs that generate data that is similar to the data it was trained on.
Examples: GANs, LLMs



Aplicações de RNAs



Redes Neurais



1.

Redes Neurais

Relembrando os principais conceitos

O que são Redes Neurais?

Aprendizado supervisionado

- ▷ **Árvore de Decisão** → regras
- ▷ **Métodos Ensemble** → combinação de classificadores
- ▷ **Naive Bayes** → probabilidades

- ▷ **Rede Neural** → ?


O que são Redes Neurais?

Aprendizado supervisionado

- ▷ **Árvore de Decisão** → regras
- ▷ **Métodos Ensemble** → combinação de classificadores
- ▷ **Naive Bayes** → probabilidades


- ▷ **Rede Neural** → padrões complexos representados como combinação de **pesos e ativações**

Redes multicamadas




Redes multicamadas


Camada de
entrada




Redes multicamadas




Redes multicamadas




Redes multicamadas



Redes multicamadas




Multilayer Perceptron (MLP)



É a combinação das funções desempenhadas por cada neurônio que define a função associada à RNA


Multilayer Perceptron (MLP)




É a combinação das funções desempenhadas por cada neurônio que define a função associada à RNA

Por que não utilizá-las para classificar imagens?


Multilayer Perceptron (MLP)




Multilayer Perceptron (MLP)




Multilayer Perceptron (MLP)



Multilayer Perceptron (MLP)



Multilayer Perceptron (MLP)



Problemas do MLP

- ▷ Uma imagem de 224×224 pixels RGB (3 valores) tem **mais de 150 mil valores de entrada**
- ▷ Conectando a 1.000 neurônios na 1ª camada → **150 milhões de pesos** para aprender
 - Computacionalmente muito caro
- ▷ MLP não considera estrutura espacial das imagens
 - O pixel do olho do gato é tratado igual ao da pata

Intuição das Redes Convolucionais

Como nosso cérebro
faz isso em um piscar
de olhos?



Reconhecer um gato

Ele não olha todos os pixels
ao mesmo tempo

Ele varre a imagem em
pedaços locais


*É exatamente isso que as
CNNs tentam imitar!*

2.

Histórico das CNNs

Uma breve linha do tempo

Histórico das RNAs



Histórico das CNNs

- ▷ As bases do que conhecemos como redes convolucionais remonta aos **anos 1970**
- ▷ Artigo seminal → LeCun, Bengio e Haffner (1998)
 - [Gradient-based Learning Applied to Document Recognition](#)
 - As ideias já estavam sendo discutidas desde 1989

PROC. OF THE IEEE, NOVEMBER 1998

1

Gradient-Based Learning Applied to Document Recognition

Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner

Histórico das CNNs

- ▷ Muito legal! Só que... ficou **dormindo por 14 anos**
 - Faltava poder computacional e dados

Histórico das CNNs

- ▷ Muito legal! Só que... ficou **dormindo por 14 anos**
 - Faltava poder computacional e dados
- ▷ 2012 → **AlexNet** vence o desafio ImageNet
 - Erro de ~15% contra 26% dos concorrentes
 - Revolução do DL → uso de GPUs
 - Google compra a startup DNN Research



Alex Krizhevsky

[University of Toronto](#)

Verified email at cs.toronto.edu - [Homepage](#)

[Machine Learning](#)



TITLE

CITED BY

YEAR

[Imagenet classification with deep convolutional neural networks](#)

A Krizhevsky, I Sutskever, GE Hinton

194934 *

2012



Histórico das CNNs

- ▷ O uso de CNNs despertou interesse das bigtechs
 - Google → busca de imagens
 - Amazon → recomendação de produtos
 - Instagram → sistema de busca
 - Facebook → marcação de usuários em fotos

Histórico das CNNs

- ▷ Fim dos anos 2000 → termo *deep learning* começa a ganhar popularidade
- ▷ Redes neurais de várias camadas sendo pré-treinadas uma camada por vez

Deep Boltzmann Machines


Ruslan Salakhutdinov
Department of Computer Science
University of Toronto
rsalakhu@cs.toronto.edu

Geoffrey Hinton
Department of Computer Science
University of Toronto
hinton@cs.toronto.edu


Deep Learning

- ▷ Embora chamativo, é apenas um termo para descrever certos tipos de redes neurais e algoritmos relacionados que consomem dados de entrada geralmente muito brutos
 - Muitas camadas de transformações não lineares

Simple Neural Network



Deep Learning Neural Network



● Input Layer

● Hidden Layer


● Output Layer

Deep Learning


- ▷ Embora chamativo, é apenas um termo para descrever certos tipos de redes neurais e algoritmos relacionados que consomem dados de entrada geralmente muito brutos
 - Muitas camadas de transformações não lineares

Uma rede neural com muitas camadas é uma **rede profunda**

Simple Neural Network



Deep Learning Neural Network



● Input Layer

● Hidden Layer

● Output Layer

Histórico das CNNs

- ▷ 2017 → **adoção em massa** do *Deep Learning* (DL) em diversas aplicações corporativas e mobile
 - Todos os eventos de tecnologia apontam DL como a principal tecnologia para criação de sistemas inteligentes

Histórico das CNNs

- ▷ 2017 → **adoção em massa** do *Deep Learning* (DL) em diversas aplicações corporativas e mobile
 - Todos os eventos de tecnologia apontam DL como a principal tecnologia para criação de sistemas inteligentes
- ▷ 2022 → **lançamento do ChatGPT**, interface Web para um LLM (*Large Language Model*)
 - Explosão no uso de IA em todo planeta
 - LLMs são arquiteturas de DL baseadas em *Transformers* e módulo de auto-atenção


3.

Redes Convolucionais

Inspiração e definições

Inspiração biológica para CNNs


- ▷ O cérebro reconhece objetos **partindo de primitivas básicas** (e.g., patas e rabo de um cachorro) e vai iterativamente construindo conceitos mais abstratos
 - Orientação seletiva
 - Campo receptivo local



Inspiração biológica para CNNs

- ▷ O cérebro reconhece objetos **partindo de primitivas básicas** (e.g., patas e rabo de um cachorro) e vai iterativamente construindo conceitos mais abstratos
 - Orientação seletiva
 - Campo receptivo local

Dá pra reconhecer quem é só vendo o nariz? E o olho?




Inspiração biológica para CNNs

- ▷ O cérebro reconhece objetos **partindo de primitivas básicas** (e.g., patas e rabo de um cachorro) e vai iterativamente construindo conceitos mais abstratos
 - Orientação seletiva
 - Campo receptivo local

Dá pra reconhecer quem é só vendo o nariz? E o olho?

O cérebro também precisa acumular **evidências locais!**




Convolução

*Olhar para pequenas regiões locais da imagem, **detectar padrões** nessas regiões, e **combinar essas informações** em camadas cada vez mais abstratas*


Uma **Rede Neural Convolucional** (ConvNet, *Convolutional Neural Network*, ou CNN) é um algoritmo de *Deep Learning* que pode (i) **captar uma imagem** de entrada, (ii) **atribuir importância** (pesos e vieses que podem ser aprendidos) a vários aspectos/objetos da imagem e (iii) ser capaz de **diferenciar um do outro**

Redes convolucionais




Redes convolucionais


Etapa 1: Convolução




Redes convolucionais



Redes convolucionais



Redes convolucionais



Etapa 1 – Convolução

- ▷ Etapa de extração de características (features)
- ▷ A rede passa pequenos filtros matemáticos (**kernels**) por toda a imagem
 - Cada filtro procura um padrão específico: linhas retas e bordas; depois formas geométricas; e nas camadas mais profundas, partes complexas como focinhos ou olhos
 - A imagem é uma matriz e o kernel é outra matriz

Em vez de olhar a imagem toda de uma vez, a rede usa uma “lupa”. Ela olha um pedacinho, procura um padrão, anota, e move a lupa.

Etapa 1 – Convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

1	0	0
1	0	1
0	1	1

Filtro (kernel)


Detector de características

0				

Mapa de características
Feature map

$$0*1 + 0*0 + 0*0 + 0*1 + 1*0 + 0*1 + 0*0 + 0*1 + 0*1 = 0$$

Etapa 1 – Convolução



$$0*1 + 0*0 + 0*0 + 1*1 + 0*0 + 0*1 + 0*0 + 0*1 + 0*1 = 1$$

Etapa 1 – Convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

1	0	0
1	0	1
0	1	1

Filtro (*kernel*)


Detector de características

0	1	0		

Mapa de características
Feature map


$$0*1 + 0*0 + 0*0 + 0*1 + 0*0 + 0*1 + 0*0 + 0*1 + 0*1 = 0$$

Etapa 1 – Convolução



$$1*1 + 0*0 + 0*0 + 1*1 + 0*0 + 1*1 + 0*0 + 1*1 + 1*1 = 5$$

Etapa 1 – Convolução



Veja online: <https://setosa.io/ev/image-kernels/>

Etapa 1 – Convolução

- ▷ Com o mapa de características (*feature map*), a **imagem fica menor** para facilitar o processamento
- ▷ Podemos perder alguma informação sobre a imagem, mas o propósito é **detectar as partes principais**
- ▷ O *feature map* **preserva as características principais** da imagem (e.g., olho, boca)

Etapa 1 – Convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7


1	0	0
1	0	1
0	1	1

Filtro (kernel)

Detector de características

0	1	0	1	0
0	2	1	1	2
1	2	2	3	1
1	3	3	3	2
1	3	1	3	5

Mapa de características
Feature map



Aplicamos a **função de ativação ReLU** no *feature map*

Etapa 1 – Convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

?


Filtro (*kernel*)
Detector de características

0	1	0	1	0
0	2	1	1	2
1	2	2	3	1
1	3	3	3	2
1	3	1	3	5

Mapa de características
Feature map

Qual o melhor kernel possível?

Etapa 1 – Convolução

<i>Original</i>	<i>Gaussian Blur</i>	<i>Sharpen</i>	<i>Edge Detection</i>
$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	$\frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$
			


Etapa 2 – *Pooling*

- ▷ É a etapa de redução de dimensionalidade
 - Seleciona as características mais relevantes da imagem
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros

Se a convolução detectou que há uma borda ali, o pooling simplesmente diz: "Sim, a borda está por aqui", sem precisar saber o pixel exato.

Etapa 2 – *Pooling*

- ▷ É a etapa de redução de dimensionalidade
 - Seleciona as características mais relevantes da imagem
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros



Mapa de características
Feature map

Etapa 2 – *Pooling*

- ▷ É a etapa de redução de dimensionalidade
 - Seleciona as características mais relevantes da imagem
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros

0	1	0	1	0
0	2	1	1	2
1	2	2	3	1
1	3	3	3	2
1	3	1	3	5

Mapa de características
Feature map

Max
Pooling




Não tem
overlap

2	1	

Etapa 2 – *Pooling*


- ▷ É a etapa de redução de dimensionalidade
 - Seleciona as características mais relevantes da imagem
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros



Mapa de características
Feature map

Etapa 2 – Pooling


- ▷ É a etapa de redução de dimensionalidade
 - Seleciona as características mais relevantes da imagem
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros



Mapa de características
Feature map


Etapa 2 – Pooling

- ▷ É a etapa de redução de dimensionalidade
 - Seleciona as características mais relevantes da imagem
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros



Redes convolucionais

As etapas 1 e 2 geralmente se **repetem várias vezes** na arquitetura da CNN, extraindo padrões cada vez mais complexos





Etapa 3 – *Flattening*

- ▷ É a etapa de preparação dos dados
 - Transforma matrizes → vetores 1D
- ▷ Pode-se usar o máximo (*max pooling*), a média dos valores, dentre outros

As Redes Neurais Tradicionais (Redes Densas) não sabem ler matrizes quadradas; elas só aceitam dados em linha reta.

Etapa 3 – *Flattening*



Rede neural densa
MLP

Etapa 4 – Rede Neural Densa

- ▷ É a etapa de classificação em si
 - Geralmente é uma rede MLP (*fully connected*)
 - Recebe a lista de números (que são as características extraídas e resumidas pelas etapas anteriores) e aprende a combiná-las para tomar a decisão final

Ela analisa as pistas (“temos bordas arredondadas, uma textura de pelo e duas orelhas pontudas”) e dá a probabilidade final matemática (e.g., "95% de chance de ser um Gato e 5% de chance de ser um Cachorro").

Veja a execução em tempo real

Simule uma rede neural em:

https://adamharley.com/nn_vis/cnn/2d.html

Exemplo Prático

Veja um exemplo em Python:

<https://www.deeplearningbook.com.br/reconhecimento-de-imagens-com-redes-neurais-convolucionais-em-python-parte-4/>

Referências

RUSSELL, Stuart J.; NORVIG, Peter. **Artificial intelligence: a modern approach**. 4th ed. Pearson, 2021. (**Capítulo 21**)

Material da Profa. Cristiane Nobre

<https://www.deeplearningbook.com.br/uma-breve-historia-das-redes-neurais-artificiais/>