


Técnicas de Agrupamento (*Clustering*)



Gabriel P. Oliveira

Inteligência Artificial
2026/1


Tarefas de Aprendizado



Agrupamento na vida real

Exemplos?

Agrupamento na vida real



Com agrupamento
Fácil de encontrar
Cada coisa em seu lugar



Sem agrupamento
Caos total

1.

O que é agrupamento

Conceitos e definições

Agrupamento em ML/IA

O objetivo é encontrar uma estrutura de grupos (clusters) nos dados em que os objetos de cada grupo compartilham alguma característica ou propriedade relevante.

Agrupamento em ML/IA

Organização de instâncias de um conjunto de dados:


- ▷ Objetos **dentro** de um mesmo grupo → muito similares entre si
- ▷ Objetos de **grupos diferentes** → pouco similares

Técnica descritiva → Muito interessante para descobrir padrões nos dados


Como você agruparia estes animais?



Como você agruparia estes animais?



Com bico



Sem bico

Como você agruparia estes animais?



Água

Terra

Como você agruparia estes animais?




Ave


Peixe

Mamífero


De uma forma mais geral...




(a) Objetos



(b) Agrupamento pela forma (2 *clusters*)



(c) Agrupamento pelo preenchimento (2 *clusters*)




(d) Agrupamento pelo preenchimento e pela forma (4 *clusters*)

Descrição do Problema


Dado um **conjunto de instâncias** descritas por múltiplos **atributos**:

1. Atribuir grupos (*clusters*) aos objetos, dividindo-os em grupos homogêneos para:
 - a. **Maximizar** a similaridade de objetos dentro de um mesmo grupo
 - b. **Minimizar** a similaridade de objetos entre grupos distintos
2. Atribuir uma descrição para cada cluster encontrado
 - a. Pode servir como **rótulo** para uma tarefa de classificação

Descrição do Problema



Descrição do Problema




2.


Etapas do Agrupamento

Qual é o passo a passo?

Etapas do Agrupamento




Etapas do Agrupamento




Pré-processamento

- ▷ Pode incluir **normalizações, conversão de tipos e redução do número de atributos**
- ▷ **Sem informação** de possíveis classificações
 - Algumas técnicas de seleção não se aplicam
- ▷ **Representação depende do algoritmo**
 - Alguns exigem representação específica
 - Outros apenas a relação de proximidade

Etapas do Agrupamento




Descrição do Problema



Como dizer se uma instância é **similar** a outra?


Métricas de Distância

Considerando pontos $X = (x_1, x_2, \dots, x_p)$ e $Y = (y_1, y_2, \dots, y_p)$



Métricas de Distância

Considerando pontos $X = (x_1, x_2, \dots, x_p)$ e $Y = (y_1, y_2, \dots, y_p)$




Euclidiana: distância em linha reta entre dois pontos

$$D(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Métricas de Distância

Considerando pontos $X = (x_1, x_2, \dots, x_p)$ e $Y = (y_1, y_2, \dots, y_p)$




Cosseno: cosseno do ângulo entre dois vetores

$$D(x, y) = \cos(\theta) = \frac{x \cdot y}{\|x\| \|y\|}$$

Métricas de Distância

Considerando pontos $X = (x_1, x_2, \dots, x_p)$ e $Y = (y_1, y_2, \dots, y_p)$




Manhattan: soma diferenças absolutas entre coordenadas

$$D(x, y) = \sum_{i=1}^k |x_i - y_i|$$

Métricas de Distância

Considerando pontos $X = (x_1, x_2, \dots, x_p)$ e $Y = (y_1, y_2, \dots, y_p)$




Minkowski: generalização de Euclidiana e Manhattan, controlada por um parâmetro p

$$D(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}$$

$p = 1 \rightarrow$ Manhattan
 $p = 2 \rightarrow$ Euclidiana
 $p = \infty \rightarrow$ Chebyshev (maior dif. entre atributos)


Etapas do Agrupamento



Tipos de Agrupamento

1. **Particional** → Divide em k grupos sem sobreposição
2. **Hierárquico** → Cria árvore de clusters (dendograma)
3. **Por densidade** → Grupos por regiões densas de pontos
4. **Baseado em modelo** → Assume que pontos têm uma certa distribuição

Etapas do Agrupamento



Validação

Objetivo → determinar se os grupos (clusters) são significativos

- ▷ Pode ajudar na determinação do número apropriado de grupos para um conjunto de dados
- ▷ No entanto, como não há classificação dos dados conhecida, é difícil realizar esta análise


Validação

Alguns fatores que têm influência no desempenho dos algoritmos de agrupamento:

- ▷ **Estrutura** dos grupos (forma, tamanho, quantidade)
- ▷ Presença de *outliers*
- ▷ Grau de **sobreposição** dos grupos
- ▷ Escolha da **medida de similaridade** (distância)

Existem alguns índices para qualidade de clusters (e.g., *Silhouette Index*)

Etapas do Agrupamento



Interpretação

Objetivo → examinar cada grupo com relação a seus objetos e definir uma descrição (“rótulo”)


- ▷ É fundamental a utilização do **conhecimento da pessoa especialista**
- ▷ Visualização dos grupos podem ajudar na interpretação

3.

Tipos de Agrupamento

Quais são os principais tipos de agrupamento?


Agrupamento em ML/IA



Tipos de Agrupamento

1. **Particional** → Divide em k grupos sem sobreposição
2. **Hierárquico** → Cria árvore de clusters (dendograma)
3. **Por densidade** → Grupos por regiões densas de pontos
4. **Baseado em modelo** → Assume que pontos têm uma certa distribuição

Tipos de Agrupamento



Tipos de Agrupamento

1. **Particional** → Divide em k grupos sem sobreposição
2. **Hierárquico** → Cria árvore de clusters (dendograma)
3. **Por densidade** → Grupos por regiões densas de pontos
4. **Baseado em modelo** → Assume que pontos têm uma certa distribuição

4.

Agrupamento Particional

Quando há um número definido de grupos

Agrupamento Particional

Ideia → dividir objetos de dados em subconjuntos (grupos) sem sobreposição, de forma que cada objeto está em exatamente um subconjunto

Exemplos → K-means, K-medoids



Agrupamento Particional

Métodos que fornecem partições → Produzem uma partição de conjunto **D** de **n** objetos em **k** grupos

Dado k , particione em k grupos otimizando um critério:

- ▷ **Ótimo global:** enumeração exaustiva de todas as partições
- ▷ **Heurísticas:** *k-means* e *k-medoids*
 - **K-means** → Cada grupo é representado pelo seu centro
 - **K-medoids** → Cada grupo é representado por um objeto

K-Means



K-Means

1. Selecione k pontos como centroides iniciais

Repita


1. Forme k grupos associando cada objeto a seu centroide mais próximo
2. Recalcule o centroide de cada grupo

Até que os centroides não apresentem mudanças

Centroide → “centro de gravidade” do grupo

- ▷ É o ponto representativo de cada grupo
- ▷ Cada coordenada i é a média das coordenadas i dos objetos do grupo

K-Means



Visualização interativa: <https://clustering-visualizer.web.app/>

K-Means: observações

- ▷ Boa parte dos grupos **já convergem nos primeiros passos do algoritmo**, ficando somente uma quantidade pequena de grupos que ainda modificam
- ▷ Assim, a condição de parada do algoritmo é substituída por ***“até que somente 1% dos objetos mudam de clusters”***

K-Means: cuidados importantes

Pré-processamento

- ▷ Se os atributos possuem valores em escalas diferentes, dependendo da medida usada, **um pode dominar o outro** no cálculo da proximidade

O que fazer?

- ▷ Normalização dos dados
- ▷ Escolher métrica de distância que não dependa da magnitude dos dados

K-Means: cuidados importantes

Pós-processamento

- ▷ Eliminar pequenos grupos que podem ser *outliers*
- ▷ Dividir grupos “frouxos”, i.e., com erro alto
- ▷ Unir grupos que estão “próximos” e tenham erro baixo

K-Means: principais limitações

Precisa definir k manualmente

- ▷ Não sabe quantos grupos existem
- ▷ Se escolher k errado, os resultados podem ser ruins

Como resolver → Use o Método do Cotovelo (Elbow Method), testando $k=2,3,4...$ e observe onde o erro para de cair abruptamente

K-Means: principais limitações

Sensível aos centroides iniciais

- ▷ Centroides iniciais aleatórios podem gerar resultados completamente diferentes a cada execução


Como resolver → *Existem variações (como o K-means++) que escolhe centroides iniciais mais espalhados, reduzindo o risco de convergência ruim*

K-Means: principais limitações

Assume grupos esféricos


- ▷ Não funciona bem com clusters de formato irregular (e.g., crescentes, aneis)

Como resolver → Use métodos de agrupamento por densidade (e.g., DBSCAN) que encontra grupos de qualquer formato sem precisar definir k




K-Means: principais limitações

Assume grupos esféricos



Pontos originais



K-means (2 grupos)

K-Means: principais limitações


Sensível a diferentes tamanhos/densidades

- ▷ Grupos muito maiores ou mais densos “dominam” os menores


Como resolver → *Use mais grupos que o esperado e depois agrupe grupos pequenos vizinhos*

K-Means: principais limitações

Sensível a diferentes tamanhos/densidades




Pontos originais




K-means (3 grupos)

K-Means: principais limitações

Sensível a diferentes tamanhos/densidades



Pontos iniciais



K-means (3 grupos)

5.

Qualidade do Agrupamento

Como dizer se a saída do algoritmo foi boa?

Por que precisamos avaliar?

“A validação de estruturas de agrupamento é a parte mais difícil e frustrante da análise de grupos.”

(Jain e Dubes, 1988)

Por que precisamos avaliar?

PROBLEMA → qualquer algoritmo SEMPRE encontra grupos — mesmo em dados completamente aleatórios!

- ▷ Ou seja, encontrar grupos não prova que eles existem de verdade

Sem validação ❌

Não sabemos se os clusters são reais
ou apenas ruído estatístico

Com validação ✅

Métricas objetivas quantificam se os
grupos são realmente coerentes

Validação de agrupamento

Validação → termo amplo para os vários procedimentos que avaliam de maneira objetiva e quantitativa os resultados de análise de agrupamento

Maneira quantitativa é alcançada através de algum tipo de **índice** (ou critério de validade)

Índices e critérios de validade

Externos → usa gabarito (partição de referência)

“Avalia o grau de correspondência entre a estrutura de grupos (partição ou hierarquia) sob avaliação e informação a priori na forma de uma solução de agrupamento esperada ou conhecida”

Internos → só usa os próprios dados

“Avalia o grau de compatibilidade entre a estrutura de grupos sob avaliação e os dados, usando apenas os próprios dados”

Critérios de validade externos

Mesmo que o problema de agrupamento seja não supervisionado, **em alguns cenários o resultado de agrupamento desejado pode já ser conhecido**

- ▷ Conjunto de dados Iris
- ▷ Outros *benchmarks*

Critérios de validade externos → Índices que medem o nível de compatibilidade entre uma partição obtida e uma partição de referência

Critérios de validade externos

Critérios de validade externos → Índices que medem o nível de compatibilidade entre uma partição obtida e uma partição de referência

- ▷ **Rand Index:** mede a concordância entre dois agrupamentos
- ▷ **Rand Index Ajustado:** índice anterior ajustado para o acaso
- ▷ **Jaccard:** mede a similaridade entre conjuntos pela interseção sobre união
- ▷ **Overall F Measure:** combina precisão e revocação (*recall*)
- ▷ **Normalized Mutual Information (NMI):** mede a informação compartilhada entre agrupamentos

Critérios de validade internos

O mais comum é não dispor de uma partição ou hierarquia de referência para validar o agrupamento

Critérios de validade internos → Índices que avaliam a estrutura obtida utilizando apenas os próprios dados

Critérios de validade internos

Critérios de validade internos → Índices que avaliam a estrutura obtida utilizando apenas os próprios dados

- **Silhouette Index:** mede quão bem cada elemento se ajusta ao seu agrupamento em comparação aos demais
- **Sum of Squared Error (SSE):** mede a compactação dos clusters pela soma dos erros quadráticos internos
- **Davies-Bouldin:** avalia a separação e compactação dos clusters, onde valores menores são melhores
- **Dunn:** mede a razão entre separação dos clusters e compactação interna, onde valores maiores são melhores
- **Calinski-Harabasz:** avalia a qualidade dos clusters pela relação entre dispersão entre e dentro dos grupos

Critérios de validade internos

Critérios de validade internos → Índices que avaliam a estrutura obtida utilizando apenas os próprios dados

- ▷ **Silhouette Index:** mede quão bem cada elemento se ajusta ao seu agrupamento em comparação aos demais
- ▷ **Sum of Squared Error (SSE):** mede a compactação dos clusters pela soma dos erros quadráticos internos
- ▷ **Davies-Bouldin:** avalia a separação e compactação dos clusters, onde valores menores são melhores
- ▷ **Dunn:** mede a razão entre separação dos clusters e compactação interna, onde valores maiores são melhores
- ▷ **Calinski-Harabasz:** avalia a qualidade dos clusters pela relação entre dispersão entre e dentro dos grupos

Silhouette Index

Avalia a **coesão e a separação dos grupos**, baseando-se na diferença entre a distância média dos pontos pertencentes ao grupo mais próximo para os pontos de um grupo

Silhouette Index

Para cada ponto x_i , calcula o valor do índice S_i :

“Estou mais próximo dos colegas do meu cluster ou dos vizinhos do cluster ao lado?”

$$S_i = \frac{\mu_{out}^{min}(x_i) - \mu_{in}(x_i)}{\max(\mu_{out}^{min}(x_i), \mu_{in}(x_i))}$$

Silhouette Index

Para cada ponto x_i , calcula o valor do índice S_i :

“Estou mais próximo dos colegas do meu cluster ou dos vizinhos do cluster ao lado?”

Coesão: Distância média de x_i para todos os pontos do seu próprio cluster
(Quanto menor, melhor)


$$S_i = \frac{\mu_{out}^{min}(x_i) - \mu_{in}(x_i)}{\max(\mu_{out}^{min}(x_i), \mu_{in}(x_i))}$$

Silhouette Index

Para cada ponto x_i , calcula o valor do índice S_i :

“Estou mais próximo dos colegas do meu cluster ou dos vizinhos do cluster ao lado?”

Separação: Distância média de x_i para os pontos do cluster mais próximo (que não é o seu)
(Quanto maior, melhor)


$$S_i = \frac{\mu_{out}^{min}(x_i) - \mu_{in}(x_i)}{\max(\mu_{out}^{min}(x_i), \mu_{in}(x_i))}$$

Silhouette Index

Valores de S_i estão sempre no intervalo $[-1, 1]$

- ▷ Valor próximo a 1 indica que x_i está **mais próximo dos pontos do seu próprio cluster** e distante dos clusters vizinhos
- ▷ Valor próximo de 0 indica que x_i está **próximo da fronteira de dois clusters**
- ▷ Valor próximo a -1 indica que x_i está **próximo dos pontos que pertencem a outro cluster**

Silhouette Index

Se S_i é calculado para cada ponto, como avaliar a qualidade do agrupamento no geral?

- ▶ **Silhouette Index Global** → média de S_i para todos os pontos
 - Pode ser usado para comparar diferentes valores de k no K-Means, por exemplo

Valor	Significado
0.71 - 1.0	Uma estrutura forte foi encontrada
0.51 - 0.70	Uma estrutura razoável foi encontrada
0.26 - 0.50	A estrutura é fraca e pode ser artificial
< 0.25	Nenhuma estrutura substancial foi encontrada

Fonte: Adaptado de Rousseeuw (1987)

Critérios de validade internos

Critérios de validade internos → Índices que avaliam a estrutura obtida utilizando apenas os próprios dados

- **Silhouette Index:** mede quão bem cada elemento se ajusta ao seu agrupamento em comparação aos demais
- **Sum of Squared Error (SSE):** mede a compactação dos clusters pela soma dos erros quadráticos internos
- **Davies-Bouldin:** avalia a separação e compactação dos clusters, onde valores menores são melhores
- **Dunn:** mede a razão entre separação dos clusters e compactação interna, onde valores maiores são melhores
- **Calinski-Harabasz:** avalia a qualidade dos clusters pela relação entre dispersão entre e dentro dos grupos

Critérios de validade internos

Critérios de validade internos → Índices que avaliam a estrutura obtida utilizando apenas os próprios dados

- ▷ **Silhouette Index:** mede quão bem cada elemento se ajusta ao seu agrupamento em comparação aos demais
- ▷ **Sum of Squared Error (SSE):** mede a compactação dos clusters pela soma dos erros quadráticos internos
- ▷ **Davies-Bouldin:** avalia a separação e compactação dos clusters, onde valores menores são melhores
- ▷ **Dunn:** mede a razão entre separação dos clusters e compactação interna, onde valores maiores são melhores
- ▷ **Calinski-Harabasz:** avalia a qualidade dos clusters pela relação entre dispersão entre e dentro dos grupos

Sum of Squared Error (SSE)

O SSE mede o **quão compactos são os clusters** — a soma das distâncias quadradas de cada ponto ao seu centroide


$$SSE = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

Sum of Squared Error (SSE)

O SSE mede o **quão compactos são os clusters** — a soma das distâncias quadradas de cada ponto ao seu centroide


$$SSE = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

Objeto dentro do cluster C_i



Sum of Squared Error (SSE)

O SSE mede o **quão compactos são os clusters** — a soma das distâncias quadradas de cada ponto ao seu centroide

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$


Centroide do cluster C_i

The diagram shows a curved arrow pointing from the text 'Centroide do cluster C_i' to the variable c_i in the formula, which is highlighted with a light blue rectangular background.

Sum of Squared Error (SSE)

O SSE mede o **quão compactos são os clusters** — a soma das distâncias quadradas de cada ponto ao seu centroide

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} \text{dist}(p, c_i)^2$$


Distância euclidiana entre p e c_i

Sum of Squared Error (SSE)

- ▷ SSE menor → clusters mais compactos → melhor qualidade
- ▷ SSE = 0 quando cada ponto é o único em seu cluster
 - Normalmente não é o objetivo do agrupamento
- ▷ **Aumentar k sempre reduz SSE!**
 - Como saber o k ideal?


$$SSE = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

Elbow Method



1. Execute K-Means para $k=2, 3, \dots, N$
2. Calcule o SSE para cada k
3. Plote o gráfico SSE x k
4. Encontre o “cotovelo” (onde a curva para de cair rápido)
5. Escolha este k

Elbow Method



1. Execute K-Means para $k=2, 3, \dots, N$
2. Calcule o SSE para cada k
3. Plote o gráfico SSE x k
4. Encontre o “cotovelo” (onde a curva para de cair rápido)
5. Escolha este k

ATENÇÃO! O “cotovelo” pode não ser tão óbvio em dados reais

6.

Considerações Importantes

Para finalizar

Boas práticas

1

Normalização

Se atributos têm escalas diferentes (renda R\$0–50k vs. idade 0–100), o atributo de maior escala dominará a distância. Normalize utilizando min-max ou z-score.

Boas práticas

1

Normalização

Se atributos têm escalas diferentes (renda R\$0–50k vs. idade 0–100), o atributo de maior escala dominará a distância. Normalize utilizando min-max ou z-score.

2

Outliers

Outliers distorcem centroides no K-means. Identifique com boxplot ou IQR e remova ou trate antes de aplicar o algoritmo.

Boas práticas

1

Normalização

Se atributos têm escalas diferentes (renda R\$0–50k vs. idade 0–100), o atributo de maior escala dominará a distância. Normalize utilizando min-max ou z-score.

2

Outliers

Outliers distorcem centroides no K-means. Identifique com boxplot ou IQR e remova ou trate antes de aplicar o algoritmo.

3

Atributos categóricos

K-means usa médias, então não funciona com texto. Use K-modes (para categorias puras) ou codifique via one-hot encoding com cautela (alta dimensionalidade).

Boas práticas

1

Normalização

Se atributos têm escalas diferentes (renda R\$0–50k vs. idade 0–100), o atributo de maior escala dominará a distância. Normalize utilizando min-max ou z-score.

2

Outliers

Outliers distorcem centroides no K-means. Identifique com boxplot ou IQR e remova ou trate antes de aplicar o algoritmo.

3

Atributos categóricos

K-means usa médias, então não funciona com texto. Use K-modes (para categorias puras) ou codifique via one-hot encoding com cautela (alta dimensionalidade).

4

Seleção de atributos

Atributos irrelevantes adicionam ruído. Use correlação, PCA ou análise de domínio para selecionar as variáveis mais discriminativas antes de agrupar.

7.

Agrupamento + Classificação

Quando combinar as duas técnicas

Um exemplo prático

Uma clínica quer prever se novos pacientes têm risco de desenvolver diabetes com base em características deles.

Um exemplo prático

Uma clínica quer prever se novos pacientes têm risco de desenvolver diabetes com base em características deles.

- ▷ Simples, é um problema de **classificação** :)

Um exemplo prático

Uma clínica quer prever se novos pacientes têm risco de desenvolver diabetes com base em características deles.

- ▷ Simples, é um problema de **classificação** :)

Problema → A clínica tem 1.000 fichas de pacientes com três medições: glicose em jejum, IMC e pressão arterial. Só que nenhuma ficha tem diagnóstico.

- ▷ Não é possível treinar um classificador :(
- ▷ Como resolver?

Um exemplo prático

Passo 1 → Aplicar K-means (clustering)

Roda-se K-means com $K=2$ sobre os três atributos. O algoritmo encontra dois grupos naturais nos dados:

- ▷ Cluster 0: média de glicose = 88, IMC = 23, pressão = 72
- ▷ Cluster 1: média de glicose = 142, IMC = 31, pressão = 86

Um médico olha esses centroides e nomeia:

- ▷ Cluster 0 → Baixo risco
- ▷ Cluster 1 → Alto risco

Conhecimento do especialista de domínio!

Um exemplo prático

Passo 2 → Gerar os pseudo-rótulos

Cada uma das 1.000 fichas recebe o rótulo do cluster ao qual foi atribuída:

Paciente	Glicose	IMC	Pressão	Rótulo Gerado
Ana	95	24	75	Baixo risco
Carlos	138	30	88	Alto risco
Maria	81	22	70	Baixo risco
Pedro	155	33	91	Alto risco

Um exemplo prático

Passo 3 → Treinar um classificador

- ▷ Com os rótulos em mãos, pode-se treinar uma árvore de decisão
 - Glicose, IMC e pressão são atributos
 - Rótulo gerado seria classe alvo
- ▷ A árvore então aprende a regra:
 - “se glicose > 115 e IMC > 27 → Alto risco”

Um exemplo prático

Passo 4 → Predizer novos pacientes

- ▷ Chega Joana, paciente nova
 - Glicose = 131, IMC = 29, pressão = 83
- ▷ A árvore classifica rapidamente: **Alto risco**
- ▷ O K-means não precisa rodar de novo

Um exemplo prático

Por que não usar só o K-Means pra prever?

- ▷ Se a clínica recebesse 200 novos pacientes por mês, **teria que re-rodar o K-means sobre todos os dados** (antigos + novos) a cada vez
- ▷ Isso é caro, lento e não-determinístico (resultado pode mudar com centroides iniciais diferentes)
- ▷ O classificador treinado é **fixo, rápido e sempre dá a mesma resposta** para os mesmos valores

Referências

FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. Rio de Janeiro, RJ: LTC, 2011. (**Capítulos 11 e 12**)

Material da Profa. Cristiane Nobre