

Mineração de Textos



Gabriel P. Oliveira

Inteligência Artificial
2026/1

Mineração de Textos



Mineração de Textos



Tipos de Dados

O que você entende por dados estruturados?

Tipos de Dados

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	37
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	85
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	83
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	27
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	43
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	77
8	7	Smith	David	11/03/1965	Canada	15/11/2016	23
9	8	Brown	Luis	03/09/1997	Australia	03/07/2015	74
10	9	Miller	Thomas	07/01/1980	Germany	07/11/2016	13
11	10	Williams	Bill	26/07/1960	United States	20/11/2015	80
12	11	Gemini	Alexia	12/09/1995	Canada	11/03/2017	35
13	12	Bond	James	25/02/1975	United Kingdom	12/08/2017	40
14	13	Burgle	Patricia	01/12/1990	United States	18/01/2015	55
15	14	Reding	Michelle	07/04/1985	Canada	23/02/2017	28
16	15	Harvey	Billy	14/07/1971	United Kingdom	12/01/2016	41
17							

id	name	age
1	Jim	28
2	Pam	26
3	Michael	42

id	subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

student_id	subject_id	grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

Arial

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet.

```
// example of data.json file
[
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "B  kker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solr  d Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "K  benhavn"
    },
    "emergencyPhoneNumbers": []
  },
  ...
]
```

Tipos de Dados

Arial

Dados estruturados →
organizados em um formato
claro e predefinido

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	37
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	85
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	83
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	27
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	43
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	77
8	7	Smith	David	11/03/1965	Canada	15/11/2016	23
9	8	Brown	Luis	03/09/1997	Australia	03/07/2015	74
10	9	Miller	Thomas	07/01/1980	Germany	07/11/2016	13
11	10	Williams	Bill	26/07/1960	United States	20/11/2015	80
12	11	Gemini	Alexia	12/09/1995	Canada	11/03/2017	35
13	12	Bond	James	25/02/1975	United Kingdom	12/08/2017	40
14	13	Burgle	Patricia	01/12/1990	United States	18/01/2015	55
15	14	Reding	Michelle	07/04/1985	Canada	23/02/2017	28
16	15	Harvey	Billy	14/07/1971	United Kingdom	12/01/2016	41
17							

id	name	age
1	Jim	28
2	Pam	26
3	Michael	42

id	subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

student_id	subject_id	grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

```
// example of data.json file
[
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "Bakker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solrød Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "København"
    },
    "emergencyPhoneNumbers": []
  },
  ...
]
```

Tipos de Dados

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	37
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	85
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	83
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	27
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	43
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	77
8	7	Smith	David	11/03/1965	Canada	15/11/2016	23
9	8	Brown	Luis	03/09/1997	Australia	03/07/2015	74
10	9	Miller	Thomas	07/01/1980	Germany	07/11/2016	13
11	10	Williams	Bill	26/07/1960	United States	20/11/2015	80
12	11	Gemini	Alexia	12/09/1995	Canada	11/03/2017	35
13	12	Bond	James	25/02/1975	United Kingdom	12/08/2017	40
14	13	Burgle	Patricia	01/12/1990	United States	18/01/2015	55
15	14	Reding	Michelle	07/04/1985	Canada	23/02/2017	28
16	15	Harvey	Billy	14/07/1971	United Kingdom	12/01/2016	41
17							

Dados estruturados →
organizados em um formato
claro e predefinido

**Formatos tabulares e
relacionais** muito utilizados

id	name	age
1	Jim	28
2	Pam	26
3	Michael	42

id	subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

student_id	subject_id	grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

```
// example of data.json file
{
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "Bakken",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solrød Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "København"
    },
    "emergencyPhoneNumbers": []
  },
  ...
}
```

Tipos de Dados

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	37
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	85
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	83
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	27
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	43
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	77
8	7	Smith	David	11/03/1965	Canada	15/11/2016	23
9	8	Brown	Luis	03/09/1997	Australia	03/07/2015	74
10	9	Miller	Thomas	07/01/1980	Germany	07/11/2016	13
11	10	Williams	Bill	26/07/1960	United States	20/11/2015	80
12	11	Gemini	Alexia	12/09/1995	Canada	11/03/2017	35
13	12	Bond	James	25/02/1975	United Kingdom	12/08/2017	40
14	13	Burgle	Patricia	01/12/1990	United States	18/01/2015	55
15	14	Reding	Michelle	07/04/1985	Canada	23/02/2017	28
16	15	Harvey	Billy	14/07/1971	United Kingdom	12/01/2016	41
17							

Dados estruturados →
organizados em um formato
claro e predefinido

Formatos tabulares e
relacionais muito utilizados

id	name	age
1	Jim	28
2	Pam	26
3	Michael	42

id	subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

student_id	subject_id	grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

Usuários podem inserir,
pesquisar e manipular dados
estruturados com eficiência

// example of data.json file

```
{  
  "id": 1,  
  "firstName": "Thomas",  
  "lastName": "Bakken",  
  "address": {  
    "streetName": "Tornelisevej",  
    "streetNumber": "10",  
    "city": "Copenhagen",  
    "postalCode": "2200",  
    "country": "Denmark"  
  },  
  "emergencyPhoneNumbers": []  
},  
...  
}
```

Tipos de Dados

Dados não estruturados → não tem formato predefinido

	A	B	
1	Purchase ID	Last name	First name
2	1	Davidson	Michael
3	2	Vito	Jim
4	3	Johnson	Tom
5	4	Lewis	Peter
6	5	Koenig	Edward
7	6	Preston	Jack
8	7	Smith	David
9	8	Brown	Luis
10	9	Miller	Thomas
11	10	Williams	Bill
12	11	Gemini	Alexia
13	12	Bond	James
14	13	Burgle	Patricia
15	14	Reding	Michelle
16	15	Harvey	Billy
17			

Arial

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet.

id	name	age
1	Jim	28
2	Pam	26
3	Michael	42

id	subject	teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

student_id	subject_id	grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

```
// example of data.json file
{
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "Bakker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solrød Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "København"
    },
    "emergencyPhoneNumbers": []
  },
  ...
}
```

Tipos de Dados

Dados não estruturados → não tem formato predefinido

Conjuntos de dados geralmente são grandes

	A	B	
1	Purchase ID	Last name	First name
2	1	Davidson	Michael
3	2	Vito	Jim
4	3	Johnson	Tom
5	4	Lewis	Peter
6	5	Koenig	Edward
7	6	Preston	Jack
8	7	Smith	David
9	8	Brown	Luis
10	9	Miller	Thomas
11			
12			
13			
14			
15			
16			
17			

Arial

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet.

id	name	age
1	Jim	28
2	Pam	26
3	Michael	42

id	subject	teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

student_id	subject_id	grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

```
// example of data.json file
{
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "Bakker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solrød Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "København"
    },
    "emergencyPhoneNumbers": []
  },
  ...
}
```

Tipos de Dados

	A	B
1	Purchase ID	Last name
2	1	Davidson
3	2	Vito
4	3	Johnson
5	4	Lewis
6	5	Koenig
7	6	Preston
8	7	Smith
9	8	Brown
10	9	Miller
11		
12		
13		
14		
15		
16		
17		

Dados não estruturados → não tem formato predefinido

Conjuntos de dados geralmente são grandes

Arial

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet.

ID	Name	Age
1	Jim	28
2	Pam	26
3	Michael	42

ID	Subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry

Exemplos incluem texto livre, imagens e vídeos

```
// example of data.json file
{
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "Bakker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solrød Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "København"
    },
    "emergencyPhoneNumbers": []
  },
  ...
}
```

Tipos de Dados

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	37
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	85
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	83
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	27
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	43
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	77
8	7	Smith	David	11/03/1965	Canada	15/11/2016	23
9							74
10							13
11							80
12							35
13							40
14							55
15							28
16							41
17							

Dados semiestruturados → são a “ponte” entre estruturados e não estruturados

ID	Name	Age
1	Jim	28
2	Pam	26
3	Michael	42

ID	Subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

Student ID	Subject ID	Grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

Arial

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet. Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren, no sea takimata sanctus est Lorem ipsum dolor sit amet.

```
// example of data.json file
[
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "B  kker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solr  d Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "K  benhavn"
    },
    "emergencyPhoneNumbers": []
  },
  ...
]
```

Tipos de Dados

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	
8	7	Smith	David	11/03/1965	Canada	15/11/2016	

Dados semiestruturados → são a “ponte” entre estruturados e não estruturados

Utilizam metadados (e.g., tags e marcadores) para identificar características específicas de dados

ID	Name	Age
1	Jim	28
2	Pam	26
3	Michael	42

ID	Subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry
4	Computers	Victor Stone

Student ID	Subject ID	Grade
2	1	98
1	2	100
1	4	75
3	3	60
2	4	76
3	2	88

```
// example of data.json file
[
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "B  kker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solr  d Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "K  benhavn"
    },
    "emergencyPhoneNumbers": []
  },
  ...
]
```

Tipos de Dados

	A	B	C	D	E	F	G
1	Purchase ID	Last name	First name	Birthday	Country	Date of purchase	Amount of purchase
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	
8	7	Smith	David	11/03/1965	Canada	15/11/2016	

Dados semiestruturados → são a “ponte” entre estruturados e não estruturados

Utilizam metadados (e.g., tags e marcadores) para identificar características específicas de dados

ID	Name	Age
1	Jim	28
2	Pam	26
3	Michael	42

ID	Subject	Teacher
1	Languages	John Jones
2	Track	Wally West
3	Swimming	Arthur Curry


Exemplos incluem arquivos JSON e XML

```
// example of data.json file
[
  {
    "id": 1,
    "firstName": "Thomas",
    "lastName": "Bækker",
    "address": {
      "streetName": "Tornelisevej",
      "streetNumber": "10",
      "city": "Solrød Strand"
    },
    "emergencyPhoneNumbers": ["+4530303030", "+4510203040"]
  },
  {
    "id": 2,
    "firstName": "Niels",
    "lastName": "Bohr",
    "address": {
      "streetName": "Flemsevej",
      "streetNumber": "31A",
      "city": "København"
    },
    "emergencyPhoneNumbers": []
  },
  ...
]
```

Mineração de Textos

- ▷ Trabalhos clássicos de Aprendizado de Máquina normalmente trabalham com **dados estruturados**
- ▷ No entanto, grande quantidade da informação disponibilizada na Web está em formato de texto não estruturado
 - Estima-se que mais de 80% de todas as informações produzidas no mundo sejam de **dados não estruturados!**

Mineração de Textos



Fonte: <https://deep-talk.medium.com/80-of-the-worlds-data-is-unstructured-7278e2ba6b73>

Mineração de Textos

Mineração de textos é o processo de transformar texto não estruturado em um formato estruturado para identificar padrões significativos e novas informações.

Mineração de Textos

Objetivo → processar a informação textual para **extrair índices numéricos** significativos e tornar esta informação acessível para os programas disponíveis nos sistemas de mineração de dados

- ▷ Análise de **palavras, conjuntos de palavras ou documentos** através de suas similaridades

Mineração de Textos

Objetivo → processar a informação textual para **extrair índices numéricos** significativos e tornar esta informação acessível para os programas disponíveis nos sistemas de mineração de dados

TEXT MINING INVOLVES A SERIES OF ACTIVITIES TO BE PERFORMED IN ORDER TO EFFICIENTLY MINE THE INFORMATION. THESE ACTIVITIES ARE:




Fonte: <https://solutionshub.epam.com/blog/post/what-is-text-mining>

Mineração de Textos


Objetivo → processar a informação textual para **extrair índices numéricos** significativos e tornar esta informação acessível para os programas disponíveis nos sistemas de mineração de dados

TEXT MINING INVOLVES A SERIES OF ACTIVITIES TO BE PERFORMED IN ORDER TO EFFICIENTLY MINE THE INFORMATION. THESE ACTIVITIES ARE:



Fonte: <https://solutionshub.epam.com/blog/post/what-is-text-mining>

Proc. de Linguagem Natural (PLN/NLP)



“Subárea da IA cujo objetivo é permitir que computadores compreendam e se comuniquem com a linguagem humana.”

Aplicações em NLP

The screenshot displays the Google Translate web interface. At the top, there are tabs for 'Texto' (selected), 'Imagens', 'Documentos', and 'Sites'. Below these, language selection options are shown: 'Detectar idioma', 'Italiano', 'Português (Brasil)', and 'Inglês' (selected). The input text in English is: 'Subfield of computer science and artificial intelligence (AI) that uses machine learning to enable computers to understand and communicate with human language'. The output text in Portuguese (Brazil) is: 'Subárea da ciência da computação e da inteligência artificial (IA) que utiliza aprendizado de máquina para permitir que computadores compreendam e se comuniquem com a linguagem humana.' A blue callout bubble labeled 'Tradução de texto' points to the translated text. Another blue callout bubble labeled 'Transcrição de fala' points to the microphone icon in the bottom left of the input area. The bottom right of the interface includes icons for copy, Google logo, and share, along with a link to 'Enviar feedback'.

Tradução de texto

Transcrição de fala

Aplicações em NLP

Correção de textos

The image shows a word processing application window with a blue header bar containing icons for home, save, undo, redo, and print. Below the header is a ribbon with tabs for Home, Insert, Draw, Design, and Layout. The Home tab is active, showing a 'Paste' button and a font selection area with 'Calibri (Bo...)' and '12'. The main text area contains two paragraphs. The first paragraph is: 'With their combined reach and complimentary business models the merger of these two great companies will forever change, consumer eyewear.' The second paragraph is: 'Marketing Plan The glasses will actually have state-of-the-art geotagging technology.' A green speech bubble points from the 'Correção de textos' header to the first paragraph. A floating window on the right displays a correction suggestion for the word 'complimentary'. The suggestion box has a title bar with a speech bubble, a gear, and a close button. The title is 'Correctness: Spelling' with an information icon. The text shows the original word 'complimentary' in red and the suggested word 'complementary' in green. Below the text are three buttons: 'Accept' (green), 'Dismiss', and '...'. At the bottom of the suggestion box are three options: 'models · Add a comma', 'change, · Remove the comma', and 'actually · Remove the phrase'. At the bottom of the floating window is a progress bar with five segments: 'Correctness' (red), 'Clarity' (blue), 'Engagement' (green with checkmark), 'Delivery' (green with checkmark), and 'Style guide' (green with checkmark). A green 'G' logo is visible at the bottom left of the floating window.

With their combined reach and complimentary business models the merger of these two great companies will forever change, consumer eyewear.

Marketing Plan
The glasses will actually have state-of-the-art geotagging technology.

Correctness: Spelling ⓘ


...their combined reach and **complimentary**
complementary business models the merger...

Accept Dismiss ...

- models · Add a comma
- change, · Remove the comma
- actually · Remove the phrase

Correctness Clarity Engagement Delivery Style guide

Aplicações em NLP



Legendas em
imagens

Aplicações em NLP




“Alexa”



“Ok Google”



“Hey Siri”



Chatbots



Fonte: <https://www.blip.ai/blog/chatbots/tudo-sobre-chatbot/>

Aplicações em NLP

- ▷ Processamento automático de mensagens, “e-mails”,
- ▷ conteúdo de redes sociais, etc
- ▷ Análise de sentimentos
- ▷ Classificação de documentos
- ▷ Detecção de fraudes
- ▷ Filtros de *spam*
- ▷ Análise de questões abertas em questionários

E mais...

Classificação de textos



Considerações importantes

- ▷ Mais apropriado para um grande número de textos de tamanho médio ou pequeno
- ▷ **Não** deve ser tratado como uma caixa preta
 - **Intervenção do analista é necessária**
- ▷ Soluções **não podem ser importadas de outra língua**
 - O que funciona para o inglês pode não funcionar para o português (e vice versa)

Eventos específicos para PT



17th International Conference on Computational Processing of Portuguese (PROPOR) – Salvador, BA



17th Symposium on Information Technology and Human Language (STIL) – Cuiabá, MT

Cartas Indígenas ao Brasil: Classificação Multi-Rótulo

Caio Almeida

Universidade Federal da Bahia

Renata Vieira

Universidade de Évora

Débora Abdalla

Universidade Federal da Bahia

<https://aclanthology.org/2026.propor-1.70.pdf>

Principais Abordagens

Estatística

- ▷ Frequência dos termos, ignorando informações semânticas

Processamento de Linguagem Natural


- ▷ Interpretação sintática e semântica das frases

1.


Pipeline de pré-processamento

Quando o texto vira dados

Pré-processamento de texto



Pré-processamento de texto



Parsing


Envolve quebrar o texto em unidades básicas (*tokens*)

- ▷ Fragmentar o texto original com base no conceito de “termo” adotado
- ▷ Remoção das marcações HTML/XML
 - Ninguém quer indexar <div> e <\div> :-D
- ▷ Normalização: letras maiúsculas, pontuação, acentos

Exemplo:

“Eu sou o Gabriel” → [“eu”, “sou”, “o”, “gabriel”]

Pré-processamento de texto



Remoção de *stop words*


“Palavras tão comuns que não carregam informação nenhuma para distinguir documentos.”

- ▷ Uma **stop list** é um conjunto de palavras que são consideradas “irrelevantes”
 - Normalmente inclui artigos, preposições, conjunções
- ▷ A stop list pode variar entre conjuntos de documentos
 - Em um domínio jurídico, não pode ser muito importante

Exemplo:

["eu", "sou", "o", "gabriel"] → ["eu", "sou", "gabriel"]

Pré-processamento de texto



Análise sintática

PoS tagging → *Part of Speech* (classe gramatical)

- ▷ Definir o tipo gramatical dos termos presentes no vetor de termos
- ▷ Lidar com a ambiguidade (posição da palavra no texto)
 - Eu canto muito mal. → VERBO
 - A sereia tem um canto muito bonito. → SUBSTANTIVO


Exemplos online: <https://parts-of-speech.info/>

Análise sintática

- ▶ **Sinonímia:** quando uma palavra possui vários sinônimos
 - Carro = automóvel = veículo
 - O modelo precisa saber que são a mesma coisa

- ▶ **Polissemia:** quando uma mesma palavra tem diferentes significados dependendo do contexto
 - Manga → da camisa ou fruta?
 - Mineração → de dados ou de ferro?
 - Banco → da praça ou instituição financeira?

Pré-processamento de texto



Redução morfológica

- ▷ Um grupo de diferentes palavras podem compartilhar um mesmo radical (*stem*)
- ▷ É preciso identificar grupos de palavras nas quais as **palavras em um mesmo grupo são pequenas variações sintáticas** umas das outras
 - Flor, flora, floricultura → Flor
 - Livro, livraria, livreiro → Livro

Redução morfológica

Stemming → reduzir uma palavra ao seu radical

Lematização → reduz a palavra ao seu lema
(masculino + singular; ou infinitivo no caso de verbos)

Redução morfológica


Stemming → reduzir uma palavra ao seu radical

Lematização → reduz a palavra ao seu lema
(masculino + singular; ou infinitivo no caso de verbos)

	Stemming
meninas	→ menin
meninos	→ menin
drogado	→ drog
drogaria	→ drog
correndo	→ corr

	Lematização
gata, gatos	→ gato
tinha, tem	→ ter
melhores	→ bom
correram	→ correr
crianças	→ criança

Pré-processamento de texto



2.

Representação Vetorial


Como transformar texto em features?

Cálculo de atributos

- ▷ Determinação de quais atributos devem representar ou estar presentes na representação de um texto
- ▷ Existem algumas formas diferentes de realizar
 - *Bag-of-words*
 - TF-IDF
 - *Word embeddings*

Bag-of-words

- ▷ Em um conjunto de n documentos e t termos, é possível modelar cada documento como um vetor $\mathbf{v}$ com t posições (uma para cada termo)
 - Valor pode ser binário (1 = presente no documento; 0 = não)
 - Ou então a frequência do termo no documento



Bag-of-words

Problemas com frequência absoluta

- ▷ Um documento com 10 ocorrências de 'banco' é mais relevante que um com 1 ocorrência?

Bag-of-words

Problemas com frequência absoluta

- ▷ Um documento com 10 ocorrências de 'banco' é mais relevante que um com 1 ocorrência?
 - Provavelmente SIM, mas não 10x mais relevante!
 - Relevância não deve crescer proporcionalmente com frequência

Bag-of-words

D1 Este é um exemplo A.

D2 Este é um mostruário.

D3 Este é outro A, exemplo A.

	A	é	Este	exemplo	mostruário	outro	um
D1	1	1	1	1	0	0	1
D2	0	1	1	0	1	0	1
D3	2	1	1	1	0	1	0

Problema: 'é' e 'Este' aparecem em todos os documentos. Eles são realmente informativos?

Bag-of-words

D1 Este é um exemplo A.

D2 Este é um mostruário.

D3 Este é outro A, exemplo A.

	A	é	Este	exemplo	mostruário	outro	um
D1	1	1	1	1	0	0	1
D2	0	1	1	0	1	0	1
D3	2	1	1	1	0	1	0

Problema: 'é' e 'Este' aparecem em todos os documentos. Eles são realmente informativos? → **NÃO! Não são bons para caracterizar textos individuais**

Bag-of-words

Problemas com frequência absoluta

- ▷ Com textos de tamanhos muito diferentes ou com muitos termos distintos, a maior parte dos valores serão iguais a zero!

Soluções mais interessantes?

TF-IDF

Term Frequency × *Inverse Document Frequency*

Atribui-se um valor a cada termo t , que considera sua frequência no texto e em todos dos documentos da base d , indicando sua importância

TF(t, d)

Term Frequency

nº de vezes que t aparece em d

total de termos em d



IDF(t)

Inverse Document Frequency

$\log(\text{nº total de docs} / \text{nº de docs com } t)$

TF-IDF

D1 Este é um exemplo A.

D2 Este é um mostruário.

D3 Este é outro A, exemplo A.

	A	é	Este	exemplo	mostruário	outro	um
D1	1	1	1	1	0	0	1
D2	0	1	1	0	1	0	1
D3	2	1	1	1	0	1	0

TF-IDF

TF(i, D): número de vezes que o termo i aparece em relação ao total de termos do texto D.

IDF(i): log do número de textos no corpus dividido pelo número de textos que o termo i aparece.

D1 Este é um exemplo A.

D2 Este é um mostruário.

D3 Este é outro A, exemplo A.

	A	é	Este	exemplo	mostruário	outro	um
D1	1	1	1	1	0	0	1
D2	0	1	1	0	1	0	1
D3	2	1	1	1	0	1	0

$$\text{TF}(\text{"Este"}, D1) = 1/5 = 0,2$$

$$\text{TF}(\text{"Este"}, D2) = 1/4 = 0,25$$

$$\text{TF}(\text{"Este"}, D3) = 1/6 = 0,17$$

$$\text{IDF}(\text{"Este"}) = \log(3/3) = 0$$

$$\text{TF}(\text{"Este"}, D1) \times \text{IDF}(\text{"Este"}) = 0,2 \times 0 = 0$$

$$\text{TF}(\text{"Este"}, D2) \times \text{IDF}(\text{"Este"}) = 0,25 \times 0 = 0$$

$$\text{TF}(\text{"Este"}, D3) \times \text{IDF}(\text{"Este"}) = 0,17 \times 0 = 0$$

TF-IDF

TF(i, D): número de vezes que o termo i aparece em relação ao total de termos do texto D.

IDF(i): log do número de textos no corpus dividido pelo número de textos que o termo i aparece.

D1 Este é um exemplo A.

D2 Este é um mostruário.

D3 Este é outro A, exemplo A.

	A	é	Este	exemplo	mostruário	outro	um
D1	1	1	1	1	0	0	1
D2	0	1	1	0	1	0	1
D3	2	1	1	1	0	1	0

$$\text{TF}(\text{"Este"}, D1) = 1/5 = 0,2$$

$$\text{TF}(\text{"Este"}, D2) = 1/4 = 0,25$$

$$\text{TF}(\text{"Este"}, D3) = 1/6 = 0,17$$

$$\text{IDF}(\text{"Este"}) = \log(3/3) = 0$$

$$\text{TF}(\text{"Este"}, D1) \times \text{IDF}(\text{"Este"}) = 0,2 \times 0 = 0$$

$$\text{TF}(\text{"Este"}, D2) \times \text{IDF}(\text{"Este"}) = 0,25 \times 0 = 0$$

$$\text{TF}(\text{"Este"}, D3) \times \text{IDF}(\text{"Este"}) = 0,17 \times 0 = 0$$

Termo aparece em todos → TF-IDF = 0

TF-IDF

TF(i, D): número de vezes que o termo i aparece em relação ao total de termos do texto D.

IDF(i): log do número de textos no corpus dividido pelo número de textos que o termo i aparece.

D1 Este é um exemplo A.

D2 Este é um mostruário.

D3 Este é outro A, exemplo A.

	A	é	Este	exemplo	mostruário	outro	um
D1	1	1	1	1	0	0	1
D2	0	1	1	0	1	0	1
D3	2	1	1	1	0	1	0

$$\text{TF}(\text{"outro"}, D1) = 0/5 = 0$$

$$\text{TF}(\text{"outro"}, D2) = 0/4 = 0$$

$$\text{TF}(\text{"outro"}, D3) = 1/6 = 0,17$$

$$\text{IDF}(\text{"outro"}) = \log(3/1) = 0,48$$

$$\text{TF}(\text{"outro"}, D1) \times \text{IDF}(\text{"outro"}) = 0 \times 0,48 = 0$$

$$\text{TF}(\text{"outro"}, D2) \times \text{IDF}(\text{"outro"}) = 0 \times 0,48 = 0$$

$$\text{TF}(\text{"outro"}, D3) \times \text{IDF}(\text{"outro"}) = 0,17 \times 0,48 = 0,08$$

TF-IDF

Como interpretar?

- ▷ Os textos são representados pelos valores $TF \times IDF$ de cada termo
 - $TF \times IDF$ igual a **zero** indica termo **não relevante**
 - $TF \times IDF$ **maior** indica termo **mais relevante**
- ▷ Textos podem ser agrupados e categorizados com base no vetor de valores $TF \times IDF$

Word embeddings



Problemas no BoW e TF-IDF

- ▷ Vetores obtidos geralmente terão o mesmo tamanho do vocabulário
 - É um problema quando temos vocabulários muito grandes
- ▷ Não conseguem captar significado entre palavras
 - Extraem pouca informação semântica e sintática dos textos

De que outra forma então poderíamos representar palavras?

Word embeddings

Ideia → escalas representando alguma informação sobre cada palavra




	Rainha	Rei
Gênero	-0.95	0.789
Realeza	0.89	0.96
...	...	...
Fruta	0.015	-0.05
Violência	0.56	0.8

Por que isso funciona?

Word embeddings

- ▷ Cada palavra é mapeada para um **vetor denso** de N dimensões (tipicamente 50 a 300)
 - Diferente de TF-IDF: vetor de 50.000 dimensões esparsas → 300 dimensões densas!
- ▷ Operações vetoriais fazem sentido semântico




Word embeddings

Alguns modelos comuns:

- ▷ **Word2Vec** → significado pelo contexto local
- ▷ **GloVe** → significado por coocorrências globais
- ▷ **FastText** → significado usando subpalavras
- ▷ **BERT** → significado dependente do contexto
- ▷ **BERTimbau** → versão PT-BR do BERT



Pré-processamento de texto



Redução de dimensionalidade

- ▶ Quando usamos BoW ou TF-IDF, o vetor de termos que representa os textos pode ser bem grande
 - É necessário reduzir o tamanho destes vetores
 - Ou seja, diminuir o número de termos
- ▶ Duas abordagens
 - Seleção de termos
 - Extração/remoção de termos

3.

Considerações Finais

Como implementar? Conclusões.

Aplicação em Classificação

Um texto como entrada → vetor TF-IDF → classificador → categoria de saída

Exemplo 1: Filtro de Spam

Entrada: "Ganhe R\$10.000 agora! Clique aqui!"

- Tokenização: ['ganhe', 'r\$10000', 'agora', 'clique']
- TF-IDF: 'ganhe', 'clique' → peso alto
- Naive Bayes: $P(\text{spam} | \text{termos}) = 97\%$
- Saída:  SPAM

Exemplo 2: Classificação de Notícia

Entrada: "Flamengo vence o Campeonato Brasileiro"

- Tokens: ['flamengo', 'vence', 'campeonato', 'brasileiro']
- TF-IDF: 'flamengo', 'campeonato' → peso alto
- SVM: vetores de treinamento indicam Esportes
- Saída:  ESPORTES

Principais Ferramentas

NLTK

Python

Biblioteca clássica de PLN. Tokenização, stemming, POS tagging, corpus de referência.

spaCy

Python

PLN industrial. Rápido, modelos pré-treinados em PT, reconhecimento de entidades (NER).

Scikit-learn

Python

TfidfVectorizer, CountVectorizer: TF-IDF em 2 linhas de código. Base dos pipelines de ML.

Hugging Face

Python

BERT, GPT, modelos transformer pré-treinados para tarefas de PLN avançadas.



Referências

Material da Profa. Cristiane Nobre

<https://medium.com/turing-talks/word-embedding-fazendo-o-computador-entender-o-significado-das-palavras-92fe22745057>